

[ÜNİVERSİTE ADI]

[LİSANSÜSTÜ EĞİTİM ENSTİTÜSÜ]

**FİNANSAL METİNLERDE DUYGU ANALİZİ:
FİNBERT, İNCE AYARLI TRANSFORMER VE SIFIR
ÖRNEKLİ MODELLERİN KARŞILAŞTIRMALI
DEĞERLENDİRİLMESİ**

YÜKSEK LİSANS TEZİ

[AD SOYAD]

[ANABİLİM DALI]

Danışman: [UNVAN AD SOYAD]

2026

ÖZET

Bu tez çalışmasında finansal metinlerin olumlu, tarafsız ve olumsuz olarak sınıflandırılması problemi; alan odaklı bir dil modeli olan FinBERT, genel amaçlı Transformer modellerinin hedef veri setine özgü ince ayarlı sürümleri ve doğal dil çıkarımı tabanlı sıfır örnekli modeller aracılığıyla karşılaştırmalı olarak incelenmiştir. Çalışmanın temel amacı, finans alanında önceden eğitilmiş bir model kullanmanın mı, hedef veri setine özgü ince ayar gerçekleştirmenin mi daha belirleyici olduğunu ve iç test başarısının farklı finansal metin kaynaklarına ne ölçüde genellenebildiğini ortaya koymaktır.

Ana veri seti üzerinde hazır ProsusAI/FinBERT modeli eğitim yapılmadan temel model olarak değerlendirilmiş; BERT-base-uncased, DistilBERT-base-uncased ve RoBERTa-base modelleri aynı sınıflandırma görevi için ince ayarlanmıştır. Modeller ayrıca bağımsız S&P 500 haber başlıkları, 3.000 örnekten oluşan sentetik finansal haber veri seti ve 5.000 örnekten oluşan Reuters anotasyon seti üzerinde test edilmiştir. Sıfır örnekli deneylerde BART-MNLI ve farklı NLI model aileleri kullanılmıştır. Temel değerlendirme ölçütü olarak sınıf dengesizliğine karşı daha açıklayıcı olan makro F1 değeri benimsenmiştir.

İç testte RoBERTa-base 0,8906 doğruluk ve 0,8651 makro F1 ile en iyi sonucu elde etmiş; BERT ve DistilBERT modelleri de hazır FinBERT'in 0,6794 makro F1 sonucunu belirgin biçimde aşmıştır. Bağımsız S&P 500 testinde RoBERTa 0,8145 makro F1 ile yine en başarılı model olmuştur. Buna karşılık Reuters testinde hazır FinBERT 0,6866 makro F1 ile ince ayarlı genel amaçlı modelleri geçmiştir. Sentetik veri setindeki çok yüksek performansların gerçek veri genellemesini doğrudan temsil etmediği görülmüştür. Bulgular, model başarısının yalnızca mimari veya alan ön eğitimiyle açıklanamayacağını; veri kaynağı, metin türü ve etiketleme şemasının belirleyici olduğunu göstermektedir.

Anahtar Kelimeler: finansal duygu analizi, FinBERT, BERT, RoBERTa, DistilBERT, ince ayar, sıfır örnekli sınıflandırma, alan kayması, Transformer

ABSTRACT

This thesis comparatively investigates financial text sentiment classification using FinBERT, target-dataset-fine-tuned general-purpose Transformer models, and natural-language-inference-based zero-shot models. The study aims to determine whether finance-

domain pretraining or dataset-specific fine-tuning is more influential and to examine how well internal test performance generalizes to financial texts from different sources.

ProsusAI/FinBERT was evaluated as an off-the-shelf baseline, while BERT-base-uncased, DistilBERT-base-uncased, and RoBERTa-base were fine-tuned for three-class sentiment classification. The models were further evaluated on an independent S&P 500 headline set, a synthetic financial news set containing 3,000 samples, and a Reuters annotation set containing 5,000 samples. Macro-F1 was selected as the primary metric because of class imbalance.

RoBERTa-base achieved the best internal-test result with 0.8906 accuracy and 0.8651 macro-F1. It also ranked first on the S&P 500 external test with 0.8138 macro-F1. In contrast, the original FinBERT obtained the best result on Reuters with 0.6866 macro-F1. These findings indicate that model performance depends on the source distribution, text genre, and annotation scheme rather than solely on model architecture or domain-specific pretraining.

Keywords: financial sentiment analysis, FinBERT, BERT, RoBERTa, DistilBERT, fine-tuning, zero-shot classification, domain shift

İÇİNDEKİLER

İçindekiler tablosunu güncellemek için Word üzerinde sağ tıklayıp Alanı Güncelle seçeneğini kullanınız.

1. GİRİŞ

1.1. Problem Durumu

Finansal piyasalar; şirket açıklamaları, haber akışları, analist raporları, merkez bankası duyuruları ve sosyal medya mesajları gibi yoğun bir metinsel bilgi üretmektedir. Bu içeriklerin elle incelenmesi, veri hacmi ve hız nedeniyle sürdürülebilir değildir. Doğal dil işleme yöntemleri, finansal metinlerden sistematik bilgi çıkarılmasını ve metinde ifade edilen ekonomik etkinin otomatik biçimde sınıflandırılmasını mümkün kılmaktadır.

Finansal duygu analizi genel amaçlı duygu analizinden daha karmaşıktır. Finans dilinde olumsuz görünen bir sözcük, bağlama göre olumlu bir piyasa sinyali taşıyabilir; aynı cümlede gelir artışı ile maliyet artışı gibi zıt yönlü bilgiler birlikte bulunabilir. Ayrıca bazı veri setleri dilsel tonu, bazıları hedef şirket üzerindeki ekonomik etkiyi, bazıları ise yükseliş-düşüş beklentisini etiketlemektedir. Bu nedenle aynı positive, neutral ve negative sınıf adları altında farklı karar kuralları yer alabilmektedir.

BERT tabanlı modeller, bağlamsal dil temsilleri sayesinde finansal duygu analizinde geleneksel sözcük sayımı ve özellik mühendisliği yaklaşımlarına göre önemli avantajlar sağlamıştır. FinBERT gibi finans alanına uyarlanmış modeller, alan terminolojisini öğrenerek güçlü bir başlangıç noktası sunmaktadır. Bununla birlikte alan ön eğitimi, hedef veri setinin kendine özgü etiket politikasını otomatik olarak öğrenmez. Bu çalışma, söz konusu ayrımı deneysel olarak incelemektedir.

1.2. Araştırmanın Amacı

Araştırmanın temel amacı, finansal duygu sınıflandırmasında hazır FinBERT, hedef veri setine özel ince ayarlanmış BERT ailesi modelleri ve sıfır örnekli NLI modellerinin performanslarını karşılaştırmak; modellerin farklı veri kaynaklarına genelleme özelliklerini değerlendirmektir.

- Hazır FinBERT modelinin hedef veri setindeki temel performansını belirlemek.
- BERT-base, DistilBERT-base ve RoBERTa-base modellerini aynı eğitim düzeninde ince ayarlamak.
- Modelleri bağımsız S&P 500, sentetik finans haberleri ve Reuters test setlerinde karşılaştırmak.
- İç test ve dış test sıralamalarının değişip değişmediğini incelemek.

- Özellikle tarafsız sınıftaki hataları etiketleme yaklaşımı ve alan kayması açısından analiz etmek.

1.3. Araştırma Soruları ve Hipotezler

Kod	Araştırma sorusu
AS1	Hedef veri setine özgü ince ayar, hazır FinBERT kullanımına göre performansı artırmakta mıdır?
AS2	BERT, DistilBERT ve RoBERTa arasında iç test performansı bakımından nasıl bir sıralama oluşmaktadır?
AS3	İç testte en başarılı model bağımsız S&P 500 ve Reuters testlerinde de en başarılı mıdır?
AS4	Sıfır örnekli NLI modelleri, denetimli ince ayarlı modellere uygulanabilir bir alternatif sunmakta mıdır?
AS5	Etiketleme şeması ve metin kaynağı özellikle tarafsız sınıfın performansını nasıl etkilemektedir?
AS6	Sentetik veri performansı gerçek finans haberlerindeki genellemeyi ne ölçüde temsil etmektedir?

Hipotezler; ince ayarlı modellerin iç testte FinBERT'i aşacağı, RoBERTa'nın en yüksek iç test başarısını sağlayacağı, model sıralamasının alan kayması nedeniyle tüm dış testlerde korunmayacağı ve en belirgin hata yoğunluğunun tarafsız sınıfta gözleneceği yönünde oluşturulmuştur.

1.4. Araştırmanın Katkıları

- Alan odaklı ön eğitim ile hedef veri setine özgü ince ayar aynı deneysel çerçevede karşılaştırması.
- İç test, yakın alan dış testi ve uzak alan dış testini birlikte değerlendirmesi.
- S&P 500 ve Reuters gibi farklı haber biçimlerinde model sıralamasının değiştiğini göstermesi.
- Etiket semantiği uyumsuzluğunu, yalnızca model hatası olarak değil veri seti tasarımı problemi olarak tartışması.
- Sentetik test sonuçlarının gerçek dünya genellemesi için dikkatli yorumlanması gerektiğine ilişkin kanıt sunması.

1.5. Sınırlılıklar

Çalışma İngilizce finansal metinlerle ve üç sınıflı düz duygu şemasıyla sınırlıdır. Reuters anotasyonlarında insan değerlendirmesini desteklemek üzere model yardımı kullanılmış olması etiket bağımsızlığını sınırlayabilir. Sentetik veri seti gerçek veri çeşitliliğini bütünüyle temsil etmemektedir. İstatistiksel anlamlılık testleri, hesaplama maliyeti ölçümleri ve birden fazla rastgele tohumla tekrarlar tez tesliminden önce eklenmelidir.

2. KURAMSAL ÇERÇEVE VE LİTERATÜR

2.1. Finansal Duygu Analizi

Duygu analizi, metinde ifade edilen değerlendirme veya yönelimin belirlenmesini amaçlar. Finans alanında amaç yalnızca yazarın duygusal tonunu tespit etmek değildir; haberin bir şirket, varlık veya piyasa üzerindeki olası etkisini sınıflandırmak da önemlidir. Bu nedenle finansal duygu analizi, genel ürün yorumu analizinden farklı bir hedef semantiğine sahiptir.

Erken dönem araştırmalar finansal sözlükler, n-gramlar, destek vektör makineleri ve lojistik regresyon üzerinde yoğunlaşmıştır. Loughran ve McDonald tarafından geliştirilen finans sözlüğü, genel sözlüklerde olumsuz kabul edilen birçok kelimenin finansal raporlarda farklı işlevlere sahip olduğunu göstermiştir. Bununla birlikte sözlük yaklaşımları sözcük sırası, olumsuzlama, hedef varlık ve karışık bilgi gibi bağlamsal unsurları sınırlı biçimde temsil etmektedir.

2.2. Transformer ve BERT

Transformer mimarisi, tekrarlayan ağlara ihtiyaç duymadan öz-dikkat mekanizmasıyla uzun bağlam ilişkilerini modellemektedir. Devlin ve arkadaşlarının geliştirdiği BERT, maskeli dil modelleme yoluyla çift yönlü bağlamsal temsiller öğrenmiş ve sınıflandırma görevlerine az miktarda görev-özel katmanla uyarlanabilmiştir (Devlin vd., 2019).

BERT'in finansal duygu analizindeki temel avantajı, bir sözcüğün anlamını cümlelerin geri kalanına göre temsil edebilmesidir. Bununla birlikte genel amaçlı ön eğitim verisi finans terminolojisini sınırlı ölçüde içerdiğinden, alan uyarlaması ve hedef görev ince ayarı önem kazanmaktadır.

2.3. FinBERT ve Alan Odaklı Ön Eğitim

Araci (2019), genel BERT modelini finansal metinlerde devam eden ön eğitim ve görev-özel ince ayar yoluyla FinBERT'e dönüştürmüştür; Financial PhraseBank ve FiQA üzerinde güçlü sonuçlar raporlamıştır. Yang, Uy ve Huang (2020) ise büyük ölçekli finansal iletişim metinleriyle ön eğitilen farklı bir FinBERT sürümünü sunmuştur.

FinBERT'in başarısı finans dilinin özel dağılımına uyarlanmasından kaynaklanmaktadır. Ancak finansal alan tek bir homojen metin türünden oluşmaz. Kurumsal rapor, Reuters haberi, kısa piyasa başlığı ve sosyal medya mesajı arasında belirgin dağılım farkları bulunur. Ayrıca alan ön eğitimi, hedef veri setinin hangi koşullarda neutral etiketi verdiğini öğretmez. Bu nedenle hazır FinBERT ile hedef veri setine özgü ince ayarlı modellerin karşılaştırılması gereklidir.

2.4. RoBERTa ve DistilBERT

RoBERTa, BERT ön eğitim prosedürünü daha fazla veri, dinamik maskeleme, daha büyük mini-batch ve sonraki cümle tahmini görevinin kaldırılması gibi değişikliklerle optimize etmiştir (Liu vd., 2019). Genel amaçlı bir model olmasına rağmen güçlü dil temsilleri, hedef veri setine ince ayar uygulandığında alan odaklı bir modeli geçebilmesini mümkün kılabilir.

DistilBERT, bilgi damıtma yoluyla BERT'in daha küçük ve hızlı bir sürümünü sunar (Sanh vd., 2019). Bu modelin değerlendirilmesi, yalnızca en yüksek doğruluğun değil, model boyutu ve çıkarım maliyeti ile performans arasındaki dengenin de tartışılmasını sağlar.

2.5. Sıfır Örnekli Sınıflandırma

Sıfır örnekli sınıflandırma, hedef göreve ait etiketli eğitim örnekleri olmadan tahmin yapılmasını amaçlar. NLI tabanlı yaklaşımda metin bir öncül, sınıf açıklaması ise hipotez olarak sunulur. BART-MNLI gibi modeller, metnin positive financial sentiment gibi bir hipotezi destekleyip desteklemediğine göre sınıf üretir.

Yaklaşımın avantajı yeni bir veri setinde eğitim maliyeti olmaksızın temel sonuç sağlayabilmesidir. Buna karşılık hipotez şablonu, sınıf açıklamalarının sözcük seçimi ve alan bilgisi eksikliği performansı önemli ölçüde etkiler. Bu nedenle sıfır örnekli sonuçlar, denetimli ince ayarlı modellerle aynı bağlamda ancak farklı maliyet yapısıyla değerlendirilmelidir.

2.6. Veri Setleri ve Etiket Semantiği

Financial PhraseBank, uzmanlar tarafından etiketlenen finans haber cümleleriyle alanın temel veri setlerinden biridir (Malo vd., 2014). FiQA, finansal metinlerde duygu puanı

ve hedef bilgisi sunmaktadır. Twitter Financial News Sentiment gibi kısa metin veri setleri ise piyasa yönüne daha yakın bir etiketleme mantığı taşıyabilir.

Aynı sınıf adlarının farklı veri setlerinde farklı anlamlara sahip olması karşılaştırmaların temel sorunlarından biridir. Bir haber dilsel olarak olumsuz ifadeler içerse bile açık yatırım yönü bulunmadığında neutral olarak etiketlenebilir. Tersine beklentiden daha düşük bir kayıp, yüzeysel olumsuz sözcüklere rağmen olumlu etki taşıyabilir.

2.7. Alan Kayması ve Dış Test

Alan kayması, eğitim ve test dağılımlarının farklılaşmasıdır. Finansal duygu analizinde kaynak kuruluş, dönem, uzunluk, şirket sektörü ve anotasyon politikası alan kaymasına neden olabilir. Rastgele iç test ayrımı, aynı veri setine özgü kalıpların öğrenilmesi nedeniyle gerçek genellemeyi olduğundan yüksek gösterebilir.

Bu tezde S&P 500 haber başlıkları yakın alan dış testi, Reuters anotasyon seti ise daha uzak alan dış testi olarak değerlendirilmiştir. Böylece modelin yalnızca hedef veri setindeki başarısı değil, farklı finansal haber biçimlerine aktarılabilirliği incelenmiştir.

2.8. Literatürün Sentezi ve Araştırma Boşluğu

Literatür finansal alan ön eğitiminin yararını, genel amaçlı Transformer modellerinin güçlü ince ayar performansını ve sıfır örnekli sınıflandırmanın esnekliğini ayrı ayrı ortaya koymaktadır. Bununla birlikte bu üç yaklaşımı aynı deney düzeninde ve birden fazla bağımsız dış testte karşılaştıran çalışmalar sınırlıdır.

Mevcut çalışma, model başarısının veri kaynağı ve etiket semantiğine bağımlılığını merkeze almaktadır. Araştırma boşluğu, en iyi iç test modelinin hangi koşullarda dış test üstünlüğünü koruduğu ve alan odaklı FinBERT'in hangi metin türlerinde yeniden avantaj sağladığı sorularında konumlanmaktadır.

3. YÖNTEM

3.1. Araştırma Tasarımı

Araştırma nicel, deneysel ve karşılaştırmalı bir tasarıma sahiptir. Aynı üç sınıflı duygu sınıflandırma görevi farklı model yaklaşımlarıyla çözülmüş; iç test ve bağımsız dış test veri setlerindeki performanslar karşılaştırılmıştır. İş akışı veri hazırlama, temel model

değerlendirmesi, tanısal deney, sıfır örnekli değerlendirme, denetimli ince ayar ve dış test aşamalarından oluşmaktadır.

Aşama	Notebook	Amaç
Kurulum	00_setup_requirements	Kütüphanelerin ve çalışma ortamının hazırlanması
Reuters veri hazırlama	01a_build_reuters_annotation_dataset	Reuters anotasyon örneklerinin oluşturulması
S&P 500 veri hazırlama	01b_build_sp500_annotation_dataset	Başlıkların ön etiketlenmesi ve dengeli anotasyon seti
FinBERT temel model	02_evaluate_finbert_baseline	Hazır FinBERT performansı ve hata analizi
Tanısal deney	03a_evaluate_unfintuned_models_diagnostic	İnce ayarsız modellerin tanısal değerlendirilmesi
Sıfır örnekli test	03b/03c	BART ve NLI model ailelerinin S&P 500 testi
İnce ayar	04_train_plain_sentiment_models	BERT, DistilBERT ve RoBERTa eğitimi
Dış testler	05/06/07	S&P 500, sentetik ve Reuters değerlendirmeleri

3.2. Veri Setleri

3.2.1. Ana Eğitim ve İç Test Veri Seti

Ana deney veri havuzu Twitter Financial News Sentiment örnekleri ile yardımcı eğitim amacıyla Financial PhraseBank örneklerinden oluşturulmuştur. Nihai test kümesi yalnızca ana Twitter veri setinden katmanlı örnekleme ile ayrılmış ve 2.387 örnek içermiştir. Financial PhraseBank örnekleri temel FinBERT karşılaştırmasında olası eğitim örtüşmesi nedeniyle test kümesine alınmamış, yalnızca eğitim havuzunda kullanılmıştır. Metinlerin küçük harfe dönüştürülmüş normalize sürümleri üzerinden eğitim-test örtüşme kontrolü uygulanmıştır.

3.2.2. S&P 500 Dış Test Seti

S&P 500 şirketlerine ilişkin haber başlıkları hazır FinBERT ile ön etiketlenmiş, daha sonra sınıflar dengelenerek anotasyon batch dosyaları oluşturulmuştur. Dış testte kullanılan geçerli değerlendirme seti 1.060 örnekten oluşmaktadır: 323 negative, 339 neutral ve 398 positive. Etiketleme sürecinde manuel inceleme için ChatGPT destekli açıklama alanları kullanılmış; ancak nihai akademik sürümde insan anotatör sayısı ve bağımsız uyum ölçümü ayrıca raporlanmalıdır.

3.2.3. Sentetik Finansal Haber Seti

Sentetik değerlendirme seti her sınıf için dengeli olacak biçimde toplam 3.000 finansal haber örneğinden oluşmaktadır. Set, açık ve kontrollü duygu sinyalleri içerdiği için

modellerin öğrenilmiş sınıf sınırlarını sınamakta yararlıdır; ancak gerçek haber dilindeki belirsizlik, örtük etki ve editoryal çeşitlilik sınırlıdır.

3.2.4. Reuters Anotasyon Seti

Reuters dış test seti 5.000 finansal haber örneğinden oluşmaktadır. Batch dosyaları farklı kolon ve başlık yapıları için sağlam okuma yordamlarıyla birleştirilmiş; metin, nihai etiket ve destekleyici açıklama alanları standartlaştırılmıştır. Reuters metinleri, ana veri setine kıyasla daha editoryal ve kurumsal bir dil taşıdığından uzak alan genelleme testi olarak ele alınmıştır.

3.3. Modeller

Model	Yaklaşım	Çalışmadaki rol
ProsusAI/FinBERT	Finans alanına özgü ön eğitim ve duygu sınıflandırma başlığı	Hazır temel model
BERT-base-uncased	Genel amaçlı Transformer encoder	Hedef veri setine ince ayarlı model
DistilBERT-base-uncased	Damıtılmış, daha hafif BERT	Verimlilik odaklı ince ayarlı model
RoBERTa-base	Optimize edilmiş BERT ön eğitimi	Güçlü genel amaçlı ince ayarlı model
BART-large-MNLI ve NLI ailesi	Doğal dil çıkarımı	Sıfır örnekli karşılaştırma

3.4. Eğitim Ayarları

İnce ayar deneylerinde dört epoch, 2×10^{-5} öğrenme oranı, 16 eğitim batch boyutu ve 32 değerlendirme batch boyutu kullanılmıştır. Metinler ilgili model tokenizer'ı ile kodlanmış, üç sınıflı sequence classification başlığı uygulanmıştır. Her epoch sonunda doğrulama yapılmış ve model seçimi makro F1 ölçütü üzerinden değerlendirilmiştir. Kesin yeniden üretilebilirlik için rastgele tohum, donanım, maksimum dizi uzunluğu, optimizör ve weight decay değerleri nihai tez sürümünde deney günlüklerinden doğrulanarak eklenmelidir.

3.5. Değerlendirme Ölçütleri

Doğruluk, kesinlik, duyarlılık, F1, makro ortalamalar ve ağırlıklı ortalamalar hesaplanmıştır. Ana ölçüt olarak makro F1 kullanılmıştır; çünkü bu ölçüt her sınıfın F1 değerini eşit ağırlıkla değerlendirir ve çoğunluk sınıfının başarıyı maskeleymesini azaltır.

Doğruluk = doğru tahmin sayısı / toplam örnek sayısıdır. Bir sınıf için kesinlik, o sınıf olarak tahmin edilen örneklerin ne kadarının doğru olduğunu; duyarlılık ise gerçek sınıf

örneklerinin ne kadarının yakalandığını gösterir. F1, kesinlik ve duyarlılığın harmonik ortalamasıdır. Makro F1, sınıf bazlı F1 değerlerinin aritmetik ortalamasıdır.

3.6. Etik ve Geçerlik Konuları

Veri setleri kamuya açık veya araştırma amaçlı kaynaklardan türetilmiştir. S&P 500 ve Reuters setlerinde kullanılan anotasyon yönergeleri Ek C’de özetlenmiştir. Bununla birlikte mevcut proje kayıtlarında anotatör sayısı ve değerlendiriciler arası uyum katsayısı bulunmadığından anotasyon güvenilirliği nicel olarak doğrulanamamıştır. Bu durum çalışmanın geçerlik sınırlılıklarından biridir. Ayrıca eğitim deneyleri tek bir sabit rastgele tohumla yürütüldüğü için model sonuçlarının farklı başlangıçlar altındaki değişkenliği raporlanamamıştır.

4. BULGULAR


4.1. Hazır FinBERT Temel Model Sonuçları

Hazır ProsusAI/FinBERT modeli, 2.387 örnekle nihai iç test kümesinde 0,7323 doğruluk ve 0,6794 makro F1 elde etmiştir. Ağırlıklı F1 değeri 0,7400’dır. Doğruluk ile makro F1 arasındaki fark, sınıf dağılımı ve özellikle tarafsız sınıftaki performans sorununa işaret etmektedir.

Hata analizinde en belirgin örüntü, gerçek etiketi neutral olan çok sayıda örneğin yüksek güvenle negative olarak tahmin edilmesidir. Karışık bilgi içeren, açık piyasa yönü taşımayan veya yalnızca bilgilendirici nitelikteki haberlerde FinBERT olumsuz sözcüklere güçlü ağırlık vermiştir. Bu durum modelin Financial PhraseBank benzeri genel finansal ton mantığı ile hedef veri setinin piyasa yönü odaklı etiket mantığı arasındaki farkla açıklanmıştır.

4.2. İnce Ayarlı Modellerin İç Test Sonuçları

Model	Doğrulama doğruluğu	Doğrulama Macro-F1	Test doğruluğu	Test Macro-F1	Test Weighted-F1
RoBERTa-base	0,8939	0,8718	0,8906	0,8651	0,8918
BERT-base-uncased	0,8820	0,8535	0,8722	0,8378	0,8733
DistilBERT-base-uncased	0,8792	0,8426	0,8583	0,8218	0,8593
Original FinBERT	N/A	N/A	0,7323	0,6794	0,7400



Şekil 1. Modellerin iç test doğruluk sonuçları

İnce ayarlı üç model de hazır FinBERT'i belirgin biçimde geçmiştir. En yüksek sonuç RoBERTa-base modelinde elde edilmiş; RoBERTa'nın FinBERT'e göre makro F1 artışı 0,1857 puan olmuştur. BERT güçlü ikinci sırada yer alırken DistilBERT daha düşük fakat hâlâ FinBERT'ten yüksek performans göstermiştir.

4.3. S&P 500 Dış Test Sonuçları

Model	Doğruluk	Macro-F1	Weighted-F1
RoBERTa-base	0,8132	0,8145	0,8153
Original FinBERT	0,7519	0,7521	0,7513
DistilBERT-base-uncased	0,7519	0,7510	0,7525
BERT-base-uncased	0,7557	0,7549	0,7561

RoBERTa S&P 500 dış testinde de ilk sırayı korumuş ve FinBERT'e göre 0,0624 makro F1 artışı sağlamıştır. Bununla birlikte BERT ve DistilBERT'in iç testte FinBERT'i geniş farkla geçmesine rağmen S&P 500 testinde FinBERT'e çok yakın sonuçlar vermesi, iç test sıralamasının tüm modellere aynı biçimde genellenmediğini göstermektedir.

4.4. Sentetik Veri Sonuçları

Model	Doğruluk	Macro-F1	Weighted-F1
-------	----------	----------	-------------

Model	Doğruluk	Macro-F1	Weighted-F1
RoBERTa-base	0,9957	0,9957	0,9957
BERT-base-uncased	0,9743	0,9742	0,9742
DistilBERT-base-uncased	0,9583	0,9581	0,9581
Original FinBERT	0,9550	0,9551	0,9551


Bütün modeller sentetik veri üzerinde çok yüksek başarı göstermiştir. RoBERTa'nın yaklaşık 0,996 makro F1 elde etmesi, sentetik örneklerde sınıf ipuçlarının açık olduğunu düşündürmektedir. Ancak Reuters ve S&P 500 sonuçlarıyla karşılaştırıldığında, sentetik performansın gerçek dünya genellemesini fazla iyimser tahmin ettiği anlaşılmaktadır.

4.5. Reuters Dış Test Sonuçları

Model	Doğruluk	Macro Precision	Macro Recall	Macro-F1	Weighted-F1
Original FinBERT	0,6966	0,6882	0,7021	0,6866	0,7016
RoBERTa-base	0,6268	0,7464	0,6723	0,6388	0,6486
BERT-base-uncased	0,6034	0,7165	0,6451	0,6131	0,6240
DistilBERT-base-uncased	0,5766	0,6883	0,6201	0,5869	0,5953

Reuters testinde model sıralaması değişmiştir. Hazır FinBERT, 0,6866 makro F1 ile en başarılı model olmuş; RoBERTa 0,6388 değerinde kalmıştır. RoBERTa'nın makro kesinliği yüksek olmasına rağmen daha düşük doğruluk ve F1 elde etmesi, bazı sınıflarda seçici fakat düşük kapsamlı tahmin ürettiğini düşündürmektedir. Bu bulgu, alan odaklı ön eğitimin profesyonel finans haberlerinde yeniden avantaj sağladığını göstermektedir.

4.6. Test Alanları Arası Karşılaştırma



Şekil 2. Modellerin test alanlarına göre Macro-F1 karşılaştırması

Model	İç test	S&P 500	Sentetik	Reuters
FinBERT	0,6794	0,7521	0,9551	0,6866
DistilBERT	0,8218	0,7510	0,9581	0,5869
BERT	0,8378	0,7549	0,9742	0,6131
RoBERTa	0,8651	0,8145	0,9957	0,6388

Sonuçlar tek bir evrensel en iyi model bulunmadığını göstermektedir. RoBERTa ana veri seti ve yakın alan S&P 500 testinde en başarılı modeldir. FinBERT ise Reuters gibi daha geleneksel finans haberi dağılımında üstünlük sağlamıştır. Bu nedenle model seçimi hedef uygulamanın metin türüne göre yapılmalıdır.

4.7. Sıfır Örnekli Deneyler

S&P 500 anotasyon seti üzerinde BART-large-MNLI ile BERT ailesinin NLI sürümleri sıfır örnekli olarak değerlendirilmiştir. En iyi sıfır örnekli sonuç BART-large-MNLI tarafından 0,6594 doğruluk ve 0,5580 makro F1 ile elde edilmiştir. Bununla birlikte BART modelinin tarafsız sınıf F1 değeri yalnızca 0,1199 olarak ölçülmüştür. Diğer NLI modellerinde bu değer daha da düşük kalmıştır. Sonuçlar, etiketli eğitim verisi gerektirmeyen yaklaşımın hızlı bir başlangıç modeli sunduğunu; ancak finansal tarafsızlık tanımını


öğrenmeden denetimli ince ayarlı modellere güçlü bir alternatif oluşturamadığını göstermektedir.

Model	N	Doğruluk	Makro kesinlik	Makro duyarlılık	Makro F1	F1-neg	F1-tar	F1-poz
BART-large-MNLI zero-shot	1060	0.6594	0.7043	0.6479	0.5580	0.8101	0.1199	0.7440
RoBERTa-base NLI zero-shot	1060	0.6085	0.7423	0.5966	0.4913	0.7523	0.0233	0.6982
BERT-base MNLI zero-shot	1060	0.5057	0.3951	0.4930	0.4033	0.5963	0.0058	0.6077
DistilBERT-base MNLI zero-shot	1060	0.4679	0.5502	0.4760	0.3880	0.5663	0.0776	0.5201


Tablo 8. S&P 500 sıfır örnekli model sonuçları

4.8. Karışıklık Matrisleri ve Sınıf Bazlı Hata Örüntüleri


Karışıklık matrisleri, toplam başarı değerlerinin hangi sınıf geçişlerinden kaynaklandığını göstermektedir. İç testte RoBERTa tarafsız sınıfta yüksek doğru tahmin sayısına ulaşırken 67 tarafsız örneği negatif olarak sınıflandırmıştır. S&P 500 dış testinde hazır FinBERT için tarafsızdan negatife hata oranı %10,62 iken bu oran RoBERTa için %5,60, BERT için %4,42 ve DistilBERT için %4,72 düzeyindedir. Buna karşın BERT ve DistilBERT gerçek negatif örnekleri tarafsız olarak sınıflandırmada daha fazla hata yapmış; bu durum makro F1 değerlerinin RoBERTa ve FinBERT'in gerisinde kalmasına katkıda bulunmuştur.




Şekil 3. İç test - RoBERTa karışıklık matrisi




Şekil 4. S&P 500 - FinBERT karışıklık matrisi



Şekil 5. S&P 500 - RoBERTa karışıklık matrisi



Şekil 6. S&P 500 - BERT karışıklık matrisi



Şekil 7. S&P 500 - DistilBERT karışıklık matrisi

5. TARTIŞMA

5.1. Hedef Veri Setine Özgü İnce Ayarın Etkisi

İç test sonuçları, hedef veri setine özgü ince ayarın güçlü etkisini açık biçimde göstermektedir. Üç genel amaçlı modelin tamamı hazır FinBERT'i aşmıştır. Bu sonuç, alan odaklı ön eğitimin tek başına hedef etiket semantiğine uyum için yeterli olmadığını desteklemektedir. FinBERT finansal dili bilmekte; ancak hedef veri setinin karışık veya yönsüz metinleri neutral olarak ele alan karar sınırını aynı ölçüde bilmemektedir.

RoBERTa'nın üstünlüğü, optimize edilmiş ön eğitim prosedürü ve güçlü genel dil temsilinin veri setine özgü ince ayarla birleşmesine bağlanabilir. BERT ile RoBERTa arasındaki fark görece sınırlı olsa da tutarlı biçimde RoBERTa lehinedir. DistilBERT daha

küçük yapısına rağmen FinBERT'i geçerek kaynak kısıtlı uygulamalar için uygulanabilir bir seçenek sunmaktadır.

5.2. Genelleme ve Alan Kayması

S&P 500 sonuçlarında yalnızca RoBERTa'nın FinBERT'i geçmesi, ana veri setine uyum sağlamanın dış test üstünlüğünü garanti etmediğini göstermektedir. BERT ve DistilBERT iç testte yüksek sonuçlar elde etmiş ancak bağımsız başlıklarda FinBERT'in biraz gerisinde kalmıştır. RoBERTa'nın dış testte de ilk sırada yer alması, daha sağlam bir temsil öğrendiğine işaret etmektedir.

Reuters sonuçları ise daha güçlü bir alan kayması örneğidir. Profesyonel ve editoryal Reuters haberleri, FinBERT'in ön eğitim ve görev geçmişine daha yakın olabilir. FinBERT'in burada yeniden birinci olması, finans alanına özgü ön eğitimin uzak alan metinlerinde koruyucu bir etkisi olabileceğini düşündürmektedir. Bu sonuç çalışmanın en önemli bulgusudur: en iyi model veri setinden bağımsız bir özellik değil, model ile hedef dağılım arasındaki uyumun sonucudur.

5.3. Tarafsız Sınıf ve Etiket Uyuşmazlığı

FinBERT hata analizinde neutral örneklerin negative olarak tahmin edilmesi, tarafsız sınıfın homojen olmadığını göstermektedir. Bu sınıf; açık yön içermeyen bilgi, karışık olumlu-olumsuz gelişme, küçük değişim, beklentiye paralel sonuç ve hedef belirsizliği gibi farklı durumları bir araya getirmektedir. Modelin olumsuz sözcüklere verdiği ağırlık, veri setinin piyasa yönü odaklı karar kuralıyla çelişmektedir.

Bu nedenle hata analizi yalnızca model yanlışı olarak sunulmamalıdır. Bazı örneklerde iki etiket de farklı sentiment tanımları altında savunulabilir. Nihai tezde anotasyon yönergesinin açık biçimde verilmesi, belirsiz örneklerin ayrıca işaretlenmesi ve insan değerlendiriciler arası uyumun raporlanması önerilmektedir.

5.4. Sentetik Verinin Yorumu

Sentetik veri üzerindeki 0,95-0,996 aralığındaki makro F1 değerleri ilk bakışta modellerin problemi neredeyse çözdüğünü düşündürebilir. Ancak Reuters sonuçlarındaki belirgin düşüş, bu yorumun geçerli olmadığını göstermektedir. Sentetik örnekler genellikle

tek yönlü ve açık sınıf ipuçları içerir; gerçek haberlerde ise örtük etkiler, karşılaştırmalar, zaman bağlamı ve birden fazla olay bulunur.

Sentetik veri eğitim ve stres testi amacıyla yararlı olmakla birlikte, ana başarı kanıtı olarak kullanılmamalıdır. Sentetik set sonuçları gerçek dışı testlerle birlikte raporlanmalı ve veri üretim yöntemi ayrıntılı biçimde açıklanmalıdır.

5.5. Sıfır Örnekli Yaklaşımların Rolü

Sıfır örnekli modellerin temel avantajı etiketli eğitim verisine ihtiyaç duymamasıdır. Bu özellik yeni pazarlar, diller veya sınıf şemaları için hızlı prototipleme sağlar. Ancak genel NLI modelleri finansal olayların ekonomik etkisini ve veri setine özgü neutral kararını öğrenmemiştir. Bu nedenle denetimli ince ayarlı modellerden düşük performans beklenmektedir.

Sıfır örnekli yaklaşımın değeri, en yüksek performansı elde etmekten çok düşük başlangıç maliyeti sağlamasıdır. Gelecek çalışmalarda finansal açıklama içeren daha ayrıntılı hipotezler, çoklu şablon ortalaması ve az örnekli instruction-tuned modeller denenebilir.

5.6. Araştırma Sorularının Yanıtlanması

Soru	Sonuç
AS1	Evet. İç testte FinBERT 0,6794 makro F1 elde ederken DistilBERT 0,8218, BERT 0,8378 ve RoBERTa 0,8651 değerine ulaşmıştır.
AS2	RoBERTa 0,8651 makro F1 ile birinci, BERT 0,8378 ile ikinci, DistilBERT 0,8218 ile üçüncü olmuştur. RoBERTa ayrıca sınıf bazlı olarak en dengeli iç test profilini vermiştir.
AS3	Hayır. RoBERTa S&P 500 testinde 0,8145 makro F1 ile üstünlüğünü korurken Reuters testinde FinBERT 0,6866 ile birinci olmuş, RoBERTa 0,6388'de kalmıştır.
AS4	En iyi sıfır örnekli model BART-large-MNLI'dir (0,5580 makro F1). Denetimli S&P 500 sonuçlarının belirgin biçimde gerisinde kalmış ve özellikle tarafsız sınıfta başarısız olmuştur (F1=0,1199).
AS5	Etiketleme şeması ve metin kaynağı tarafsız sınıfı doğrudan etkilemiştir. S&P 500'de tarafsızdan negatife hata oranı FinBERT için %10,62, RoBERTa için %5,60'tır.
AS6	Sentetik sette makro F1 değerleri 0,9551-0,9957 aralığındayken Reuters'ta 0,5869-0,6866 aralığına düşmüştür. Sentetik performans gerçek dünya genellemesini fazla iyimser göstermektedir.

5.7. Bulguların Literatürle Karşılaştırılması

Hazır FinBERT'in iç testte hedef veri setine özel ince ayarlı modellerin gerisinde kalması, finans alanına özgü ön eğitimin tek başına görev uyumunu garanti etmediğini göstermektedir. Araci (2019) ile Yang, Uy ve Huang (2020), finansal metinlerde alan odaklı ön eğitimin yararını ortaya koymuştur. Bu tezde Reuters sonuçları söz konusu bulgularla uyumludur; hazır FinBERT profesyonel finans haberlerinde en yüksek makro F1 değerine

ulaşmıştır. Buna karşılık kısa, piyasa yönelimli ana veri setinde RoBERTa'nın üstünlüğü, hedef veri setine özgü ince ayarın bazı görevlerde alan ön eğitiminden daha belirleyici olabileceğine işaret etmektedir.

RoBERTa'nın iç test ve S&P 500 dış testindeki başarısı, Liu ve diğerlerinin (2019) optimize edilmiş ön eğitim sürecinin güçlü aktarım performansı sağladığı yönündeki bulgularıyla tutarlıdır. DistilBERT'in daha düşük olmakla birlikte FinBERT'in iç test sonucunu aşması ise Sanh ve diğerlerinin (2019) daha küçük modellerin önemli ölçüde performans koruyabildiği sonucunu desteklemektedir. BERT ve FinBERT'in görevler arasında değişen sıralaması, Peng ve diğerlerinin (2021) alan uyarlamasının değerinin göreve ve veri dağılımına bağlı olduğu yönündeki değerlendirmesiyle örtüşmektedir.

Tarafsız sınıfın veri setleri arasında farklı anlamlar taşıması, Loughran ve McDonald'ın (2011) finansal söz varlığının genel duygu sözlüklerinden farklı yorumlanması gerektiği yönündeki temel argümanını genişletmektedir. Financial PhraseBank (Malo ve diğerleri, 2014) kurumsal haber cümlelerinin ekonomik etkisini merkeze alırken, bu çalışmanın ana veri seti kısa ve piyasa yönelimli metinleri içermektedir. Bu nedenle tarafsızdan negatife hataların yalnızca model yetersizliği değil, etiket semantiği ve veri kaynağı arasındaki uyumsuzlukla birlikte değerlendirilmesi gerekir. Varlık düzeyli duygu yaklaşımını öneren Tang ve diğerleri (2023) de tek bir cümle etiketinin hedefe bağlı farklı etkileri maskeleyebileceğini göstermektedir.

5.8. Hipotezlerin Değerlendirilmesi

Hipotez	Karar	Gerekece
H1	Desteklendi	Üç ince ayarlı model de iç testte FinBERT'in 0,6794 makro F1 değerini aşmıştır.
H2	Desteklendi	RoBERTa iç testte 0,8651 makro F1 ile BERT ve DistilBERT'in önünde yer almıştır.
H3	Desteklendi	İç testteki model sıralaması Reuters dış testinde değişmiş ve FinBERT birinci olmuştur.
H4	Desteklendi	En iyi sıfır örnekli model 0,5580 makro F1 ile tüm denetimli modellerin gerisinde kalmıştır.
H5	Desteklendi	Sıfır örnekli modellerde tarafsız F1 çok düşük; FinBERT'in S&P 500 tarafsızdan negatife hata oranı %10,62'dir.

6. SONUÇ VE ÖNERİLER

6.1. Genel Sonuç

Bu tez, finansal duygu analizinde alan odaklı ön eğitim, hedef veri setine özgü ince ayar ve sıfır örnekli sınıflandırma yaklaşımlarını çoklu test alanlarında karşılaştırmıştır. Hedef veri setine özgü ince ayar, kısa ve piyasa yönelimli finansal metinlerde genel amaçlı Transformer modellerinin hazır FinBERT'i geçmesini sağlamıştır. Bununla birlikte Reuters gibi farklı dilsel ve editoryal özelliklere sahip dış test verilerinde FinBERT'in yeniden üstünlük göstermesi, finansal duygu analizi performansının yalnızca model mimarisiyle açıklanamayacağını; veri kaynağı, etiket semantiği ve alan kaymasından önemli ölçüde etkilendiğini ortaya koymuştur.

Çalışmanın ana sonucu, finansal duygu analizinde tek bir modelin evrensel olarak en iyi kabul edilemeyeceğidir. Model seçimi; hedef metin türü, etiket politikası, veri kaynağı ve uygulama maliyetiyle birlikte yapılmalıdır. İç test başarısı tek başına üretim ortamı için yeterli kanıt değildir; bağımsız ve mümkünse birden fazla dış test gereklidir.

6.2. Uygulayıcılara Öneriler

- Kısa piyasa başlıkları ve hedef veri setine benzeyen içeriklerde RoBERTa ince ayarı öncelikli aday olarak değerlendirilmelidir.
- Profesyonel finans haberlerinde FinBERT mutlaka ayrı bir temel model olarak test edilmelidir.
- Sınıf dengesizliği bulunan veri setlerinde model seçimi yalnızca doğrulukla yapılmamalı; makro F1 ve sınıf bazlı ölçütler raporlanmalıdır.
- Üretim öncesinde zaman, kaynak ve sektör bazlı dış testler uygulanmalıdır.
- Tarafsız sınıf için açık anotasyon yönergeleri ve belirsiz/mixed kategorisi değerlendirilmelidir.

6.3. Gelecek Çalışmalar

- NOSIBLE veya SENTiVENT gibi yeni bağımsız test setlerinin eklenmesi.
- Varlık ve olay düzeyli finansal duygu analizine geçilmesi.
- Çok dilli ve özellikle Türkçe finansal haber veri setlerinin oluşturulması.
- LLM, instruction tuning ve az örnekli yöntemlerle karşılaştırma yapılması.
- Haber duygu tahminlerinin hisse fiyatı ve volatilité hareketleriyle ilişkilendirilmesi.

- Birden fazla rastgele tohum, güven aralığı ve istatistiksel anlamlılık testlerinin uygulanması.
- Model boyutu, enerji tüketimi, eğitim süresi ve çıkarım gecikmesinin birlikte değerlendirilmesi.

KAYNAKÇA

Araci, D. (2019). FinBERT: Financial sentiment analysis with pre-trained language models. arXiv:1908.10063.

Balakrishnan, S., Fang, Y., & Zhu, X. (2022). Exploring robustness of prefix tuning in noisy data: A case study in financial sentiment analysis. Proceedings of FinNLP 2022.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. Proceedings of NAACL-HLT, 4171–4186.

Dong, Z., Fan, X., & Peng, Z. (2024). FNSPID: A comprehensive financial news dataset in time series. arXiv:2402.06698.

Kirtac, K., & Germano, G. (2024). Enhanced financial sentiment analysis and trading strategy development using large language models. Proceedings of WASSA 2024.

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). RoBERTa: A robustly optimized BERT pretraining approach. arXiv:1907.11692.

Loughran, T., & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. The Journal of Finance, 66(1), 35–65.

Malo, P., Sinha, A., Korhonen, P., Wallenius, J., & Takala, P. (2014). Good debt or bad debt: Detecting semantic orientations in economic texts. Journal of the Association for Information Science and Technology, 65(4), 782–796.

Peng, B., Chersoni, E., Hsu, Y.-Y., & Huang, C.-R. (2021). Is domain adaptation worth your investment? Comparing BERT and FinBERT on financial

tasks. Proceedings of the First Workshop on Economics and Natural Language Processing.

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter. arXiv:1910.01108.

Takala, P., Malo, P., Sinha, A., & Ahlgren, O. (2014). Gold-standard for topic-specific sentiment analysis of economic texts. Proceedings of LREC 2014.

Tang, Y., Yang, Y., Huang, A., Tam, A., & Tang, J. (2023). FinEntity: Entity-level sentiment classification for financial texts. Proceedings of EMNLP 2023.

Yang, Y., Uy, M. C. S., & Huang, A. (2020). FinBERT: A pretrained language model for financial communications. arXiv:2006.08097.

EK A. NİHAİ TESLİM ÖNCESİ TAMAMLANACAK BİLGİLER

- Kapak sayfasındaki üniversite, enstitü, anabilim dalı, öğrenci ve danışman bilgileri.
- Üniversitenin tez yazım kılavuzuna göre kenar boşlukları, kapak ve ön sayfalar.
- Sıfır örnekli deneylerin nihai doğruluk, Macro-F1 ve karışıklık matrisi tabloları.
- S&P 500 BERT ve DistilBERT doğruluk/Weighted-F1 hücrelerinin çıktı CSV'sinden tamamlanması.
- Eğitim donanımı, maksimum dizi uzunluğu, random seed, optimizier ve weight decay ayrıntıları.
- Anotatör sayısı, anotasyon yönergesi ve değerlendiriciler arası uyum ölçütü.
- Kaynakların DOI, cilt, sayı ve sayfa bilgilerinin üniversitenin istediği kaynakça stiline göre doğrulanması.

EK B. DENEY DOSYALARI

Tezde kullanılan deneyler 00_setup_requirements.ipynb ile 09_search_new_dataset.ipynb arasındaki Jupyter Notebook dosyalarında yürütülmüştür. Notebooklar veri hazırlama, temel model değerlendirmesi, sıfır örnekli test, ince ayar ve bağımsız dış test aşamalarını ayrı ayrı belgelemektedir.

EK C. DENEY AYRINTILARI, TOPLU SONUÇLAR VE HATA ANALİZİ

Bu ek, tez danışmanlığı değerlendirmesinde istenen deney ayrıntılarını mevcut proje dosyalarından çıkarılabildiği ölçüde tek yerde toplar. Sayısal değerler proje klasöründeki split, checkpoint, notebook çıktısı ve prediction CSV dosyalarından alınmıştır; kaydı bulunmayan bilgiler açık sınırlılık olarak belirtilmiştir.

C.1. Deney ve Ortam Ayrıntıları

Başlık	Ayrıntı
Ana veri	16.777 örnek; Twitter Financial News Sentiment 11.931, Financial PhraseBank 4.846.
Split	Mevcut split dosyaları: train 12.950, validation 1.432, test 2.386. Toplam ana havuza göre yaklaşık %77,19 / %8,54 / %14,22.
Sınıf dağılımı	Ana havuz: negative 2.393 (%14,26), neutral 10.623 (%63,32), positive 3.761 (%22,42).
Eğitim ayarları	Seed 42; epoch 4; learning rate 2e-5; train batch size 16; eval batch size 32; max length 128; weight decay 0,01; class weights açık.
Model sürümleri	ProsusAI/finbert; bert-base-uncased; distilbert-base-uncased; roberta-base; zero-shot için BART-large-MNLI ve NLI/MNLI model ailesi.
Yazılım/donanım	Python 3.14.2, PyTorch 2.11.0+cpu, Transformers 5.8.1, Datasets 4.5.0, scikit-learn 1.8.0. Notebook çıktılarında CUDA false ve cihaz CPU olarak görünmektedir.
İstatistiksel güvenilirlik	Mevcut çalıştırmalar tek random seed (42) ile yapılmıştır. Çoklu seed ortalama ve standart sapma bu klasörde mevcut değildir; bu nedenle sonuçlar tek çalıştırma olarak raporlanmıştır.

C.2. Veri Seti Büyüklükleri ve Sınıf Dağılımları

Veri seti	N	Negative	Neutral	Positive
Ana havuz	16.777	2.393	10.623	3.761
Train	12.950	1.820	8.137	2.993
Validation	1.432	215	929	288
Test	2.386	358	1.549	479
S&P 500 dış test	1.060	323	339	398
Sentetik test	3.000	1.000	1.000	1.000
Reuters dış test	5.000	1.579	1.146	2.275

C.3. Tek Sonuç Tablosu

Tabloda P-makro ve R-makro sırasıyla makro precision ve makro recall değerlerini gösterir. Internal testte Original FinBERT satırı notebook çıktısından alınmış ve n=2.387 olarak raporlanmıştır; güncel split dosyasında test satır sayısı 2.386'dır.

Veri	Model	N	Acc	P-makro	R-makro	F1-makro	F1-neg	F1-neu	F1-pos
Internal Twitter test	RoBERTa-base	2386	0.8906	0.8511	0.8814	0.8651	0.8329	0.9210	0.8415
Internal Twitter test	BERT-base-uncased	2386	0.8722	0.8280	0.8487	0.8378	0.7699	0.9092	0.8344
Internal Twitter test	DistilBERT-base-uncased	2386	0.8583	0.8136	0.8308	0.8218	0.7633	0.8989	0.8032
Internal Twitter test	Original FinBERT	2387	0.7323	0.6648	0.7154	0.6794	0.6044	0.8060	0.6279
S&P 500 external test	RoBERTa-base	1060	0.8132	0.8249	0.8138	0.8145	0.8331	0.7768	0.8338
S&P 500 external test	BERT-base-uncased	1060	0.7557	0.7714	0.7554	0.7549	0.7448	0.7458	0.7741
S&P 500 external test	Original FinBERT	1060	0.7519	0.7531	0.7567	0.7521	0.7663	0.7482	0.7418
S&P 500 external test	DistilBERT-base-uncased	1060	0.7519	0.7669	0.7510	0.7510	0.7392	0.7378	0.7759
Synthetic financial news	RoBERTa-base	3000	0.9957	0.9957	0.9957	0.9957	0.9945	0.9970	0.9955
Synthetic financial news	BERT-base-uncased	3000	0.9743	0.9748	0.9743	0.9742	0.9646	0.9779	0.9802
Synthetic financial news	DistilBERT-base-uncased	3000	0.9583	0.9591	0.9583	0.9581	0.9450	0.9710	0.9582

Veri	Model	N	Acc	P-makro	R-makro	F1-makro	F1-neg	F1-neu	F1-pos
Synthetic financial news	Original FinBERT	3000	0.9550	0.9568	0.9550	0.9551	0.9373	0.9578	0.9701
Reuters external test	Original FinBERT	5000	0.6966	0.6882	0.7021	0.6866	0.7483	0.5820	0.7295
Reuters external test	RoBERTa-base	5000	0.6268	0.7464	0.6723	0.6388	0.7269	0.5412	0.6484
Reuters external test	BERT-base-uncased	5000	0.6034	0.7165	0.6451	0.6131	0.6790	0.5245	0.6359
Reuters external test	DistilBERT-base-uncased	5000	0.5766	0.6883	0.6201	0.5869	0.6588	0.5052	0.5966
S&P 500 zero-shot	BART-large-MNLI zero-shot	1060	0.6594	0.7043	0.6479	0.5580	0.8101	0.1199	0.7440
S&P 500 zero-shot	RoBERTa-base NLI zero-shot	1060	0.6085	0.7423	0.5966	0.4913	0.7523	0.0233	0.6982
S&P 500 zero-shot	BERT-base MNLI zero-shot	1060	0.5057	0.3951	0.4930	0.4033	0.5963	0.0058	0.6077
S&P 500 zero-shot	DistilBERT-base MNLI zero-shot	1060	0.4679	0.5502	0.4760	0.3880	0.5663	0.0776	0.5201

C.4. Anotasyon Yöntemi ve Sınırlılık

S&P 500 setinde haber başlıkları önce FinBERT ile etiketlenmiş, ardından dengeli anotasyon batchleri hazırlanmıştır. Batch yapısında final_label, ChatGPT destekli açıklama, güven ve not alanları bulunmaktadır. Reuters seti 5.000 örnek olarak hazırlanmış; final_label alanı değerlendirme etiketi olarak kullanılmıştır. Kullanılan yönerge özetle positive için yatırımcı açısından olumlu beklenti/gerçekleşme, negative için olumsuz beklenti/risk/kayıp, neutral için olgusal veya yönü belirsiz haber tanımlarını kullanır. Birden fazla hedefte çatışan sentiment varsa target_entity doldurulması veya plain sentiment için örneğin ayrılması önerilmiştir.

Mevcut dosyalarda kaç insan anotatörün görev aldığı ve anotatörler arası uyumun Cohen kappa veya Krippendorff alpha gibi bir ölçütle hesaplandığına ilişkin tamamlanmış kayıt bulunmamaktadır. Bu nedenle çalışma, anotasyon güvenilirliğini ölçülmüş bir bulgu olarak değil, sınırlılık ve gelecek çalışma gereksinimi olarak raporlamalıdır.

C.5. Confusion Matrix ve Hata Analizi

Model/test	Neutral -> negative	Oran
Internal RoBERTa	67 / 1.549	0,0433
Internal BERT	84 / 1.549	0,0542
Internal DistilBERT	82 / 1.549	0,0529
S&P 500 Original FinBERT	36 / 339	0,1062
S&P 500 RoBERTa	19 / 339	0,0560
S&P 500 BERT	15 / 339	0,0442
S&P 500 DistilBERT	16 / 339	0,0472

Örnek hata başlıkları özellikle karışık sinyal taşıyan veya piyasa yönü açık olmayan haberlerde yoğunlaşmaktadır: 'S&P 500 Gains and Losses Today: NetApp and GM Rise; Hormel and Las Vegas Sands Fall' hem yükselen hem düşen hisseleri içerdiği için neutral kabul edilmiştir, ancak FinBERT negative tahmin etmiştir. 'Strong corporate earnings are helping the US avoid a recession - but there are 2 big risks facing markets...' olumlu ve riskli

unsurları birlikte taşıdığı için neutral/karışık kabul edilmiştir. 'AP Explains: What resignation of New Zealand's leader means' ise finansal yön içermeyen siyasi/açıklayıcı bir başlık olmasına rağmen negative tahmin edilmiştir.

C.6. Zero-Shot ve Sentetik Veri Yorumu

Zero-shot deneyleri tamamlanmış ve tek sonuç tablosuna eklenmiştir. BART-large-MNLI S&P 500 üzerinde 0,6594 doğruluk ve 0,5580 makro F1 elde ederek zero-shot modeller içinde en iyi sonucu vermiştir. Buna rağmen neutral sınıf F1'i 0,1199 düzeyinde kalmıştır; RoBERTa-base NLI, BERT-base MNLI ve DistilBERT-base MNLI sürümlerinde neutral F1 daha da düşüktür. Bu bulgu, NLI tabanlı zero-shot yaklaşımın finansal neutral tanımını öğrenmeden güçlü bir alternatif olamadığını göstermektedir.

Sentetik veri sonuçları da tabloya eklenmiştir. Tüm modeller sentetik sette 0,9551 ile 0,9957 arasında makro F1 üretmiştir. Bu yüksek değerler, sentetik örneklerde duygu ipuçlarının açık olmasından kaynaklanabilir; bu nedenle sentetik test gerçek Reuters ve S&P 500 dış testlerinin yerine geçmemeli, yalnızca kontrollü bir stres testi olarak yorumlanmalıdır.