

FİNANSAL DUYGU ANALİZİ – HIZLI NOTLAR

Tezin tek cümlelik ana fikri

Hedef veri setine özgü ince ayar, kısa/piyasa yönelimli finansal metinlerde hazır FinBERT'i geçebilir; ancak Reuters gibi farklı kaynaklarda FinBERT yeniden üstün olabilir. Dolayısıyla başarı; model mimarisinin yanında veri kaynağı, etiket semantiği ve alan kaymasına bağlıdır.

1. Giriş

- Problem: Finansal metinlerde positive / neutral / negative sınıfları veri setleri arasında aynı anlamı taşımayabilir.
- Amaç: Hazır FinBERT ile hedef veri setine ince ayarlı BERT, DistilBERT ve RoBERTa'yı; iç test ve farklı dış testlerde karşılaştırmak.
- Ana katkı: İç test başarısının farklı kaynaklara genellenip genellenmediğini göstermek ve neutral sınıf hatalarını etiket semantiği açısından incelemek.
- Zero-shot deneyleri ana araştırma eksenini değil; tamamlayıcı/keşifsel analizdir.
- Sınırlılıklar: tek random seed; anotatörler arası uyum katsayısı yok; Reuters/S&P500 anotasyonlarında model destekli süreç; sentetik veri gerçek dağılımı tam temsil etmiyor.

Araştırma soruları – çok kısa cevaplar

- AS1: Fine-tuning FinBERT'i geçiyor mu? → İç testte evet; üç ince ayarlı model de geçti.
- AS2: İnce ayarlı modellerin sırası? → RoBERTa > BERT > DistilBERT.
- AS3: İç testte birinci olan her dış testte de birinci mi? → Hayır; Reuters'ta FinBERT birinci.
- AS4: Veri kaynağı/etiket şeması özellikle neutral sınıfı etkiliyor mu? → Evet; hata örüntüleri kaynaklara göre değişiyor.
- AS5: Sentetik başarı gerçek dünyayı temsil ediyor mu? → Tam olarak hayır; sentetik sonuçlar belirgin biçimde daha yüksek.

2. Kuramsal çerçeve / literatür

- BERT: bağlamsal temsil; genel amaçlı ön eğitim.
- FinBERT: finans diline alan uyarlaması; fakat hedef veri setinin etiket politikasını otomatik olarak öğrenmez.
- RoBERTa: optimize edilmiş BERT ön eğitim yaklaşımı; bu tezde en güçlü iç test modeli.
- DistilBERT: daha hafif BERT; performans/verimlilik dengesi.
- Alan kayması: eğitim ve test dağılımlarının kaynak, dönem, metin türü veya etiketleme açısından farklılaşması.
- Araştırma boşluğu: alan-özel ön eğitim ile hedef veri setine özel ince ayarın, birden fazla dış testte birlikte karşılaştırılması.

3. Yöntem

- Ana görev: 3 sınıflı finansal sentiment sınıflandırması.
- İç test: 2.386/2.387 civarı örnek; proje çıktılarında FinBERT satırı 2.387, güncel split 2.386 olarak kayıtlı.
- S&P 500 dış test: N=1.060 → 323 negative, 339 neutral, 398 positive.
- Sentetik test: N=3.000 → sınıf başına 1.000.
- Reuters dış test: N=5.000 → 1.579 negative, 1.146 neutral, 2.275 positive.
- Ana metrik: Macro-F1; sınıflara eşit ağırlık verdiği için dengesiz veri üzerinde ana kıyas ölçütü.
- Eğitim: 4 epoch, learning rate 2×10^{-5} , train batch 16, eval batch 32; tek seed=42.

4. Bulgular – ezberlenmesi gereken ana rakamlar

- İç test: RoBERTa Acc 0,8906 / Macro-F1 0,8651; BERT 0,8722 / 0,8378; DistilBERT 0,8583 / 0,8218; FinBERT 0,7323 / 0,6794.
- S&P 500: RoBERTa Acc 0,8132 / Macro-F1 0,8145; BERT 0,7557 / 0,7549; FinBERT 0,7519 / 0,7521; DistilBERT 0,7519 / 0,7510.
- Reuters: FinBERT 0,6966 / Macro-F1 0,6866; RoBERTa 0,6268 / 0,6388; BERT 0,6034 / 0,6131; DistilBERT 0,5766 / 0,5869.
- Sentetik: RoBERTa Macro-F1 0,9957; BERT 0,9742; DistilBERT 0,9581; FinBERT 0,9551.
- Zero-shot tamamlayıcı sonuç: BART-large-MNLI Acc 0,6594 / Macro-F1 0,5580; neutral F1 yalnızca 0,1199.

Karışıklık matrisi / hata analizi

- İç test RoBERTa: neutral→negative 67 / 1549 = %4,33.
- S&P 500 FinBERT: 36 / 339 = %10,62.

- S&P 500 RoBERTa: 19 / 339 = %5,60.
- S&P 500 BERT: 15 / 339 = %4,42.
- S&P 500 DistilBERT: 16 / 339 = %4,72.
- Yorum: FinBERT'in finansal olumsuz tonu yakalaması, hedef veri setinin 'piyasa yönü yoksa neutral' karar sınırıyla bazen çatışıyor.

5. Tartışma

- Fine-tuning güçlü: iç testte genel amaçlı modeller FinBERT'i geçti.
- Ama genelleme otomatik değil: Reuters'ta model sıralaması değişti ve FinBERT birinci oldu.
- Bu yüzden 'RoBERTa her yerde en iyi' denmiyor; 'en iyi model hedef dağılıma bağlı' deniyor.
- Neutral sınıf, veri setleri arasındaki etiket semantiği farkının en görünür olduğu sınıf.
- Sentetik test yüksek skor veriyor ama gerçek dünya genellemesini fazla iyimser gösterebilir.
- Zero-shot, etiketli veri yokken başlangıç ölçütü; tezde ana alternatif olarak sunulmuyor.

6. Sonuç – 20 saniyelik cevap

Çalışmanın ana sonucu; finansal alan ön eğitiminin tek başına yeterli olmadığı, hedef veri setine özel ince ayarın yakın dağılımlarda çok güçlü olduğu, ancak kaynak/etiket semantiği değiştiğinde FinBERT gibi alan-özel modellerin yeniden avantaj sağlayabildiğidir. Bu nedenle model seçimi yalnızca iç test skoruna göre yapılmamalıdır.

metrik/kısaltmalar

- Acc = Accuracy (doğruluk).
- P-makro = Her sınıfın precision değerinin eşit ağırlıklı ortalaması.
- R-makro = Her sınıfın recall değerinin eşit ağırlıklı ortalaması.
- Macro-F1 = Her sınıfın F1 skorunun eşit ağırlıklı ortalaması.
- Weighted-F1 = Sınıf F1'lerinin sınıf örnek sayısına göre ağırlıklı ortalaması; çoğunluk sınıfının etkisi daha fazladır.
- F1-neg / F1-neu / F1-pos = negative / neutral / positive sınıfına ait ayrı F1 skorları.
- N = değerlendirmeye giren örnek sayısı.
- N/A = o metrik uygulanmadı/hesaplanmadı. FinBERT validation metriği yok; çünkü hedef veri setinde yeniden eğitilmedi.
- NLI = Natural Language Inference; metin ile hipotez arasındaki entailment/contradiction/neutral ilişkisini öğrenen görev.
- MNLI = Multi-Genre NLI; farklı metin türlerinden oluşturulmuş NLI eğitim veri seti.
- Neutral→negative oranı = gerçek neutral olup negative tahmin edilen örnek sayısı / toplam gerçek neutral sayısı.

Son savunma cümlesi

Tez 'tek bir model en iyidir' iddiası kurmuyor. Asıl iddia, finansal sentiment performansının model + hedef veri dağılımı + etiket semantiği etkileşimine bağlı olduğudur.