

İZMİR KATİP ÇELEBİ ÜNİVERSİTESİ

FEN BİLİMLERİ ENSTİTÜSÜ

FİNANSAL DUYGU ANALİZİNDE MODEL GENELLEMESİ: FİNBERT VE
İNCE AYARLI TRANSFORMER MODELLERİNİN KARŞILAŞTIRMALI
İNCELENMESİ

YÜKSEK LİSANS TEZİ

SERKAN KAYMAK

YAZILIM MÜHENDİSLİĞİ ANABİLİM DALI

Danışman: Dr. Öğr. Üyesi Mansur Alp TOÇOĞLU

2026

ÖZET

Bu tez çalışmasında finansal metinlerin olumlu, tarafsız ve olumsuz olarak sınıflandırılması problemi; finans alanına özgü hazır FinBERT, aynı FinBERT modelinin hedef veri setine ince ayarlanmış sürümü ve hedef veri setine özel olarak ince ayarlanan BERT, DistilBERT ve RoBERTa modelleri üzerinden karşılaştırmalı olarak incelenmiştir. Temel amaç, alan-özü ön eğitim ile hedef veri setine özgü ince ayarın sınıflandırma performansı, yeniden üretilebilirlik ve farklı finansal metin kaynaklarına genelleme üzerindeki etkisini birlikte değerlendirmektir.

Ana veri havuzu 16.777 örnekten oluşmuş; mevcut splitlerde 12.950 eğitim, 1.432 doğrulama ve 2.386 test örneği kullanılmıştır. BERT-base-uncased, DistilBERT-base-uncased, RoBERTa-base ve ProsusAI/FinBERT hedef veri setinde aynı temel eğitim ayarlarıyla ince ayarlanmış; tekrar edilebilirliği değerlendirmek için 42, 123 ve 2024 tohumları kullanılmıştır. Orijinal FinBERT, BERT, DistilBERT, RoBERTa ve hedefe ince ayarlı FinBERT; S&P 500, sentetik finansal haber ve Reuters dış testlerinde değerlendirilmiştir. NLI tabanlı sıfır örnekli modeller tamamlayıcı/keşifsel bir deney olarak tutulmuştur. Ana ölçüt Macro-F1 olup; çoklu tohum ortalama ve standart sapmaları, McNemar testi, Holm düzeltmesi, 5.000 tekrarlı eşleştirilmiş bootstrap güven aralıkları, RoBERTa kaynak-bileşimi ablasyonu, sınıf bazlı hata analizi ve CPU çıkarım verimliliği de raporlanmıştır.

İç testte RoBERTa-base 0,8651 Macro-F1 ile ilk sırada yer alırken hedef veri setine ince ayarlı FinBERT 0,8512 değerine ulaşmış ve hazır FinBERT'in 0,6794 sonucuna göre büyük bir artış göstermiştir. Üç tohum ortalamasında RoBERTa $0,8728 \pm 0,0068$ Macro-F1 ile birinci; fine-tuned FinBERT $0,8480 \pm 0,0028$, BERT $0,8396 \pm 0,0023$ ve DistilBERT $0,8231 \pm 0,0028$ ile onu izlemiştir. Fine-tuned FinBERT dış testte S&P 500 üzerinde 0,7723, sentetik sette 0,9746 ve Reuters'ta 0,6101 Macro-F1 elde etmiştir. S&P 500'de RoBERTa 0,8145 ile en yüksek sonucu verirken Reuters'ta hazır FinBERT 0,6866 ile yeniden ilk sıraya çıkmıştır. RoBERTa kaynak-ablasyonunda Twitter-only eğitim iç testte 0,8810 Macro-F1 ile Twitter + Financial PhraseBank koşulunun 0,8679 sonucunu aşmıştır. Bulgular, hedefe özgü ince ayarın güçlü etkisini doğrularken alan-özel ön eğitimin veya daha fazla heterojen eğitim

verisinin tek başına evrensel üstünlük sağlamadığını; veri kaynağı, etiket semantiği ve kaynak bileşiminin model sıralamasını değiştirebildiğini göstermektedir.

Anahtar Kelimeler: finansal duygu analizi, FinBERT, BERT, RoBERTa, DistilBERT, ince ayar, model genellemesi, alan kayması, Transformer

ABSTRACT

This thesis comparatively investigates financial sentiment classification using the off-the-shelf finance-domain FinBERT model, a target-dataset-fine-tuned version of FinBERT, and target-dataset-fine-tuned BERT, DistilBERT, and RoBERTa models. The main objective is to jointly examine the effects of domain-specific pretraining and target-dataset fine-tuning on classification performance, reproducibility, and generalization across different financial text sources.

The main pool contained 16,777 examples, with 12,950 training, 1,432 validation, and 2,386 test examples in the saved splits. BERT-base-uncased, DistilBERT-base-uncased, RoBERTa-base, and ProsusAI/FinBERT were fine-tuned under the same core training regime and repeated with seeds 42, 123, and 2024. The original FinBERT, BERT, DistilBERT, RoBERTa, and target-fine-tuned FinBERT were evaluated on S&P 500, synthetic financial news, and Reuters external sets. NLI-based zero-shot models were retained as a supplementary exploratory analysis. Macro-F1 was the primary metric; multi-seed mean and standard deviation, McNemar tests, Holm correction, 5,000-repetition paired bootstrap confidence intervals, a RoBERTa source-composition ablation, class-level error analysis, and CPU inference efficiency were additionally reported.

RoBERTa-base achieved 0.8651 macro-F1 on the seed-42 internal test, while target-fine-tuned FinBERT reached 0.8512, substantially improving over the off-the-shelf FinBERT result of 0.6794. Across three seeds, RoBERTa achieved 0.8728 ± 0.0068 macro-F1, followed by fine-tuned FinBERT (0.8480 ± 0.0028), BERT (0.8396 ± 0.0023), and DistilBERT (0.8231 ± 0.0028). Fine-tuned FinBERT obtained 0.7723 on S&P 500, 0.9746 on the synthetic set, and 0.6101 on Reuters. RoBERTa remained best on S&P 500 (0.8145), whereas the original FinBERT ranked first on Reuters (0.6866). In the RoBERTa source ablation, Twitter-only training achieved 0.8810 internal macro-F1, exceeding the Twitter + Financial PhraseBank condition (0.8679). Overall, the findings show that task-specific fine-

tuning is highly influential, but neither domain-specific pretraining nor simply adding heterogeneous labeled data guarantees universal superiority across sources.

Keywords: financial sentiment analysis, FinBERT, BERT, RoBERTa, DistilBERT, fine-tuning, model generalization, domain shift

İÇİNDEKİLER

1. GİRİŞ	6
1.1. Problem Durumu	6
1.2. Araştırmanın Amacı	6
1.3. Araştırma Soruları ve Hipotezler	7
1.4. Araştırmanın Katkıları	7
1.5. Sınırlılıklar	8
2. KURAMSAL ÇERÇEVE VE LİTERATÜR	8
2.1. Finansal Duygu Analizi	8
2.2. Transformer ve BERT	9
2.3. FinBERT ve Alan Odaklı Ön Eğitim	9
2.4. RoBERTa ve DistilBERT	10
2.5. Tamamlayıcı Yaklaşım Olarak Sıfır Örnekli Sınıflandırma	10
2.6. Veri Setleri ve Etiket Semantiği	11
2.7. Alan Kayması ve Dış Test	11
2.8. Literatürün Sentezi ve Araştırma Boşluğu	11
3. YÖNTEM	12
3.1. Araştırma Tasarımı	12
3.2. Veri Setleri	13
3.3. Modeller	14
3.4. Eğitim Ayarları	14
3.5. Değerlendirme Ölçütleri	15
3.6. Etik ve Geçerlik Konuları	15
4. BULGULAR	16
4.1. Hazır FinBERT Temel Model Sonuçları	16
4.2. İnce Ayarlı Modellerin İç Test Sonuçları	16
4.3. S&P 500 Dış Test Sonuçları	17
4.4. Sentetik Veri Sonuçları	18
4.5. Reuters Dış Test Sonuçları	18
4.6. Test Alanları Arası Karşılaştırma	19
4.7. Tamamlayıcı/Keşifsel Analiz: Sıfır Örnekli NLI Modelleri	20
4.8. Karışıklık Matrisleri ve Sınıf Bazlı Hata Örüntüleri	20
4.9. Çoklu Tohum Sonuçları ve Yeniden Üretilbilirlik	25
4.10. İstatistiksel Anlamlılık ve Güven Aralıkları	26
4.11. Model Verimliliği	27
4.12. Fine-Tuned FinBERT Hata Örüntüleri	27
4.13. RoBERTa Kaynak-Bileşimi Ablasyonu	28
5. TARTIŞMA	29
5.1. Hedef Veri Setine Özgü İnce Ayarın Etkisi	29
5.2. Genelleme ve Alan Kayması	29
5.3. Tarafsız Sınıf ve Etiket Uyuşmazlığı	30
5.4. Sentetik Verinin Yorumu	30
5.5. Sıfır Örnekli Modellerden Elde Edilen Tamamlayıcı Bulgular	31
5.6. Araştırma Sorularının Yanıtlanması	31
5.7. Bulguların Literatürle Karşılaştırılması	32
5.8. Hipotezlerin Değerlendirilmesi	33
6. SONUÇ VE ÖNERİLER	33
6.1. Genel Sonuç	33
6.2. Uygulayıcılara Öneriler	34
6.3. Gelecek Çalışmalar	34
KAYNAKÇA	35
EK A. DENEY DOSYALARI	36
EK B. DENEY AYRINTILARI, TOPLU SONUÇLAR VE HATA ANALİZİ	37

1. GİRİŞ

1.1. Problem Durumu

Finansal piyasalar; şirket açıklamaları, haber akışları, analist raporları, merkez bankası duyuruları ve sosyal medya mesajları gibi yoğun bir metinsel bilgi üretmektedir. Bu içeriklerin elle incelenmesi, veri hacmi ve hız nedeniyle sürdürülebilir değildir. Doğal dil işleme yöntemleri, finansal metinlerden sistematik bilgi çıkarılmasını ve metinde ifade edilen ekonomik etkinin otomatik biçimde sınıflandırılmasını mümkün kılmaktadır.

Finansal duygu analizi genel amaçlı duygu analizinden daha karmaşıktır. Finans dilinde olumsuz görünen bir sözcük, bağlama göre olumlu bir piyasa sinyali taşıyabilir; aynı cümlede gelir artışı ile maliyet artışı gibi zıt yönlü bilgiler birlikte bulunabilir. Ayrıca bazı veri setleri dilsel tonu, bazıları hedef şirket üzerindeki ekonomik etkiyi, bazıları ise yükseliş-düşüş beklentisini etiketlemektedir. Bu nedenle aynı positive, neutral ve negative sınıf adları altında farklı karar kuralları yer alabilmektedir.

BERT tabanlı modeller, bağlamsal dil temsilleri sayesinde finansal duygu analizinde geleneksel sözcük sayımı ve özellik mühendisliği yaklaşımlarına göre önemli avantajlar sağlamıştır. FinBERT gibi finans alanına uyarlanmış modeller, alan terminolojisini öğrenerek güçlü bir başlangıç noktası sunmaktadır. Bununla birlikte alan ön eğitimi, hedef veri setinin kendine özgü etiket politikasını otomatik olarak öğrenmez. Bu çalışma, söz konusu ayrımı deneysel olarak incelemektedir.

1.2. Araştırmanın Amacı

Araştırmanın temel amacı, finansal duygu sınıflandırmasında hazır FinBERT modeli, aynı modelin hedef veri setine ince ayarlanmış sürümü ve hedef veri setine özel ince ayarlanmış BERT, DistilBERT ve RoBERTa modellerinin performanslarını karşılaştırmak; sonuçların farklı tohumlarda ne ölçüde tekrarlandığını ve farklı finansal metin kaynaklarına ne ölçüde genellendiğini incelemektir. Çalışma ayrıca örnek-bazlı istatistiksel karşılaştırmalar ve CPU çıkarım verimliliğiyle performans-maliyet dengesini değerlendirmektedir.

- Hazır FinBERT modelinin hedef veri setindeki temel performansını belirlemek ve aynı FinBERT modelinin hedef veri setine ince ayarlandığında sağladığı kazanımı ölçmek.

- BERT-base, DistilBERT-base, RoBERTa-base ve FinBERT modellerini aynı temel eğitim düzeninde ince ayarlamak ve 42, 123 ve 2024 tohumlarında performans kararlılığını incelemek.
- Orijinal FinBERT ile ince ayarlı genel amaçlı modelleri bağımsız S&P 500, sentetik finans haberleri ve Reuters test setlerinde karşılaştırmak.
- İç testteki model sıralamasının çoklu tohumlarda ve farklı dış test kaynaklarında korunup korunmadığını incelemek.
- Özellikle tarafsız sınıftaki hata geçişlerini, istatistiksel anlamlılığı ve model verimliliğini birlikte analiz etmek.

1.3. Araştırma Soruları ve Hipotezler

Kod	Araştırma sorusu
AS1	Hedef veri setine özgü ince ayar, hazır FinBERT kullanımına göre performansı artırmakta mıdır ve FinBERT'in kendisi hedef veri setine ince ayarlandığında sonuç nasıl değişmektedir?
AS2	BERT, DistilBERT, RoBERTa ve fine-tuned FinBERT'in iç test performansları üç farklı random seed altında nasıl farklılaşmaktadır?
AS3	İç testte en başarılı olan genel amaçlı model, bağımsız S&P 500 ve Reuters dış testlerinde de üstünlüğünü korumakta mıdır?
AS4	Veri kaynağı ve etiket semantiği, özellikle neutral sınıfındaki hata örüntülerini nasıl etkilemektedir?
AS5	Sentetik finansal metinlerde elde edilen yüksek performans gerçek finans haberlerindeki genellemeyi ne ölçüde temsil etmektedir?

Hipotezler; hedef veri setine özgü ince ayarın hazır FinBERT'e göre belirgin performans artışı sağlayacağı, RoBERTa'nın çoklu tohum ortalamasında en yüksek iç test performansını koruyacağı, model sıralamasının alan kayması nedeniyle tüm dış testlerde korunmayacağı, tarafsız sınıf hata örüntülerinin kaynak ve modele göre değişeceği ve sentetik veri performansının gerçek dış test başarısını olduğundan iyimser göstereceği yönünde kurulmuştur.

1.4. Araştırmanın Katkıları

- Alan odaklı ön eğitim ile hedef veri setine özgü ince ayarı yalnızca hazır FinBERT üzerinden değil, FinBERT'in kendisini de hedef veri setine ince ayarlayarak daha dengeli bir deneysel çerçevede karşılaştırması.
- İç test, yakın alan dış testi ve uzak alan dış testini birlikte değerlendirmesi; iç testte ayrıca üç farklı random seed ile yeniden üretilebilirliği ölçmesi.
- RoBERTa ile diğer ince ayarlı modeller arasındaki farkları McNemar testi, Holm düzeltmesi ve eşleştirilmiş bootstrap güven aralıklarıyla örnek-bazlı olarak sınaması.

- Etiket semantiği uyumsuzluğunu yalnızca model hatası olarak değil veri seti tasarımı problemi olarak tartışması; fine-tuned FinBERT için hata geçişlerini nicel olarak incelemesi ve RoBERTa üzerinde Twitter-only ile Twitter + Financial PhraseBank koşullarını karşılaştıran kaynak-bileşimi ablasyonu ile heterojen yardımcı verinin etkisini doğrudan sınaması.
- Başarı ölçütlerinin yanında parametre sayısı, CPU örnek/saniye ve örnek başına gecikme ile performans-verimlilik dengesini raporlaması.

1.5. Sınırlılıklar

Çalışma İngilizce finansal metinlerle ve üç sınıflı düz duygu şemasıyla sınırlıdır. Reuters anotasyonlarında insan değerlendirmesini desteklemek üzere model yardımı kullanılmış olması ve anotatörler arası bağımsız bir uyum katsayısının bulunmaması anotasyon geçerliği açısından sınırlılıktır. Hazır FinBERT baseline'ı tarihsel notebook akışında 2.387 örnekle bir test bölümü üzerinde değerlendirilmişken güncel kaydedilmiş split 2.386 örnektir; bu tek örneklik fark doğrudan karşılaştırmalarda not edilmiştir. Kaynak-ablasyonu seed 42 ile sınırlıdır ve çoklu seed tekrarı yapılmamıştır. Ablasyonun S&P 500 çıktısı 1.030 örnek kullanırken doğrulanmış ana S&P dış test seti 1.060 örnektir; bu nedenle ablasyon S&P sonuçları yalnız aynı 1.030 örnekteki iki eğitim koşulunun karşılaştırması için kullanılmıştır. Dış eşleştirilmiş testlerde S&P RoBERTa prediction girdisinin yanlış dosyayla eşleştiği tespit edilmiş, Reuters RoBERTa prediction girdisi ise mevcut olmamıştır; bu çiftler istatistiksel sonuca dahil edilmemiştir. Manuel hata kategorileri için 50 örneklik inceleme şablonu hazırlanmış olmakla birlikte tamamlanmış bağımsız insan kodlaması bulunmadığından nitel kategori oranları raporlanmamıştır. CPU verimlilik ölçümleri tek donanım ortamına özgüdür ve mutlak hız değerleri farklı sistemlerde değişebilir.

2. KURAMSAL ÇERÇEVE VE LİTERATÜR

2.1. Finansal Duygu Analizi

Duygu analizi, metinde ifade edilen değerlendirme veya yönelimin belirlenmesini amaçlar. Finans alanında amaç yalnızca yazarın duygusal tonunu tespit etmek değildir; haberin bir şirket, varlık veya piyasa üzerindeki olası etkisini sınıflandırmak da önemlidir. Bu nedenle finansal duygu analizi, genel ürün yorumu analizinden farklı bir hedef semantiğine sahiptir.

Erken dönem arařtırmalar finansal sözlükler, n-gramlar, destek vektör makineleri ve lojistik regresyon üzerinde yoğunlařmıřtır. Loughran ve McDonald tarafından geliştirilen finans sözlüğü, genel sözlüklerde olumsuz kabul edilen birçok kelimenin finansal raporlarda farklı işlevlere sahip olduğunu göstermiştir. Bununla birlikte sözlük yaklaşımları sözcük sırası, olumsuzlama, hedef varlık ve karışık bilgi gibi bağlamsal unsurları sınırlı biçimde temsil etmektedir.

2.2. Transformer ve BERT

Transformer mimarisi, tekrarlayan ağılara ihtiyaç duymadan öz-dikkat mekanizmasıyla uzun bağlam ilişkilerini modellemektedir. Devlin ve arkadaşlarının geliřtirdiğı BERT, maskeli dil modelleme yoluyla çift yönlü bağlamsal temsiller öğrenmiş ve sınıflandırma görevlerine az miktarda görev-özel katmanla uyarlanabilmiştir (Devlin vd., 2019).

BERT'in finansal duygu analizindeki temel avantajı, bir sözcüğün anlamını cümlelerin geri kalanına göre temsil edebilmesidir. Bununla birlikte genel amaçlı ön eğitim verisi finans terminolojisini sınırlı ölçüde içerdüğinden, alan uyarlaması ve hedef görev ince ayarı önem kazanmaktadır.

2.3. FinBERT ve Alan Odaklı Ön Eğitim

Araci (2019), genel BERT modelini finansal metinlerde devam eden ön eğitim ve görev-özel ince ayar yoluyla FinBERT'e dönüřtürmüş; Financial PhraseBank ve FiQA üzerinde güçlü sonuçlar raporlamıştır. Yang, Uy ve Huang (2020) ise büyük ölçekli finansal iletişim metinleriyle ön eğitilen farklı bir FinBERT sürümü sunmuştur.

FinBERT'in başarısı finans dilinin özel dağılımına uyarlanmasından kaynaklanmaktadır. Ancak finansal alan tek bir homojen metin türünden oluşmaz. Kurumsal rapor, Reuters haberi, kısa piyasa başlığı ve sosyal medya mesajı arasında belirgin dağılım farkları bulunur. Ayrıca alan ön eğitimi, hedef veri setinin hangi koşullarda neutral etiketi verdiğini öğretmez. Bu nedenle hazır FinBERT ile hedef veri setine özgü ince ayarlı modellerin karşılaştırılması gereklidir.

2.4. RoBERTa ve DistilBERT

RoBERTa, BERT ön eğitim prosedürünü daha fazla veri, dinamik maskeleme, daha büyük mini-batch ve sonraki cümle tahmini görevinin kaldırılması gibi değişikliklerle optimize etmiştir (Liu vd., 2019). Genel amaçlı bir model olmasına rağmen güçlü dil temsilleri, hedef veri setine ince ayar uygulandığında alan odaklı bir modeli geçebilmesini mümkün kılabilir.

DistilBERT, bilgi damıtma yoluyla BERT'in daha küçük ve hızlı bir sürümünü sunar (Sanh vd., 2019). Bu modelin değerlendirilmesi, yalnızca en yüksek doğruluğun değil, model boyutu ve çıkarım maliyeti ile performans arasındaki dengenin de tartışılmasını sağlar.

2.5. Tamamlayıcı Yaklaşım Olarak Sıfır Örnekli Sınıflandırma

Sıfır örnekli sınıflandırma, hedef göreve ait etiketli eğitim örnekleri olmadan tahmin yapılmasını amaçlar. NLI tabanlı yaklaşımda metin bir öncül, sınıf açıklaması ise hipotez olarak sunulur. BART-MNLI gibi modeller, metnin positive financial sentiment gibi bir hipotezi destekleyip desteklemediğine göre sınıf üretir.

Yaklaşımın avantajı yeni bir veri setinde eğitim maliyeti olmaksızın temel bir başlangıç sonucu sağlayabilmesidir. Buna karşılık hipotez şablonu, sınıf açıklamalarının sözcük seçimi ve alan bilgisi eksikliği performansı önemli ölçüde etkiler. Bu tezde sıfır örnekli sonuçlar ana araştırma hipotezlerinin bir parçası olarak değil, denetimli ince ayarlı modellere kıyasla etiketsiz başlangıç performansını göstermek amacıyla tamamlayıcı/keşifsel olarak ele alınmıştır.

Finans alanında NLI performansının alan kaymasına duyarlılığı güncel çalışmalarla da gösterilmiştir. Magomere vd. (2025), SEC filings, yıllık raporlar ve earnings call transkriptlerini kapsayan FinNLI benchmarkında genel alan NLI modellerinin finansal NLI görevinde belirgin performans kaybı yaşadığını; FinNLI üzerinde ince ayarın sıfır örnekli modellere göre performansı artırdığını raporlamıştır. Bu bulgu, bu tezde NLI tabanlı sıfır örnekli modellerin ana karşılaştırmaya eşdeğer değil, tamamlayıcı bir başlangıç ölçütü olarak ele alınmasını desteklemektedir.

2.6. Veri Setleri ve Etiket Semantiği

Financial PhraseBank, uzmanlar tarafından etiketlenen finans haber cümleleriyle alanın temel veri setlerinden biridir (Malo vd., 2014). FiQA, finansal metinlerde duygu puanı ve hedef bilgisi sunmaktadır. Twitter Financial News Sentiment gibi kısa metin veri setleri ise piyasa yönüne daha yakın bir etiketleme mantığı taşıyabilir.

Aynı sınıf adlarının farklı veri setlerinde farklı anlamlara sahip olması karşılaştırmaların temel sorunlarından biridir. Bir haber dilsel olarak olumsuz ifadeler içerse bile açık yatırım yönü bulunmadığında neutral olarak etiketlenebilir. Tersine beklentiden daha düşük bir kayıp, yüzeysel olumsuz sözcüklere rağmen olumlu etki taşıyabilir.

2.7. Alan Kayması ve Dış Test

Alan kayması, eğitim ve test dağılımlarının farklılaşmasıdır. Finansal duygu analizinde kaynak kuruluş, dönem, uzunluk, şirket sektörü ve anotasyon politikası alan kaymasına neden olabilir. Rastgele iç test ayrımı, aynı veri setine özgü kalıpların öğrenilmesi nedeniyle gerçek genellemeyi olduğundan yüksek gösterebilir.

Guo vd. (2023), üç yıllık gerçek finansal sosyal medya verisi üzerinde zamansal veri dağılımı kaymasını incelemiş ve ince ayarlı modellerin geçmiş dönem verisiyle eğitilip gelecekteki dağılıma uygulandığında out-of-sample performansında sistematik düşüş yaşayabildiğini göstermiştir. Bu sonuç, finansal duygu analizinde rastgele iç test ayrımının tek başına gerçek kullanım koşullarındaki genellemeyi temsil etmeyebileceğini ve bağımsız dış testlerin önemini desteklemektedir.

Bu tezde S&P 500 haber başlıkları yakın alan dış testi, Reuters anotasyon seti ise daha uzak alan dış testi olarak değerlendirilmiştir. Böylece modelin yalnızca hedef veri setindeki başarısı değil, farklı finansal haber biçimlerine aktarılabilirliği incelenmiştir.

2.8. Literatürün Sentezi ve Araştırma Boşluğu

Literatür finansal alan ön eğitiminin yararını ve genel amaçlı Transformer modellerinin güçlü ince ayar performansını ortaya koymaktadır. Buna karşın, aynı model ailesinin iç test ile farklı kaynaklardan oluşturulan bağımsız dış testlerde nasıl sıralandığını; veri kaynağı ve etiket semantiğinin bu sıralamayı nasıl değiştirdiğini birlikte inceleyen

alıřmalar sınırlıdır. Sıfır rnekli NLI yaklařımı ise bu ana karřılařtırmaya ek, tamamlayıcı/keřifsel bir referans noktası olarak deęerlendirilmiřtir.

ok gncel bir n baskı alıřmasında Luo (2026), beř finansal metin veri setini ortak  sınıflı bir benchmarkta birleřtirerek hazır FinBERT ve Financial-RoBERTa, zero-shot bir LLM ve QLoRA ile uyarlanmış LLM modellerini karřılařtırmıřtır. alıřmada QLoRA ile grev-zel uyarlamanın sınıflandırma performansını belirgin biimde artırabildięi, ancak daha yksek duygu sınıflandırma bařarısının istatistiksel olarak saęlam getiri ngrsne otomatik olarak dnřmedięi raporlanmıřtır (Luo, 2026). Bu bulgu, finansal NLP modellerinin tek bir i test metrięi yerine farklı veri kaynakları ve kullanım amaları altında deęerlendirilmesi gerektięi ynndeki daha geniř genelleme tartıřmasıyla uyumludur.

Mevcut alıřma, model bařarısının veri kaynaęı ve etiket semantięine baęımlılıęını merkeze almaktadır. Arařtırma bořluęu, en iyi i test modelinin hangi kořullarda dıř test stnlęn koruduęu ve alan odaklı FinBERT'in hangi metin trlerinde yeniden avantaj saęladığı sorularında konumlanmaktadır.

3. YNTEM

3.1. Arařtırma Tasarımı

Arařtırma nicel, deneysel ve karřılařtırmalı bir tasarıma sahiptir. İlk ařamada hazır ProsusAI/FinBERT temel model olarak deęerlendirilmiř; BERT, DistilBERT ve RoBERTa hedef veri setinde ince ayarlanmıřtır. İkinci ařamada FinBERT'in kendisi de aynı hedef veri setine ince ayarlanarak alan-zg n eęitim ile grev-zg ince ayarın birlikte etkisi test edilmiřtir. nc ařamada drt ince ayarlı model 42, 123 ve 2024 tohumları altında karřılařtırılmıř; ortalama ve standart sapmalar ile eřleřtirilmiř McNemar-Holm ve bootstrap analizleri raporlanmıřtır. Drdnc ařamada fine-tuned FinBERT, S&P 500, Reuters ve sentetik dıř testlerde deęerlendirilmiřtir. Beřinci ařamada RoBERTa iin Twitter-only ve Twitter + Financial PhraseBank eęitim kořulları seed 42 altında kaynak-ablasyonuyla karřılařtırılmıřtır. Son olarak hata rntleri, yksek gvenli yanlıř tahminler ve CPU ıkarım verimlilięi incelenmiřtir.

Ařama	Notebook	Ama
Kurulum	00_setup_requirements	Ktphanelerin ve alıřma ortamının hazırlanması

Aşama	Notebook	Amaç
Reuters veri hazırlama	01a_build_reuters_annotation_dataset	Reuters anotasyon örneklerinin oluşturulması
S&P 500 veri hazırlama	01b_build_sp500_annotation_dataset	Başlıkların ön etiketlenmesi ve dengeli anotasyon seti
FinBERT temel model	02_evaluate_finbert_baseline	Hazır FinBERT performansı ve hata analizi
Tanısal deney	03a_evaluate_unfinetuned_models_diagnostic	İnce ayarsız modellerin tanısal değerlendirilmesi
Sıfır örnekli test	03b/03c	BART ve NLI model ailelerinin S&P 500 testi
İnce ayar	04_train_plain_sentiment_models	BERT, DistilBERT ve RoBERTa eğitimi
Dış testler	05/06/07	S&P 500, sentetik ve Reuters değerlendirmeleri
FinBERT hedef ince ayarı	08_finetune_finbert_target_dataset	ProsusAI/FinBERT'in aynı hedef veri setinde ince ayarlanması
Çoklu tohum	10_multiseed_training	BERT, DistilBERT, RoBERTa ve fine-tuned FinBERT için seed 123 ve 2024; seed 42 ile birleştirme
İstatistiksel testler	11_statistical_significance_tests	McNemar + Holm, paired bootstrap ve %95 güven aralıkları
Model × veri × sınıf	13_model_dataset_class_analysis	Mevcut iç/dış test sonuçlarının ortak matriste analizi
Genişletilmiş hata analizi	14_extended_error_analysis	Fine-tuned FinBERT hata geçişleri ve yüksek güvenli hatalar
Verimlilik	15_model_efficiency_analysis	Parametre sayısı, CPU throughput ve latency karşılaştırması
Kaynak ablasyonu	12_roberta_dataset_ablation	RoBERTa: Twitter-only vs Twitter + Financial PhraseBank
Fine-tuned FinBERT dış test	16_finetuned_finbert_external_evaluation_v2	Fine-tuned FinBERT'in S&P 500, sentetik ve Reuters değerlendirmesi
Dış eşleştirilmiş testler	17_external_statistical_significance_tests_v3	Uygun aynı-örnekli dış tahminlerde McNemar-Holm ve paired bootstrap

3.2. Veri Setleri

3.2.1. Ana Eğitim ve İç Test Veri Seti

Ana deney veri havuzu Twitter Financial News Sentiment örnekleri ile yardımcı eğitim amacıyla Financial PhraseBank örneklerinden oluşturulmuştur. Güncel kaydedilmiş splitlerde eğitim kümesi 12.950, doğrulama kümesi 1.432 ve iç test kümesi 2.386 örnekten oluşmaktadır. İç test kümesi yalnızca ana Twitter veri setinden katmanlı örnekleme ile ayrılmıştır ve 358 negative, 1.549 neutral ve 479 positive örnek içermektedir. Financial PhraseBank örnekleri test kümesine alınmamış, yalnızca eğitim havuzunda kullanılmıştır. Metinlerin normalize edilmiş sürümleri üzerinden eğitim-test örtüşme kontrolü uygulanmıştır. Hazır FinBERT temel modelinin daha önceki değerlendirme notebooku ise aynı deney hattının 2.387 örnekle tarihsel test sürümünü kullanmıştır; bu tek örneklelik fark sonuç tablolarında ayrıca belirtilmiş ve bir sınırlılık olarak korunmuştur.

3.2.2. S&P 500 Dış Test Seti

S&P 500 şirketlerine ilişkin haber başlıkları hazır FinBERT ile ön etiketlenmiş, daha sonra sınıflar dengelenerek anotasyon batch dosyaları oluşturulmuştur. Dış testte kullanılan geçerli değerlendirme seti 1.060 örnekten oluşmaktadır: 323 negative, 339 neutral ve 398 positive. Etiketleme sürecinde manuel inceleme için ChatGPT destekli açıklama alanları kullanılmış; ancak nihai akademik sürümde insan anotatör sayısı ve bağımsız uyum ölçümü ayrıca raporlanmalıdır.

3.2.3. Sentetik Finansal Haber Seti

Sentetik değerlendirme seti her sınıf için dengeli olacak biçimde toplam 3.000 finansal haber örneğinden oluşmaktadır. Set, açık ve kontrollü duygu sinyalleri içerdiği için modellerin öğrenilmiş sınıf sınırlarını sınamakta yararlıdır; ancak gerçek haber dilindeki belirsizlik, örtük etki ve editoryal çeşitlilik sınırlıdır.

3.2.4. Reuters Anotasyon Seti

Reuters dış test seti 5.000 finansal haber örneğinden oluşmaktadır. Batch dosyaları farklı kolon ve başlık yapıları için sağlam okuma yordamlarıyla birleştirilmiş; metin, nihai etiket ve destekleyici açıklama alanları standartlaştırılmıştır. Reuters metinleri, ana veri setine kıyasla daha editoryal ve kurumsal bir dil taşıdığından uzak alan genelleme testi olarak ele alınmıştır.

3.3. Modeller

Model	Yaklaşım	Çalışmadaki rol
ProsusAI/FinBERT	Finans alanına özgü ön eğitim ve duygu sınıflandırma başlığı	Hazır temel model
BERT-base-uncased	Genel amaçlı Transformer encoder	Hedef veri setine ince ayarlı model
DistilBERT-base-uncased	Damıtılmış, daha hafif BERT	Verimlilik odaklı ince ayarlı model
RoBERTa-base	Optimize edilmiş BERT ön eğitimi	Güçlü genel amaçlı ince ayarlı model
BART-large-MNLI ve NLI ailesi	Doğal dil çıkarımı	Tamamlayıcı/keşifsel başlangıç ölçütü
ProsusAI/FinBERT (fine-tuned)	Finans alanına özgü ön eğitim + hedef veri setine görev-özel ince ayar	Alan ön eğitimi ile hedef ince ayarın birleşik etkisini ölçen model

3.4. Eğitim Ayarları

İnce ayar deneylerinde dört epoch, 2×10^{-5} öğrenme oranı, 16 eğitim batch boyutu, 32 değerlendirme batch boyutu, 128 maksimum dizi uzunluğu ve 0,01 weight decay

kullanılmıştır. Sınıf dengesizliği nedeniyle sınıf ağırlıkları eğitim kaybına dahil edilmiştir. Seed 42 ana deney için kullanılmış; yeniden üretilebilirlik analizinde seed 123 ve 2024 eklenmiştir. BERT, DistilBERT, RoBERTa ve fine-tuned FinBERT aynı kaydedilmiş splitler üzerinde değerlendirilmiş; model seçimi validation Macro-F1 değerine göre yapılmıştır. Eğitim ve çoklu tohum çalıştırmaları CPU ortamında yürütülmüştür.

3.5. Değerlendirme Ölçütleri

Doğruluk, kesinlik, duyarlılık, F1, makro ortalamalar ve ağırlıklı ortalamalar hesaplanmıştır. Ana ölçüt olarak makro F1 kullanılmıştır; çünkü bu ölçüt her sınıfın F1 değerini eşit ağırlıkla değerlendirerek baskın neutral sınıfının accuracy üzerindeki etkisini sınırlar. Çoklu tohum deneylerinde her model için üç seed üzerinden ortalama $\pm$ standart sapma raporlanmıştır. Aynı test örneklerinde iki modelin doğru/yanlış kararları McNemar testiyle karşılaştırılmış ve çoklu karşılaştırmalar için Holm düzeltmesi uygulanmıştır (McNemar, 1947). Macro-F1 farkları aynı örneklerin birlikte yeniden örneklenmesine dayanan 5.000 tekrarlı paired bootstrap ile %95 güven aralığı üzerinden incelenmiştir (Efron & Tibshirani, 1993). Ayrıca model parametre sayısı, CPU örnek/saniye ve örnek başına gecikme performans-verimlilik analizi için kullanılmıştır.

Doğruluk = doğru tahmin sayısı / toplam örnek sayısıdır. Bir sınıf için kesinlik, o sınıf olarak tahmin edilen örneklerin ne kadarının doğru olduğunu; duyarlılık ise gerçek sınıf örneklerinin ne kadarının yakalandığını gösterir. F1, kesinlik ve duyarlılığın harmonik ortalamasıdır. Makro F1, sınıf bazlı F1 değerlerinin aritmetik ortalamasıdır.

3.6. Etik ve Geçerlik Konuları

Veri setleri kamuya açık veya araştırma amaçlı kaynaklardan türetilmiştir. S&P 500 ve Reuters setlerinde kullanılan anotasyon yönergeleri Ek B’de özetlenmiştir. Bununla birlikte mevcut proje kayıtlarında anotatör sayısı ve değerlendiriciler arası bağımsız uyum katsayısı bulunmadığından anotasyon güvenilirliği nicel olarak doğrulanamamıştır; bu durum çalışmanın geçerlik sınırlılıklarından biridir. Yeniden üretilebilirlik açısından BERT, DistilBERT, RoBERTa ve hedef veri setine ince ayarlı FinBERT seed 42, 123 ve 2024 altında değerlendirilmiş ve ortalama $\pm$ standart sapma raporlanmıştır. Örnek-bazlı eşleştirilmiş McNemar ve paired bootstrap testleri, seed 42 genel model koşullarında aynı formatta prediction CSV dosyaları bulunmadığından seed 123 ve 2024 ile sınırlıdır. Ayrıca

hazır FinBERT temel modelinin tarihsel 2.387 örnekli iç test sürümü ile güncel 2.386 örnekli split arasındaki tek örneklik fark karşılaştırmalarda açıkça belirtilmiştir.

4. BULGULAR


4.1. Hazır FinBERT Temel Model Sonuçları

Hazır ProsusAI/FinBERT modeli, 2.387 örnekli nihai iç test kümesinde 0,7323 doğruluk ve 0,6794 makro F1 elde etmiştir. Ağırlıklı F1 değeri 0,7400'dır. Doğruluk ile makro F1 arasındaki fark, sınıf dağılımı ve özellikle tarafsız sınıftaki performans sorununa işaret etmektedir.

Hata analizinde en belirgin örüntü, gerçek etiketi neutral olan çok sayıda örneğin yüksek güvenle negative olarak tahmin edilmesidir. Karışık bilgi içeren, açık piyasa yönü taşımayan veya yalnızca bilgilendirici nitelikteki haberlerde FinBERT olumsuz sözcüklere güçlü ağırlık vermiştir. Bu durum modelin Financial PhraseBank benzeri genel finansal ton mantığı ile hedef veri setinin piyasa yönü odaklı etiket mantığı arasındaki farkla açıklanmıştır.

4.2. İnce Ayarlı Modellerin İç Test Sonuçları

Model	Doğrulama doğruluğu	Doğrulama Macro-F1	Test doğruluğu	Test Macro-F1	Test Weighted-F1
RoBERTa-base	0,8939	0,8718	0,8906	0,8651	0,8918
Fine-tuned FinBERT	0,8820	0,8539	0,8818	0,8512	0,8829
BERT-base-uncased	0,8820	0,8535	0,8722	0,8378	0,8733
DistilBERT-base-uncased	0,8792	0,8426	0,8583	0,8218	0,8593
Original FinBERT	N/A	N/A	0,7323	0,6794	0,7400



Şekil 1. Modellerin iç test doğruluk sonuçları

İnce ayarlı bütün modeller hazır FinBERT'in 0,6794 makro F1 sonucunu belirgin biçimde aşmıştır. FinBERT'in kendisinin hedef veri setine ince ayarlanması makro F1'i 0,8512'ye yükseltmiş ve alan-özü ön eğitimin hedefe özgü ince ayarla birleştiğinde güçlü bir sonuç verdiğini göstermiştir. Buna rağmen seed 42'de en yüksek iç test sonucu RoBERTa-base modelinde 0,8651 makro F1 ile elde edilmiştir. Fine-tuned FinBERT 0,8512 ile ikinci, BERT 0,8378 ile üçüncü ve DistilBERT 0,8218 ile dördüncü sırada yer almıştır. Fine-tuned FinBERT'in validation (0,8539) ve test (0,8512) makro F1 değerlerinin yakınlığı, seçilen modelin doğrulama kümesine aşırı uyum göstermediğine dair olumlu bir işarettir.

4.3. S&P 500 Dış Test Sonuçları

Model	Doğruluk	Macro-F1	Weighted-F1
RoBERTa-base	0,8132	0,8145	0,8153
Original FinBERT	0,7519	0,7521	0,7513
DistilBERT-base-uncased	0,7519	0,7510	0,7525
BERT-base-uncased	0,7557	0,7549	0,7561
Fine-tuned FinBERT	0,7726	0,7723	0,7739

RoBERTa S&P 500 dış testinde 0,8145 Macro-F1 ile ilk sırayı korumuştur. Fine-tuned FinBERT aynı 1.060 örnek üzerinde 0,7723 Macro-F1 elde ederek hazır FinBERT'in 0,7521 sonucunu 0,0201 puan aşmış, ancak RoBERTa'nın gerisinde kalmıştır. Original

FinBERT ile fine-tuned FinBERT arasındaki dış eşleştirilmiş karşılaştırmada fark sayısal olarak fine-tuned FinBERT lehine olsa da Holm-düzeltilmiş McNemar testi anlamlı değildir ($p=0,1678$) ve Original–fine-tuned Macro-F1 bootstrap %95 güven aralığı $[-0,0492; 0,0080]$ sıfırı içermektedir. Bu nedenle S&P 500’de fine-tuning kazancı gözlenmekle birlikte istatistiksel olarak kesin bir üstünlük olarak yorumlanmamıştır.

4.4. Sentetik Veri Sonuçları

Model	Doğruluk	Macro-F1	Weighted-F1
RoBERTa-base	0,9957	0,9957	0,9957
BERT-base-uncased	0,9743	0,9742	0,9742
DistilBERT-base-uncased	0,9583	0,9581	0,9581
Original FinBERT	0,9550	0,9551	0,9551
Fine-tuned FinBERT	0,9747	0,9746	0,9746

Bütün modeller sentetik veri üzerinde çok yüksek başarı göstermiştir. RoBERTa 0,9957 Macro-F1 ile ilk sırada, fine-tuned FinBERT 0,9746 ile BERT’in 0,9742 sonucuna çok yakın ikinci grupta yer almıştır. DistilBERT 0,9581 ve hazır FinBERT 0,9551 düzeyindedir. Bu sıkışmış yüksek performans aralığı, sentetik örneklerde sınıf ipuçlarının gerçek dış testlere göre daha açık olduğunu ve sentetik sonucun tek başına gerçek dünya genellemesi kanıtı sayılamayacağını göstermektedir.


4.5. Reuters Dış Test Sonuçları

Model	Doğruluk	Macro Precision	Macro Recall	Macro-F1	Weighted-F1
Original FinBERT	0,6966	0,6882	0,7021	0,6866	0,7016
RoBERTa-base	0,6268	0,7464	0,6723	0,6388	0,6486
BERT-base-uncased	0,6034	0,7165	0,6451	0,6131	0,6240
DistilBERT-base-uncased	0,5766	0,6883	0,6201	0,5869	0,5953
Fine-tuned FinBERT	0,5984	0,7207	0,6474	0,6101	0,6171

Reuters testinde model sıralaması belirgin biçimde değişmiştir. Hazır FinBERT 0,6866 Macro-F1 ile en başarılı model, RoBERTa 0,6388 ile ikinci olmuştur. Fine-tuned FinBERT 0,6101 ile BERT’in 0,6131 sonucuna yakın, fakat hazır FinBERT’in belirgin biçimde gerisinde kalmıştır. Aynı 5.000 Reuters örneğinde Original FinBERT ile fine-tuned FinBERT arasındaki eşleştirilmiş analizde Original FinBERT lehine $\Delta\text{Macro-F1}=+0,0765$ bulunmuş; Holm-düzeltilmiş McNemar p-değeri $1,37 \times 10^{-32}$ düzeyinde kalmış ve bootstrap %95 güven aralığı $[0,0610; 0,0923]$ sıfırı dışlamıştır. Böylece hedefe özgü fine-tuning’in

uzak editoryal dağılımda hazır FinBERT’in genelleme avantajını azaltabildiği güçlü biçimde desteklenmiştir.

4.6. Test Alanları Arası Karşılaştırma



Şekil 2. Modellerin test alanlarına göre Macro-F1 karşılaştırması

Model	İç test	S&P 500	Sentetik	Reuters
FinBERT	0,6794	0,7521	0,9551	0,6866
DistilBERT	0,8218	0,7510	0,9581	0,5869
BERT	0,8378	0,7549	0,9742	0,6131
RoBERTa	0,8651	0,8145	0,9957	0,6388
Fine-tuned FinBERT	0,8512	0,7723	0,9746	0,6101

Sonuçlar tek bir evrensel en iyi model bulunmadığını göstermektedir. İç testte ve S&P 500’de RoBERTa öne çıkarken, Reuters’ta hazır FinBERT yeniden birinci olmuştur. Fine-tuned FinBERT iç testte 0,8512’den S&P 500’de 0,7723’e ve Reuters’ta 0,6101’e gerilerken sentetik sette 0,9746’ya ulaşmıştır. Bu değişim, görev-özel fine-tuning kazancının dış dağılımlara otomatik olarak taşınmadığını; kaynak dili, editoryal yapı ve etiket semantiğine bağlı olarak model sıralamasının yeniden düzenlenebildiğini göstermektedir.

4.7. Tamamlayıcı/Keşifsel Analiz: Sıfır Örnekli NLI Modelleri

Bu bölümdeki sıfır örnekli deneyler, çalışmanın temel hipotezlerini sınamak için değil, etiketli görev-özel eğitim verisi kullanılmadığında elde edilebilecek başlangıç performansını keşifsel olarak değerlendirmek amacıyla gerçekleştirilmiştir. S&P 500 anotasyon seti üzerinde BART-large-MNLI ile BERT ailesinin NLI sürümleri sıfır örnekli olarak değerlendirilmiştir. En iyi sonuç BART-large-MNLI tarafından 0,6594 doğruluk ve 0,5580 makro F1 ile elde edilmiştir. Bununla birlikte tarafsız sınıf F1 değeri 0,1199 düzeyinde kalmış; diğer NLI modellerinde daha da düşük değerler gözlenmiştir. Bu nedenle sonuçlar, sıfır örnekli yaklaşımın denetimli modellerin eşdeğer alternatifi olarak değil, düşük başlangıç maliyetli tamamlayıcı bir referans olarak değerlendirilmesi gerektiğini göstermektedir.

Model	N	Doğruluk	Makro kesinlik	Makro duyarlılık	Makro F1	F1-neg	F1-tar	F1-poz
BART-large-MNLI zero-shot	1060	0.6594	0.7043	0.6479	0.5580	0.8101	0.1199	0.7440
RoBERTa-base NLI zero-shot	1060	0.6085	0.7423	0.5966	0.4913	0.7523	0.0233	0.6982
BERT-base MNLI zero-shot	1060	0.5057	0.3951	0.4930	0.4033	0.5963	0.0058	0.6077
DistilBERT-base MNLI zero-shot	1060	0.4679	0.5502	0.4760	0.3880	0.5663	0.0776	0.5201

Tablo 8. S&P 500 sıfır örnekli model sonuçları

4.8. Karışıklık Matrisleri ve Sınıf Bazlı Hata Örüntüleri

Karışıklık matrisleri, toplam başarı değerlerinin hangi sınıf geçişlerinden kaynaklandığını göstermektedir. İç testte RoBERTa tarafsız sınıfta yüksek doğru tahmin sayısına ulaşırken 67 tarafsız örneği negatif olarak sınıflandırmıştır. S&P 500 dış testinde hazır FinBERT için tarafsızdan negatife hata oranı %10,62 iken bu oran RoBERTa için %5,60, BERT için %4,42 ve DistilBERT için %4,72 düzeyindedir. Buna karşın BERT ve DistilBERT gerçek negatif örnekleri tarafsız olarak sınıflandırmada daha fazla hata yapmış; bu durum makro F1 değerlerinin RoBERTa ve FinBERT'in gerisinde kalmasına katkıda bulunmuştur.

İç test - RoBERTa

Gerçek sınıf	Negatif	309	35	14
	Tarafsız	67	1394	88
	Pozitif	8	49	422
		Negatif	Tarafsız	Pozitif
		Tahmin edilen sınıf		

Şekil 3. İç test - RoBERTa karışıklık matrisi

S&P 500 - FinBERT			
Gerçek sınıf	Negatif	Tarafsız	Pozitif
	264	37	22
	36	260	43
	66	59	273
	Negatif	Tarafsız	Pozitif
Tahmin edilen sınıf			

Şekil 4. S&P 500 - FinBERT karışıklık matrisi

S&P 500 - RoBERTa

Gerçek sınıf	Negatif	252	53	18
	Tarafsız	19	294	26
	Pozitif	11	71	316
		Negatif	Tarafsız	Pozitif
		Tahmin edilen sınıf		

Şekil 5. S&P 500 - RoBERTa karışıklık matrisi

S&P 500 - BERT

Gerçek sınıf	Negatif	216	73	34
	Tarafsız	15	292	32
	Pozitif	26	79	293
		Negatif	Tarafsız	Pozitif
		Tahmin edilen sınıf		

Şekil 6. S&P 500 - BERT karışıklık matrisi

S&P 500 - DistilBERT

Gerçek sınıf	Negatif	214	76	33
	Tarafsız	16	287	36
	Pozitif	26	76	296
		Negatif	Tarafsız	Pozitif
		Tahmin edilen sınıf		

Şekil 7. S&P 500 - DistilBERT karışıklık matrisi


4.9. Çoklu Tohum Sonuçları ve Yeniden Üretilirlik

BERT, DistilBERT, RoBERTa ve fine-tuned FinBERT modelleri seed 42, 123 ve 2024 sonuçlarıyla birlikte değerlendirildiğinde model sıralamasının büyük ölçüde korunduğu görülmüştür. Üç tohumun ortalamasında RoBERTa $0,8728 \pm 0,0068$ Macro-F1 ile ilk sıradadır. Fine-tuned FinBERT $0,8480 \pm 0,0028$, BERT $0,8396 \pm 0,0023$ ve DistilBERT $0,8231 \pm 0,0028$ değerine ulaşmıştır. DistilBERT'in seed 42 ve 123 Macro-F1 değerlerinin neredeyse aynı olması ve diğer modellerde de düşük standart sapmalar gözlenmesi, tek-seed sonuçlarının genel sıralamayı büyük ölçüde yansıttığını desteklemektedir.

Tablo 9. Üç random seed için iç test performansı (ortalama $\pm$ std)

Model	n seed	Accuracy mean $\pm$ std	Macro-F1 mean $\pm$ std	Weighted-F1 mean $\pm$ std
RoBERTa-base	3	$0,8975 \pm 0,0059$	$0,8728 \pm 0,0068$	$0,8984 \pm 0,0057$
Fine-tuned FinBERT	3	$0,8790 \pm 0,0025$	$0,8480 \pm 0,0028$	$0,8799 \pm 0,0026$
BERT-base-uncased	3	$0,8736 \pm 0,0021$	$0,8396 \pm 0,0023$	$0,8743 \pm 0,0017$

DistilBERT-base-uncased	3	0,8601 $\pm$ 0,0028	0,8231 $\pm$ 0,0028	0,8610 $\pm$ 0,0029
-------------------------	---	---------------------	---------------------	---------------------



Şekil 8. Üç random seed altında Macro-F1 ortalamaları ve standart sapmalar

4.10. İstatistiksel Anlamlılık ve Güven Aralıkları

İç testte seed 123 ve 2024 için aynı 2.386 örnek üzerinde eşleştirilmiş karşılaştırmalar yapılmıştır. McNemar p-değerleri Holm yöntemiyle düzeltilmiş; Macro-F1 farkları 5.000 tekrarlı paired bootstrap ile %95 güven aralığı üzerinden değerlendirilmiştir. RoBERTa'nın fine-tuned FinBERT'e üstünlüğü her iki seed'de de desteklenmiştir. Dış testte aynı protokol yalnızca giriş dosyaları ve örnek eşleşmesi doğrulanmış çiftlerde kullanılmıştır: S&P 500'de Original FinBERT–fine-tuned FinBERT farkı anlamlı bulunmazken (Holm $p=0,1678$), Reuters'ta Original FinBERT'in fine-tuned FinBERT'e üstünlüğü güçlü biçimde desteklenmiştir (Holm $p \approx 1,37 \times 10^{-32}$; %95 GA [0,0610; 0,0923]). S&P 500 RoBERTa–fine-tuned FinBERT otomatik eşleştirmesinde RoBERTa için 0,4913 gibi ana S&P sonucuyla uyumsuz bir dosya seçildiği tespit edildiğinden bu karşılaştırma bilimsel sonuçlara dahil edilmemiştir; Reuters RoBERTa tahmin dosyası da eşleştirilmiş test girdisi olarak mevcut olmadığı için bu çift test edilmemiştir.

Tablo 10. Seçilmiş eşleştirilmiş istatistiksel karşılaştırmalar

Karşılaştırma	Seed 123	Seed 2024	Yorum
RoBERTa vs Fine-tuned FinBERT	Holm $p=0,000617$; $\Delta F1=+0,0294$; %95 GA [0,0138; 0,0446]	Holm $p=0,001410$; $\Delta F1=+0,0312$; %95 GA [0,0162; 0,0462]	Her iki seed'de anlamlı
RoBERTa vs BERT	Holm $p=0,000348$; $\Delta F1=+0,0335$	Holm $p=0,000070$; $\Delta F1=+0,0390$	Her iki seed'de anlamlı
RoBERTa vs DistilBERT	Holm $p<0,000001$; $\Delta F1=+0,0544$	Holm $p<0,000001$; $\Delta F1=+0,0513$	Her iki seed'de anlamlı
Fine-tuned FinBERT vs BERT	Holm $p=0,879829$; GA sıfırı içeriyor	Holm $p=0,369760$; GA sıfırı içeriyor	Anlamlı fark yok


BERT vs DistilBERT	Holm p=0,009323; GA sıfırı dışlıyor	Holm p=0,214522; GA sıfırı içeriyor	Seed'e duyarlı
--------------------	-------------------------------------	-------------------------------------	----------------

4.11. Model Verimliliği

CPU üzerinde 1.000 iç test örneği, batch size 32 ve üç tekrar kullanılarak yapılan çıkarım benchmarkında DistilBERT açık ara en yüksek throughput değerini vermiştir. DistilBERT 66,96 milyon parametre ile BERT'in yaklaşık %61'i büyüklüğünde olup 70,30 örnek/s hızına ulaşmıştır; bu değer BERT'in 31,37 örnek/s hızının yaklaşık 2,24 katıdır. RoBERTa 124,65 milyon parametreyle en büyük model olmasına rağmen 35,91 örnek/s hızında çalışmış ve iç testte en yüksek Macro-F1'i sağlamıştır. Bu nedenle DistilBERT hız ve boyut öncelikli uygulamalarda, RoBERTa ise en yüksek sınıflandırma başarısının öncelikli olduğu durumda farklı avantajlar sunmaktadır.

Tablo 11. CPU çıkarım verimliliği ve iç test performansı

Model	Parametre (M)	CPU örnek/s	Gecikme (ms/örnek)	Internal Macro-F1
Original FinBERT	109,48	30,81	32,46	0,6794
Fine-tuned FinBERT	109,48	28,84	34,68	0,8512
BERT	109,48	31,37	31,88	0,8378
DistilBERT	66,96	70,30	14,23	0,8218
RoBERTa	124,65	35,91	27,85	0,8651



Şekil 9. İç test Macro-F1 ile CPU çıkarım hızı arasındaki denge


4.12. Fine-Tuned FinBERT Hata Örüntüleri

Fine-tuned FinBERT iç testte 2.386 örneğin 282'sini yanlış sınıflandırmıştır. En sık iki hata yönü neutral → positive (78; %27,66) ve neutral → negative (75; %26,60) olmuştur.

Negative → neutral ve positive → neutral geçişleri 52’şer örnekle hataların ayrı ayrı %18,44’ünü oluşturmuştur. Hataların 217’si (%77,0) en az 0,90, 196’sı (%69,5) en az 0,95 ve 137’si (%48,6) en az 0,99 tahmin güvenine sahiptir. Bu yüksek-güvenli yanlışlar, problemin yalnızca belirsiz düşük güven örneklerinden değil; modelin bazı başlıkları sistematik biçimde farklı etiket semantiğiyle yorumlamasından da kaynaklandığını göstermektedir.

Tablo 12. Fine-tuned FinBERT iç test hata geçişleri

Gerçek → Tahmin	Hata sayısı	Toplam hatalar içindeki pay
neutral → positive	78	%27,66
neutral → negative	75	%26,60
negative → neutral	52	%18,44
positive → neutral	52	%18,44
positive → negative	17	%6,03
negative → positive	8	%2,84



Şekil 10. Fine-tuned FinBERT iç test hata geçişlerinin dağılımı

4.13. RoBERTa Kaynak-Bileşimi Ablasyonu

Kaynak-ablasyon deneyinde RoBERTa seed 42 ve aynı temel hiperparametreler altında iki eğitim koşuluyla karşılaştırılmıştır: yalnız Twitter eğitim verisi (n=8.110) ve Twitter + Financial PhraseBank birleşimi (n=12.950). İç testte Twitter-only koşulu 0,9036 doğruluk ve 0,8810 Macro-F1 elde ederken birleşik koşul 0,8948 doğruluk ve 0,8679 Macro-F1 üretmiştir. Financial PhraseBank eklenmesi bu koşulda Macro-F1’i 0,0132 azaltmış; negative, neutral ve positive sınıflarında sırasıyla -0,0236, -0,0046 ve -0,0112 F1 farkı oluşturmuştur.

Reuters dış testinde Twitter-only RoBERTa 0,6465, birleşik eğitim 0,6305 Macro-F1 elde etmiş; fark -0,0160 olmuştur. S&P 500 ablasyon çıktısında Twitter-only 0,7989 ve birleşik eğitim 0,7968 Macro-F1 üretmiştir; ancak bu ablasyon dosyası 1.030 örnek kullanırken

tezdeki doğrulanmış ana S&P 500 değerlendirmesi 1.060 örnektir. Bu nedenle S&P ablasyon sonucu ana S&P model tablosuyla doğrudan istatistiksel karşılaştırma amacıyla kullanılmamış, yalnızca ablasyon koşulları arasındaki aynı-1.030-örnekli iç karşılaştırma olarak raporlanmıştır. Genel olarak bulgu, daha fazla fakat farklı kaynak/etiket semantiği taşıyan eğitim verisinin otomatik olarak daha iyi genelleme sağlamadığını düşündürmektedir.

Veri seti	Twitter-only Macro-F1	Twitter + PhraseBank Macro-F1	PhraseBank farkı
İç test (N=2.386)	0,8810	0,8679	-0,0132
Reuters (N=5.000)	0,6465	0,6305	-0,0160
S&P 500 ablasyon (N=1.030)	0,7989	0,7968	-0,0021

5. TARTIŞMA

5.1. Hedef Veri Setine Özgü İnce Ayarın Etkisi

İç test sonuçları, hedef veri setine özgü ince ayarın güçlü etkisini açık biçimde göstermektedir. Hazır FinBERT'in 0,6794 Macro-F1 değeri aynı hedef veri setinde fine-tuning sonrasında 0,8512'ye yükselmiştir. Bununla birlikte kaynak-ablasyonu daha fazla etiketli verinin otomatik kazanç sağlamadığını göstermiştir: RoBERTa'nın Twitter-only eğitimi 0,8810 Macro-F1 ile Twitter + PhraseBank koşulunun 0,8679 sonucunu aşmıştır. Bu iki bulgu birlikte değerlendirildiğinde kritik unsurun yalnız veri miktarı değil, hedef dağılım ve etiket politikasına uygun görev-özel öğrenme olduğu sonucuna ulaşılmaktadır.

RoBERTa'nın üstünlüğü yalnızca tek bir seed sonucuna dayanmamaktadır. Seed 123 ve 2024'te RoBERTa ile fine-tuned FinBERT arasındaki yaklaşık 0,03 Macro-F1 farkı hem paired bootstrap güven aralıklarında sıfırı dışlamış hem Holm-düzeltilmiş McNemar testinde anlamlı kalmıştır. Buna karşılık fine-tuned FinBERT ile BERT arasındaki fark iki seed'de de anlamlı değildir. Bu durum, fine-tuned FinBERT'in BERT'e göre numerik olarak daha yüksek ortalamaya sahip olmasına rağmen iki modelin örnek-bazlı başarı düzeylerinin yakın olduğunu; RoBERTa'nın ise daha net bir üstünlük sergilediğini göstermektedir.

5.2. Genelleme ve Alan Kayması

S&P 500 sonuçlarında RoBERTa'nın 0,8145 Macro-F1 ile ilk sırada kalması, ana veri setinde güçlü olan temsilin yakın alan dış testine aktarılabilirdiğini göstermektedir. Fine-tuned FinBERT 0,7723 ile hazır FinBERT'in 0,7521 sonucunu aşmış, ancak eşleştirilmiş testte bu fark istatistiksel olarak anlamlı bulunmamıştır. Reuters'ta ise hazır FinBERT 0,6866, RoBERTa 0,6388 ve fine-tuned FinBERT 0,6101 elde etmiştir. Original FinBERT'in

fine-tuned FinBERT'e Reuters üstünlüğü eşleştirilmiş McNemar-Holm ve bootstrap tarafından desteklenmiştir. Bu nedenle target fine-tuning, yakın dağılımda yararlı olabilirken daha uzak editoryal kaynakta alan-özel hazır modelin genelleme avantajını azaltabilmektedir.

Reuters sonuçları daha güçlü bir alan kayması örneğidir. Profesyonel ve editoryal Reuters haberleri, FinBERT'in finans alanı ön eğitimine daha yakın bir dil taşıırken hedef fine-tuning verisi kısa ve piyasa yönelimli sosyal medya örneklerine daha yakındır. Fine-tuned FinBERT'in Reuters Macro-F1'inin 0,6101'e düşmesi ve hazır FinBERT'in 0,6866 ile üstün kalması, görev-özel uyarlamasının bir tür dağılım uzmanlaşması yaratabildiğini göstermektedir. RoBERTa kaynak-ablasyonunda PhraseBank eklenmesinin Reuters performansını 0,6465'ten 0,6305'e düşürmesi de kaynak karışımının genelleme etkisinin doğrusal olmadığını desteklemektedir.

5.3. Tarafsız Sınıf ve Etiket Uyuşmazlığı

Fine-tuned FinBERT hata analizinde neutral sınıf hâlâ temel karar sınırındır. Modelde neutral → negative 75 ve neutral → positive 78 hata gözlenmiş; toplam 282 hatanın %54,3'ü bu iki yönden oluşmuştur. Bununla birlikte hazır FinBERT'in tarihsel internal neutral → negative sayısına kıyasla fine-tuning belirgin iyileşme sağlamaktadır. Hataların yaklaşık %77'sinin en az 0,90 güvenle üretilmesi, bazı örneklerin model açısından belirsiz olmaktan ziyade farklı etiket semantiği altında sistematik olarak farklı yorumlandığını düşündürmektedir. Bu nedenle neutral sınıf tartışması model kalitesi ile anotasyon politikası arasındaki etkileşim olarak ele alınmalıdır.

Bu nedenle hata analizi yalnızca model yanlışı olarak sunulmamalıdır. Bazı örneklerde iki etiket de farklı sentiment tanımları altında savunulabilir. Nihai tezde anotasyon yönergesinin açık biçimde verilmesi, belirsiz örneklerin ayrıca işaretlenmesi ve insan değerlendirciler arası uyumun raporlanması önerilmektedir.

5.4. Sentetik Verinin Yorumu

Sentetik veri üzerindeki 0,95-0,996 aralığındaki makro F1 değerleri ilk bakışta modellerin problemi neredeyse çözdüğünü düşündürülebilir. Ancak Reuters sonuçlarındaki belirgin düşüş, bu yorumun geçerli olmadığını göstermektedir. Sentetik örnekler genellikle

tek yönlü ve açık sınıf ipuçları içerir; gerçek haberlerde ise örtük etkiler, karşılaştırmalar, zaman bağlamı ve birden fazla olay bulunur.

Sentetik veri eğitim ve stres testi amacıyla yararlı olmakla birlikte, ana başarı kanıtı olarak kullanılmamalıdır. Sentetik set sonuçları gerçek dışı testlerle birlikte raporlanmalı ve veri üretim yöntemi ayrıntılı biçimde açıklanmalıdır.

5.5. Sıfır Örnekli Modellerden Elde Edilen Tamamlayıcı Bulgular

Tamamlayıcı sıfır örnekli deneylerin temel avantajı etiketli görev-özel eğitim verisine ihtiyaç duymamasıdır. Bu özellik hızlı prototipleme açısından yararlı olsa da genel NLI modelleri finansal olayların ekonomik etkisini ve veri setine özgü neutral karar sınırını öğrenmemiştir. Nitekim S&P 500 deneylerinde özellikle tarafsız sınıf performansı belirgin biçimde düşük kalmıştır.

Bu nedenle sıfır örnekli yaklaşım tezde ana model gruplarına eşdeğer bir alternatif olarak değil, etiketli veri bulunmadığında elde edilebilecek başlangıç düzeyini gösteren keşifsel bir analiz olarak yorumlanmıştır. Gelecek çalışmalarda finansal açıklama içeren hipotezler, çoklu şablon ortalaması ve az örnekli instruction-tuned modeller denenebilir. FinNLI sonuçlarında da genel alan NLI modellerinin finansal metinlere taşındığında belirgin performans kaybı göstermesi ve görev-özel ince ayarın iyileşme sağlaması, bu yorumla uyumludur (Magomere vd., 2025).

5.6. Araştırma Sorularının Yanıtlanması

Soru	Sonuç
AS1	Evet. Hazır FinBERT 0,6794 Macro-F1 üretirken aynı model hedef veri setinde ince ayarlandığında 0,8512'ye yükselmiştir. BERT, DistilBERT ve RoBERTa da hazır FinBERT'i belirgin biçimde aşmıştır.
AS2	Üç seed ortalamasında RoBERTa $0,8728 \pm 0,0068$ ile birinci, fine-tuned FinBERT $0,8480 \pm 0,0028$ ile ikinci, BERT $0,8396 \pm 0,0023$ ile üçüncü ve DistilBERT $0,8231 \pm 0,0028$ ile dördüncü olmuştur. RoBERTa'nın fine-tuned FinBERT'e üstünlüğü seed 123 ve 2024'te istatistiksel olarak desteklenmiştir.
AS3	Hayır. RoBERTa S&P 500 testinde 0,8145 Macro-F1 ile üstünlüğünü korurken Reuters'ta Original FinBERT 0,6866 ile birinci olmuştur. Fine-tuned FinBERT Reuters'ta 0,6101'e düşmüştür.
AS4	Evet. Neutral hata yönleri ve kaynak-ablasyonu, kaynak/etiket semantiğinin karar sınırlarını etkilediğini göstermiştir. Twitter-only RoBERTa iç testte birleşik Twitter+PhraseBank eğitiminden 0,0132 Macro-F1 daha yüksektir.
AS5	Sentetik sette Macro-F1 değerleri 0,9551–0,9957 aralığındayken Reuters'ta 0,5869–0,6866 aralığına düşmüştür. Sentetik performans gerçek dünya genellemesini belirgin biçimde fazla iyimser göstermektedir.

5.7. Bulguların Literatürle Karşılaştırılması

Hazır FinBERT'in iç testte hedef veri setine özel ince ayarlı modellerin gerisinde kalması ve aynı FinBERT'in hedef veri setinde yeniden ince ayarlandığında 0,6794'ten

0,8512 Macro-F1'e yükselmesi, alan uyarlamasının görev uyumuyla tamamlanması gerektiğini göstermektedir. Bu bulgu, domain adaptation literatüründeki alan ön eğitimi avantajıyla uyumludur; ancak RoBERTa'nın üç seed ortalamasında fine-tuned FinBERT'i geçmesi, domain-specific pretraining'in tek başına model seçiminde yeterli bir ölçüt olmadığını ortaya koymaktadır.

RoBERTa'nın iç test ve S&P 500 dış testindeki başarısı, Liu ve diğerlerinin (2019) optimize edilmiş ön eğitim sürecinin güçlü aktarım performansı sağladığı yönündeki bulgularıyla tutarlıdır. DistilBERT'in daha düşük olmakla birlikte FinBERT'in iç test sonucunu aşması ise Sanh ve diğerlerinin (2019) daha küçük modellerin önemli ölçüde performans koruyabildiği sonucunu desteklemektedir. BERT ve FinBERT'in görevler arasında değişen sıralaması, Peng ve diğerlerinin (2021) alan uyarlamasının değerinin göreve ve veri dağılımına bağlı olduğu yönündeki değerlendirmesiyle örtüşmektedir.

Tarafsız sınıfın veri setleri arasında farklı anlamlar taşıması, Loughran ve McDonald'ın (2011) finansal söz varlığının genel duygu sözlüklerinden farklı yorumlanması gerektiği yönündeki temel argümanını genişletmektedir. Financial PhraseBank (Malo ve diğerleri, 2014) kurumsal haber cümlelerinin ekonomik etkisini merkeze alırken, bu çalışmanın ana veri seti kısa ve piyasa yönelimli metinleri içermektedir. Bu nedenle tarafsızdan negatife hataların yalnızca model yetersizliği değil, etiket semantiği ve veri kaynağı arasındaki uyumsuzlukla birlikte değerlendirilmesi gerekir. Varlık düzeyli duygu yaklaşımını öneren Tang ve diğerleri (2023) de tek bir cümle etiketinin hedefe bağlı farklı etkileri maskeleyebileceğini göstermektedir. Kaynak-ablasyon sonucu da aynı çerçeveyi desteklemektedir: Financial PhraseBank gibi kurumsal haber cümlelerinin Twitter tabanlı hedef göreve eklenmesi, RoBERTa için iç test ve Reuters'ta otomatik bir kazanç üretmemiştir. Bu bulgu veri kaynağının yalnız hacim değil, etiket semantiği ve metin türü bakımından da uyumlu olması gerektiğini göstermektedir.

5.8. Hipotezlerin Değerlendirilmesi

Hipotez	Karar	Gerekçe
H1	Desteklendi	Hazır FinBERT 0,6794 Macro-F1 üretirken fine-tuned FinBERT 0,8512'ye çıkmış; BERT, DistilBERT ve RoBERTa da baseline'ı aşmıştır.

Hipotez	Karar	Gerekeçe
H2	Desteklendi	RoBERTa üç seed ortalamasında $0,8728 \pm 0,0068$ Macro-F1 ile en yüksek sonucu vermiş ve fine-tuned FinBERT'e karşı seed 123/2024 eşleştirilmiş testlerinde anlamlı üstünlük göstermiştir.
H3	Desteklendi	İç test/S&P sıralaması Reuters'ta değişmiş; hazır FinBERT 0,6866 ile fine-tuned FinBERT 0,6101 ve RoBERTa 0,6388'i aşmıştır.
H4	Desteklendi	Neutral hata örüntüleri ile RoBERTa kaynak-ablasyonu, kaynak ve etiket semantiğinin model davranışını etkilediğini göstermiştir.
H5	Desteklendi	Sentetik sette tüm modellerin Macro-F1 değerleri gerçek S&P 500 ve Reuters dış testlerinden daha yüksek gerçekleşmiştir.

6. SONUÇ VE ÖNERİLER

6.1. Genel Sonuç

Bu tez, finansal duygu analizinde hazır alan-özel FinBERT modeli, hedef veri setine ince ayarlı FinBERT ve hedef veri setine ince ayarlı BERT, DistilBERT ve RoBERTa modellerini karşılaştırmıştır. Hazır FinBERT'in 0,6794 Macro-F1 değeri hedef fine-tuning sonrasında 0,8512'ye yükselmiş; RoBERTa seed 42'de 0,8651 ve üç seed ortalamasında $0,8728 \pm 0,0068$ ile en güçlü iç test modelidir. Fine-tuned FinBERT S&P 500'de 0,7723, sentetik sette 0,9746 ve Reuters'ta 0,6101 Macro-F1 elde etmiştir. Reuters'ta hazır FinBERT'in 0,6866 ile fine-tuned sürümden anlamlı biçimde üstün olması, fine-tuning kazancının kaynaklar arasında garanti olmadığını göstermiştir. RoBERTa kaynak-ablasyonunda Twitter-only eğitim 0,8810 Macro-F1 ile Twitter + PhraseBank koşulunu 0,0132 puan aşmıştır. Böylece çalışma, model mimarisi kadar hedefe özgü fine-tuning, veri kaynağı ve etiket semantiğinin birlikte belirleyici olduğunu ortaya koymaktadır.

Çalışmanın ana sonucu, finansal duygu analizinde tek bir modelin evrensel olarak en iyi kabul edilemeyeceğidir. RoBERTa hedefe benzer iç testte ve S&P 500'de güçlü iken Reuters'ta hazır FinBERT yeniden birinci olmuştur. Fine-tuned FinBERT'in Reuters düşüşü, hedefe uyarılmanın uzak kaynaktan genelleme kaybı yaratabileceğini göstermektedir. Kaynak-ablasyonu ise daha fazla heterojen eğitim verisinin performansı otomatik artırmadığını ortaya koymuştur. Verimlilik açısından DistilBERT en yüksek CPU throughput değerine sahipken RoBERTa en güçlü performans profilini sunmuştur.

6.2. Uygulayıcılara Öneriler

- Kısa piyasa başlıkları ve hedef veri setine benzeyen içeriklerde RoBERTa ince ayarı öncelikli aday olarak değerlendirilmelidir; çoklu seed ve eşleştirilmiş testler bu tercihi desteklemektedir.
- Profesyonel finans haberlerinde hazır FinBERT ayrı bir temel model olarak korunmalı; hedefe fine-tuned sürümün performansının aynı kaynağa genelleneceği varsayılmamalıdır. Dış test ve eşleştirilmiş örnek-bazlı karşılaştırmalar model seçiminin parçası olmalıdır.
- Sınıf dengesizliği bulunan veri setlerinde model seçimi yalnızca doğrulukla yapılmamalı; makro F1 ve sınıf bazlı ölçütler raporlanmalıdır.
- Üretim öncesinde zaman, kaynak ve sektör bazlı dış testler uygulanmalı; performans yanında throughput ve gecikme ölçümleri de kullanım senaryosuna göre raporlanmalıdır.
- Tarafsız sınıf için açık anotasyon yönergeleri, belirsiz/mixed kategorisi ve yüksek güvenli yanıtların manuel incelemesi önerilmektedir.

6.3. Gelecek Çalışmalar

- Fine-tuned FinBERT ve RoBERTa için dış testlerde birden fazla seed ve eksiksiz eşleştirilmiş prediction dosyalarıyla tekrarlı güvenilirlik analizlerinin genişletilmesi.
- Kaynak-ablasyonunun seed 42 ile sınırlı kalmaması; Twitter-only ve Twitter + Financial PhraseBank koşullarının birden fazla seed ile tekrarlanması ve kaynak ağırlıklandırma stratejilerinin sınanması.
- Anotatörler arası uyumun bağımsız insan anotasyonu ve Cohen kappa/Krippendorff alpha gibi ölçütlerle raporlanması.
- Kalibrasyon (ECE), güvenilirlik diyagramları ve yüksek güvenli yanlış tahminlerin daha sistematik incelenmesi.
- Çok dilli ve özellikle Türkçe finansal haber veri setlerinin oluşturulması ve kaynaklar arası domain shift analizinin genişletilmesi.
- Fine-tuned FinBERT ve diğer modeller için dış testlerde de çoklu seed veya yeniden örneklemeli güvenilirlik analizlerinin uygulanması.
- CPU çıkarım hızına ek olarak enerji tüketimi, bellek kullanımı ve toplam eğitim maliyetinin standart bir donanım protokolünde ölçülmesi.

KAYNAKÇA

Araci, D. (2019). FinBERT: Financial sentiment analysis with pre-trained language models. arXiv:1908.10063.

Balakrishnan, S., Fang, Y., & Zhu, X. (2022). Exploring robustness of prefix tuning in noisy data: A case study in financial sentiment analysis. *Proceedings of FinNLP 2022*.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT*, 4171–4186.

Dong, Z., Fan, X., & Peng, Z. (2024). FNSPID: A comprehensive financial news dataset in time series. *arXiv:2402.06698*.

Guo, Y., Hu, C., & Yang, Y. (2023). Predict the future from the past? On the temporal data distribution shift in financial sentiment classifications. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 1029–1038.

Kirtac, K., & Germano, G. (2024). Enhanced financial sentiment analysis and trading strategy development using large language models. *Proceedings of WASSA 2024*.

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). RoBERTa: A robustly optimized BERT pretraining approach. *arXiv:1907.11692*.

Loughran, T., & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. *The Journal of Finance*, 66(1), 35–65.

Luo, F. (2026). From financial sentiment classification to return predictability: A QLoRA benchmark of large language models. *arXiv:2608.04200 [Preprint]*.

Magomere, J., Kochkina, E., Mensah, S., Kaur, S., & Smiley, C. H. (2025). FinNLI: Novel dataset for multi-genre financial natural language inference benchmarking. *Findings of the Association for Computational Linguistics: NAACL 2025*, 4545–4568.

Malo, P., Sinha, A., Korhonen, P., Wallenius, J., & Takala, P. (2014). Good debt or bad debt: Detecting semantic orientations in economic texts. *Journal of the Association for Information Science and Technology*, 65(4), 782–796.

Peng, B., Chersoni, E., Hsu, Y.-Y., & Huang, C.-R. (2021). Is domain adaptation worth your investment? Comparing BERT and FinBERT on financial tasks. Proceedings of the First Workshop on Economics and Natural Language Processing.

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter. arXiv:1910.01108.

Takala, P., Malo, P., Sinha, A., & Ahlgren, O. (2014). Gold-standard for topic-specific sentiment analysis of economic texts. Proceedings of LREC 2014.

Tang, Y., Yang, Y., Huang, A., Tam, A., & Tang, J. (2023). FinEntity: Entity-level sentiment classification for financial texts. Proceedings of EMNLP 2023.

Yang, Y., Uy, M. C. S., & Huang, A. (2020). FinBERT: A pretrained language model for financial communications. arXiv:2006.08097.

Efron, B., & Tibshirani, R. J. (1993). An introduction to the bootstrap. Chapman & Hall/CRC.

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. Psychometrika, 12, 153–157.

EK A. DENEY DOSYALARI

Tezde kullanılan temel deney akışı 00_setup_requirements.ipynb ile başlamış; 08_finetune_finbert_target_dataset, 10_multiseed_training, 11_statistical_significance_tests, 12_roberta_dataset_ablation, 13_model_dataset_class_analysis, 14_extended_error_analysis, 15_model_efficiency_analysis, 16_finetuned_finbert_external_evaluation_v2 ve 17_external_statistical_significance_tests_v3 notebooklarıyla genişletilmiştir. Notebooklar veri hazırlama, temel model, fine-tuning, dış test, çoklu seed, kaynak-ablasyonu, istatistiksel güvenilirlik, hata analizi ve verimlilik aşamalarını kapsar.

EK B. DENEY AYRINTILARI, TOPLU SONUÇLAR VE HATA ANALİZİ

Bu ek, tez danışmanlığı değerlendirmesinde istenen deney ayrıntılarını mevcut proje dosyalarından çıkarılabildiği ölçüde tek yerde toplar. Sayısal değerler proje klasöründeki

split, checkpoint, notebook çıktısı ve prediction CSV dosyalarından alınmıştır; kaydı bulunmayan bilgiler açık sınırlılık olarak belirtilmiştir.

B.1. Deney ve Ortam Ayrıntıları

Başlık	Ayrıntı
Ana veri	16.777 örnek; Twitter Financial News Sentiment 11.931, Financial PhraseBank 4.846.
Split	Mevcut split dosyaları: train 12.950, validation 1.432, test 2.386. Toplam ana havuza göre yaklaşık %77,19 / %8,54 / %14,22.
Sınıf dağılımı	Ana havuz: negative 2.393 (%14,26), neutral 10.623 (%63,32), positive 3.761 (%22,42).
Eğitim ayarları	Seed 42; epoch 4; learning rate 2e-5; train batch size 16; eval batch size 32; max length 128; weight decay 0,01; class weights açık.
Model sürümleri	ProsusAI/finbert; bert-base-uncased; distilbert-base-uncased; roberta-base; zero-shot için BART-large-MNLI ve NLI/MNLI model ailesi.
Yazılım/donanım	Python 3.14.2, PyTorch 2.11.0+cpu, Transformers 5.8.1, Datasets 4.5.0, scikit-learn 1.8.0. Notebook çıktılarında CUDA false ve cihaz CPU olarak görünmektedir.
İstatistiksel güvenilirlik	BERT, DistilBERT, RoBERTa ve fine-tuned FinBERT için seed 42, 123 ve 2024 mean ± std; internal seed 123/2024 prediction dosyalarında McNemar + Holm ve 5.000 tekrarlı paired bootstrap. Dış testte doğrulanmış eşleşmelerde S&P Original FinBERT vs FT FinBERT ve Reuters Original FinBERT vs FT FinBERT analiz edildi; uyumsuz/eksik dosya çiftleri sonuçlara dahil edilmedi.

B.2. Veri Seti Büyüklükleri ve Sınıf Dağılımları

Veri seti	N	Negative	Neutral	Positive
Ana havuz	16.777	2.393	10.623	3.761
Train	12.950	1.820	8.137	2.993
Validation	1.432	215	929	288
Test	2.386	358	1.549	479
S&P 500 dış test	1.060	323	339	398
Sentetik test	3.000	1.000	1.000	1.000
Reuters dış test	5.000	1.579	1.146	2.275

B.3. Tek Sonuç Tablosu

Tabloda P-makro ve R-makro sırasıyla makro precision ve makro recall değerlerini gösterir. Internal testte Original FinBERT satırı notebook çıktısından alınmış ve n=2.387 olarak raporlanmıştır; güncel split dosyasında test satır sayısı 2.386'dır.

Veri	Model	N	Acc	P-makro	R-makro	F1-makro	F1-neg	F1-neu	F1-pos
Internal Twitter test	RoBERTa-base	2386	0.8906	0.8511	0.8814	0.8651	0.8329	0.9210	0.8415
Internal Twitter test	BERT-base-uncased	2386	0.8722	0.8280	0.8487	0.8378	0.7699	0.9092	0.8344
Internal Twitter test	DistilBERT-base-uncased	2386	0.8583	0.8136	0.8308	0.8218	0.7633	0.8989	0.8032
Internal Twitter test	Original FinBERT	2387	0.7323	0.6648	0.7154	0.6794	0.6044	0.8060	0.6279
S&P 500 external test	RoBERTa-base	1060	0.8132	0.8249	0.8138	0.8145	0.8331	0.7768	0.8338
S&P 500 external test	BERT-base-uncased	1060	0.7557	0.7714	0.7554	0.7549	0.7448	0.7458	0.7741
S&P 500 external test	Original FinBERT	1060	0.7519	0.7531	0.7567	0.7521	0.7663	0.7482	0.7418
S&P 500 external test	DistilBERT-base-uncased	1060	0.7519	0.7669	0.7510	0.7510	0.7392	0.7378	0.7759
Synthetic financial news	RoBERTa-base	3000	0.9957	0.9957	0.9957	0.9957	0.9945	0.9970	0.9955
Synthetic financial news	BERT-base-uncased	3000	0.9743	0.9748	0.9743	0.9742	0.9646	0.9779	0.9802
Synthetic financial news	DistilBERT-base-uncased	3000	0.9583	0.9591	0.9583	0.9581	0.9450	0.9710	0.9582
Synthetic financial news	Original FinBERT	3000	0.9550	0.9568	0.9550	0.9551	0.9373	0.9578	0.9701
Reuters external test	Original FinBERT	5000	0.6966	0.6882	0.7021	0.6866	0.7483	0.5820	0.7295
Reuters external test	RoBERTa-base	5000	0.6268	0.7464	0.6723	0.6388	0.7269	0.5412	0.6484
Reuters external test	BERT-base-uncased	5000	0.6034	0.7165	0.6451	0.6131	0.6790	0.5245	0.6359

Veri	Model	N	Acc	P-makro	R-makro	F1-makro	F1-neg	F1-neu	F1-pos
Reuters external test	DistilBERT-base-uncased	5000	0.5766	0.6883	0.6201	0.5869	0.6588	0.5052	0.5966
S&P 500 zero-shot	BART-large-MNLI zero-shot	1060	0.6594	0.7043	0.6479	0.5580	0.8101	0.1199	0.7440
S&P 500 zero-shot	RoBERTa-base NLI zero-shot	1060	0.6085	0.7423	0.5966	0.4913	0.7523	0.0233	0.6982
S&P 500 zero-shot	BERT-base MNLI zero-shot	1060	0.5057	0.3951	0.4930	0.4033	0.5963	0.0058	0.6077
S&P 500 zero-shot	DistilBERT-base MNLI zero-shot	1060	0.4679	0.5502	0.4760	0.3880	0.5663	0.0776	0.5201
Internal Twitter test	Fine-tuned FinBERT	2386	0.8818	0.8405	0.8632	0.8512	0.7968	0.9157	0.8410
S&P 500 external test	Fine-tuned FinBERT	1060	0.7726	0.7945	0.7721	0.7723	0.7636	0.7538	0.7995
Synthetic financial news	Fine-tuned FinBERT	3000	0.9747	0.9750	0.9747	0.9746	0.9658	0.9876	0.9704
Reuters external test	Fine-tuned FinBERT	5000	0.5984	0.7207	0.6474	0.6101	0.6937	0.5277	0.6090
Ablation internal test	RoBERTa Twitter-only	2386	0.9036	0.8662	0.8981	0.8810	0.8453	0.9297	0.8681
Ablation internal test	RoBERTa Twitter+PhraseBank	2386	0.8948	0.8578	0.8813	0.8679	0.8217	0.9250	0.8568
Ablation Reuters	RoBERTa Twitter-only	5000	0.6356	0.7402	0.6781	0.6465	0.7365	0.5460	0.6570
Ablation Reuters	RoBERTa Twitter+PhraseBank	5000	0.6178	0.7363	0.6648	0.6305	0.7307	0.5315	0.6294
Ablation S&P 500 (N=1030)	RoBERTa Twitter-only	1030	0.7981	0.8149	0.7973	0.7989	0.8042	0.7635	0.8290
Ablation S&P 500 (N=1030)	RoBERTa Twitter+PhraseBank	1030	0.7951	0.8076	0.7964	0.7968	0.8162	0.7614	0.8128

B.4. Anotasyon Yöntemi ve Sınırlılık

S&P 500 setinde haber başlıkları önce FinBERT ile etiketlenmiş, ardından dengeli anotasyon batchleri hazırlanmıştır. Batch yapısında final_label, ChatGPT destekli açıklama, güven ve not alanları bulunmaktadır. Reuters seti 5.000 örnek olarak hazırlanmış; final_label alanı değerlendirme etiketi olarak kullanılmıştır. Kullanılan yönerge özetle positive için yatırımcı açısından olumlu beklenti/gerçekleşme, negative için olumsuz beklenti/risk/kayıp, neutral için olgusal veya yönü belirsiz haber tanımlarını kullanır. Birden fazla hedefte çatışan sentiment varsa target_entity doldurulması veya plain sentiment için örneğin ayrılması önerilmiştir.

Mevcut dosyalarda kaç insan anotatörün görev aldığı ve anotatörler arası uyumun Cohen kappa veya Krippendorff alpha gibi bir ölçütle hesaplandığına ilişkin tamamlanmış kayıt bulunmamaktadır. Bu nedenle çalışma, anotasyon güvenilirliğini ölçülmüş bir bulgu olarak değil, sınırlılık ve gelecek çalışma gereksinimi olarak raporlamalıdır.

B.5. Confusion Matrix ve Hata Analizi

Model/test	Neutral -> negative	Oran
Internal RoBERTa	67 / 1.549	0,0433
Internal BERT	84 / 1.549	0,0542
Internal DistilBERT	82 / 1.549	0,0529
S&P 500 Original FinBERT	36 / 339	0,1062
S&P 500 RoBERTa	19 / 339	0,0560

Model/test	Neutral -> negative	Oran
S&P 500 BERT	15 / 339	0,0442
S&P 500 DistilBERT	16 / 339	0,0472
Internal Fine-tuned FinBERT	75 / 1.549	0,0484

Örnek hata başlıkları özellikle karışık sinyal taşıyan veya piyasa yönü açık olmayan haberlerde yoğunlaşmaktadır: 'S&P 500 Gains and Losses Today: NetApp and GM Rise; Hormel and Las Vegas Sands Fall' hem yükselen hem düşen hisseleri içerdiği için neutral kabul edilmiştir, ancak FinBERT negative tahmin etmiştir. 'Strong corporate earnings are helping the US avoid a recession - but there are 2 big risks facing markets...' olumlu ve riskli unsurları birlikte taşıdığı için neutral/karışık kabul edilmiştir. 'AP Explains: What resignation of New Zealand's leader means' ise finansal yön içermeyen siyasi/açıklayıcı bir başlık olmasına rağmen negative tahmin edilmiştir.

B.6. Zero-Shot ve Sentetik Veri Yorumu

Zero-shot deneyleri tamamlanmış ve tek sonuç tablosuna eklenmiştir. BART-large-MNLI S&P 500 üzerinde 0,6594 doğruluk ve 0,5580 makro F1 elde ederek zero-shot modeller içinde en iyi sonucu vermiştir. Buna rağmen neutral sınıf F1'i 0,1199 düzeyinde kalmıştır; RoBERTa-base NLI, BERT-base MNLI ve DistilBERT-base MNLI sürümlerinde neutral F1 daha da düşüktür. Bu bulgu, NLI tabanlı zero-shot yaklaşımın finansal neutral tanımını öğrenmeden güçlü bir alternatif olamadığını göstermektedir.

Sentetik veri sonuçları da tabloya eklenmiştir. Tüm modeller sentetik sette 0,9551 ile 0,9957 arasında makro F1 üretmiştir. Bu yüksek değerler, sentetik örneklerde duygu ipuçlarının açık olmasından kaynaklanabilir; bu nedenle sentetik test gerçek Reuters ve S&P 500 dış testlerinin yerine geçmemeli, yalnızca kontrollü bir stres testi olarak yorumlanmalıdır.

B.7. Fine-Tuned FinBERT ve Çoklu Tohum Sonuçları

Fine-tuned FinBERT seed 42 iç testinde 0,8818 accuracy, 0,8512 Macro-F1 ve 0,8829 Weighted-F1 elde etmiştir. Üç seed ortalamasında $0,8480 \pm 0,0028$ Macro-F1 üretmiştir. Dış testlerde S&P 500 0,7723, sentetik 0,9746 ve Reuters 0,6101 Macro-F1 elde edilmiştir. S&P 500'de hazır FinBERT'e karşı +0,0201 sayısal fark istatistiksel olarak anlamlı bulunmazken, Reuters'ta hazır FinBERT'in +0,0765 üstünlüğü güçlü biçimde desteklenmiştir.

Model	n seed	Macro-F1 mean $\pm$ std	Accuracy mean $\pm$ std
RoBERTa-base	3	$0,8728 \pm 0,0068$	$0,8975 \pm 0,0059$
Fine-tuned FinBERT	3	$0,8480 \pm 0,0028$	$0,8790 \pm 0,0025$
BERT-base-uncased	3	$0,8396 \pm 0,0023$	$0,8736 \pm 0,0021$
DistilBERT-base-uncased	3	$0,8231 \pm 0,0028$	$0,8601 \pm 0,0028$

B.8. İstatistiksel Test Özeti

Seed 123 ve 2024 internal eşleştirilmiş testlerinde RoBERTa'nın fine-tuned FinBERT'e üstünlüğü iki yöntemle de desteklenmiştir. Dış testte S&P 500 Original FinBERT vs fine-tuned FinBERT karşılaştırması anlamlı değildir (Holm $p=0,1678$; Original-FT $\Delta F1=-0,0201$; %95 GA $[-0,0492; 0,0080]$). Reuters'ta Original FinBERT vs fine-tuned FinBERT farkı anlamlıdır ($\Delta F1=+0,0765$; Holm $p\approx 1,37\times 10^{-32}$; %95 GA $[0,0610; 0,0923]$). S&P RoBERTa eşleştirmesinde yanlış RoBERTa prediction girdisi tespit edildiği, Reuters RoBERTa prediction girdisi ise bulunmadığı için bu iki çift dış istatistiksel sonuç olarak raporlanmamıştır.

B.9. Model Verimliliği

1.000 internal test örneği, batch size 32 ve üç CPU tekrarıyla yapılan benchmarkta DistilBERT 70,30 örnek/s ve 14,23 ms/örnek ile en hızlı modeldir. BERT 31,37, RoBERTa 35,91, Original FinBERT 30,81 ve fine-tuned FinBERT 28,84 örnek/s hızında ölçülmüştür. Ölçümler kullanılan donanım ve yazılım ortamına özgü olduğundan mutlak hızdan çok modeller arası göreceli farklar yorumlanmıştır.

B.10. RoBERTa Kaynak-Ablasyon Sonuçları

12_roberta_dataset_ablation notebooku tamamlanmıştır. Seed 42 altında Twitter-only eğitim iç testte 0,8810 Macro-F1, Twitter + Financial PhraseBank eğitimi 0,8679 Macro-F1 elde etmiştir (PhraseBank farkı -0,0132). Reuters'ta aynı koşullar 0,6465 ve 0,6305 (fark -0,0160) üretmiştir. Ablasyon S&P çıktısı 1.030 örnek kullanmıştır ve ana doğrulanmış 1.060 örnekli S&P değerlendirmesinden farklı olduğu için yalnız aynı 1.030 örnek üzerindeki iki ablasyon koşulunu karşılaştırmak amacıyla kullanılmıştır.

B.11. Dış Test İstatistiksel Doğrulama ve Girdi Kalitesi

Notebook 17 çıktıları veri-girdisi düzeyinde ayrıca kontrol edilmiştir. S&P 500 RoBERTa vs fine-tuned FinBERT satırında RoBERTa Macro-F1=0,4913 görülmesi, ana S&P RoBERTa sonucu olan 0,8145 ile açıkça uyumsuzdur ve sıfır örnekli RoBERTa-NLI sonucuna karşılık gelmektedir. Bu nedenle bu satır yanlış prediction dosyası eşleşmesi olarak değerlendirilmiş ve tezin bilimsel sonuçlarından çıkarılmıştır. Reuters RoBERTa karşılaştırması giriş dosyası eksikliği nedeniyle zaten atlanmıştır. Bu kalite kontrolü, yalnız metrik üretmenin değil, eşleştirilen prediction dosyalarının kimliğini ve N değerini doğrulamanın da zorunlu olduğunu göstermektedir.