

TEZ ÇALIŞMASI ÖZETİ

Serkan Kaymak
Yazılım Mühendisliği Tezli Yüksek Lisans Programı
Danışman: Dr. Öğr. Üyesi Mansur Alp Toçoğlu

Bu çalışmada finansal duygu sınıflandırmasında alan-özgü ön eğitim, hedef veri setine özgü ince ayar, model mimarisi ve veri kaynağının genelleme performansına etkisi karşılaştırmalı olarak incelenmiştir.

Son Tamamlanan Çalışmalar

Bu hafta sonu tezde açık kalan deneysel doğrulama ve son kontrol adımlarını tamamladım. Özellikle fine-tuned FinBERT'in dış testleri, kaynak-bileşimi ablasyonu ve dış test istatistiklerinin tezde eksiksiz ve tutarlı biçimde yer almasına odaklandım.

- Fine-tuned FinBERT'i S&P 500, Reuters ve sentetik veri setlerinde yeniden değerlendirdim. S&P 500 yükleyicisinde önce 1.030 örneğe düşen okuma problemi giderildi ve ana dış test 1.060 örnek üzerinde doğrulandı. Nihai Macro-F1 değerleri S&P 500'de 0,7723, Reuters'ta 0,6101 ve sentetik sette 0,9746 oldu.
- Dış testler için eşleştirilmiş istatistiksel doğrulama ekledim. Original FinBERT ile fine-tuned FinBERT arasındaki fark S&P 500'de anlamlı bulunmadı (Holm $p=0,1678$); Reuters'ta ise Original FinBERT lehine +0,0765 Macro-F1 farkı güçlü biçimde anlamlı bulundu.
- İstatistik notebookunda S&P RoBERTa için otomatik seçilen prediction dosyasının yanlış olduğunu fark ettim. 0,4913 değeri ana RoBERTa S&P sonucu 0,8145 ile uyuşmadığı ve zero-shot RoBERTa-NLI çıktısına karşılık geldiği için bu karşılaştırmayı bilimsel sonuçlara dahil etmedim. Reuters RoBERTa için uygun eşleştirilmiş prediction girdisi bulunmadığından o çift de raporlanmadı.
- RoBERTa kaynak-bileşimi ablasyonunu tamamladım. Seed 42 koşulunda Twitter-only eğitim iç testte 0,8810, Twitter + Financial PhraseBank eğitimi 0,8679 Macro-F1 verdi. Reuters'ta da Twitter-only 0,6465 ile 0,6305 olan birleşik koşulun üzerinde kaldı. Bu sonuç yardımcı verinin yalnız miktarının değil, kaynak ve etiket semantiği uyumunun da önemli olduğunu gösterdi.
- Fine-tuned FinBERT hata analizini güncelledim. İç testte 282 hata bulundu; neutral→positive 78 ve neutral→negative 75 ile en büyük iki hata yönü oldu. Hataların %77,0'ının en az 0,90 güvenle üretilmesi, sorunun yalnız düşük güvenli belirsizlikten kaynaklanmadığını gösterdi.
- Tezin yöntem, bulgular, tartışma, sonuç, sınırlılıklar ve ek bölümlerini bu yeni sonuçlara göre yeniden güncelledim. Karışıklık matrisi görsellerini de aynı akademik gri tonlu stile getirerek tez genelindeki görsel dili sadeleştirdim.

1. Çalışmanın kapsamı

- Ana veri havuzu 16.777 örnek: Twitter Financial News Sentiment 11.931 + Financial PhraseBank 4.846. Kaydedilmiş splitter: 12.950 train, 1.432 validation, 2.386 test.
- Karşılaştırılan ana modeller: Original ProsusAI/FinBERT, target-fine-tuned FinBERT, BERT-base-uncased, DistilBERT-base-uncased ve RoBERTa-base.
- BERT, DistilBERT, RoBERTa ve fine-tuned FinBERT deneyleri seed 42, 123 ve 2024 ile tekrarlanmış; sonuçlar ortalama $\pm$ standart sapma ile raporlanmıştır.
- Dış genelleme değerlendirmeleri doğrulanmış S&P 500 (N=1.060), Reuters (N=5.000) ve sentetik finansal haber (N=3.000) veri setlerinde gerçekleştirilmiştir.

- Tamamlayıcı olarak NLI/MNLI tabanlı zero-shot modeller, McNemar + Holm düzeltmesi, 5.000 tekrarlı paired bootstrap, kaynak-bileşimi ablasyonu, hata geçişleri ve CPU inference verimliliği incelenmiştir.

2. Ana sonuçlar

Model	Seed 42 iç test Macro-F1	3-seed Macro-F1 mean $\pm$ std
RoBERTa-base	0,8651	0,8728 $\pm$ 0,0068
Fine-tuned FinBERT	0,8512	0,8480 $\pm$ 0,0028
BERT-base-uncased	0,8378	0,8396 $\pm$ 0,0023
DistilBERT-base-uncased	0,8218	0,8231 $\pm$ 0,0028
Original FinBERT	0,6794	-

İç testte hedefe özgü ince ayar belirgin kazanç sağlamaktadır. FinBERT'in hazır sürümü 0,6794 Macro-F1 iken hedef veri setine ince ayarlanmış sürümü 0,8512'ye çıkmıştır. Buna rağmen RoBERTa hem seed 42'de hem de üç-seed ortalamasında en güçlü modeldir.

3. Dış genelleme ve sıralama değişimi

Veri	Original FinBERT	RoBERTa	Fine-tuned FinBERT	Ana yorum
S&P 500 (N=1.060)	0,7521	0,8145	0,7723	RoBERTa birinci; FT FinBERT hazır sürümü sayısal olarak aşar.
Reuters (N=5.000)	0,6866	0,6388	0,6101	Original FinBERT birinci; model sıralaması değişir.
Sentetik (N=3.000)	0,9551	0,9957	0,9746	Çok kolay/açık sinyalli kontrol seti; gerçek genelleme kanıtı olarak tek başına yeterli değil.

Temel bulgu, tek bir "evrensel en iyi model" bulunmamasıdır. Hedefe benzer kısa/piyasa yönelimli metinlerde RoBERTa öne çıkarken, Reuters gibi daha editoryal finans dilinde alan-özümlü hazır FinBERT yeniden avantaj kazanmaktadır.

4. Eşleştirilmiş istatistiksel doğrulama

- Internal seed 123: RoBERTa - fine-tuned FinBERT Δ Macro-F1=+0,0294; Holm p=0,000617; %95 GA [0,0138; 0,0446].
- Internal seed 2024: RoBERTa - fine-tuned FinBERT Δ Macro-F1=+0,0312; Holm p=0,001410; %95 GA [0,0162; 0,0462].
- S&P 500 Original FinBERT - fine-tuned FinBERT: Δ Macro-F1=-0,0201; Holm p=0,1678; %95 GA [-0,0492; 0,0080]. Fark anlamlı değildir.
- Reuters Original FinBERT - fine-tuned FinBERT: Δ Macro-F1=+0,0765; Holm p $\approx$ 1,37 $\times$ 10⁻³²; %95 GA [0,0610; 0,0923]. Original FinBERT üstünlüğü güçlü biçimde desteklenmektedir.

Dış testlerde uygulanan eşleştirilmiş istatistiksel analizlerde prediction dosyalarının kimliği ayrıca kontrol edilmiştir. S&P 500 RoBERTa karşılaştırmasında elde edilen 0,4913 Macro-F1 değerinin ana RoBERTa sonucu olan 0,8145 ile uyuşmadığı ve zero-shot RoBERTa-NLI çıktısıyla aynı olduğu görülmüştür. Bu nedenle söz konusu eşleştirme geçersiz kabul edilerek bilimsel değerlendirmeye dahil edilmemiştir. Reuters RoBERTa için aynı formatta prediction girdisi bulunmadığından ilgili eşleştirilmiş test raporlanmamıştır.

5. RoBERTa kaynak-bileşimi ablasyonu

Veri	Twitter-only	Twitter + PhraseBank	PhraseBank farkı
İç test (N=2.386)	0,8810	0,8679	-0,0132
Reuters (N=5.000)	0,6465	0,6305	-0,0160
S&P ablasyon (N=1.030)	0,7989	0,7968	-0,0021

Seed 42 kontrollü ablasyonunda Financial PhraseBank eklemek iç test ve Reuters performansını artırmamıştır. Bu sonuç “daha fazla veri her zaman daha iyidir” yorumunu desteklemez; kaynak ve etiket semantiği uyumunun veri miktarı kadar önemli olduğunu düşündürür. Ablasyon S&P çıktısı N=1.030 olduğundan ana doğrulanmış N=1.060 S&P sonuçlarıyla doğrudan kıyaslanmamalıdır.

6. Hata analizi ve neutral sınıf

Gerçek → Tahmin	Hata	Pay
neutral → positive	78	%27,66
neutral → negative	75	%26,60
negative → neutral	52	%18,44
positive → neutral	52	%18,44
positive → negative	17	%6,03
negative → positive	8	%2,84

Fine-tuned FinBERT iç testte toplam 282 hata yapmıştır. Hataların 217’si (%77,0) en az 0,90, 196’sı (%69,5) en az 0,95 ve 137’si (%48,6) en az 0,99 güvenle üretilmiştir. Bu durum hataların yalnızca düşük güvenli belirsiz örneklerden kaynaklanmadığını, etiket semantiği/karar sınırı uyumsuzluğunun da önemli olduğunu göstermektedir.

7. Verimlilik

Model	Parametre (M)	CPU örnek/s	ms/örnek	Internal Macro-F1
Original FinBERT	109,48	30,81	32,46	0,6794
Fine-tuned FinBERT	109,48	28,84	34,68	0,8512
BERT	109,48	31,37	31,88	0,8378
DistilBERT	66,96	70,30	14,23	0,8218
RoBERTa	124,65	35,91	27,85	0,8651

DistilBERT en hızlı ve en küçük modeldir; BERT’e göre yaklaşık 2,24× throughput sağlamaktadır. RoBERTa ise daha yüksek performans karşılığında daha büyük model boyutu taşımaktadır.

8. Sınırlılıklar ve değerlendirme notları

- Hazır FinBERT’in tarihsel iç test çıktısı 2.387 örnek, güncel kaydedilmiş test split’i ise 2.386 örnektir; bu tek örneklik fark karşılaştırmalarda açıkça belirtilmiştir.
- RoBERTa kaynak-bileşimi ablasyonu seed 42 ile yürütülmüştür; çoklu seed tekrarı bu ek analiz için yapılmamıştır.
- Ablasyonun S&P 500 çıktısı N=1.030, ana doğrulanmış S&P 500 dış testi ise N=1.060’tır. Bu nedenle ablasyon S&P sonuçları yalnız kendi iki eğitim koşulu arasında karşılaştırılmıştır.
- Dış eşleştirilmiş testlerde yanlış prediction girdisi tespit edilen S&P RoBERTa karşılaştırması ile prediction girdisi bulunmayan Reuters RoBERTa karşılaştırması istatistiksel sonuca dahil edilmemiştir.
- CPU inference ölçümleri tek donanım ortamında gerçekleştirilmiştir; mutlak hız değerleri farklı sistemlerde değişebilir.

9. Genel sonuç

Çalışmanın ana sonucu, hedefe özgü fine-tuning'in çok güçlü olmakla birlikte genelleme kazancının veri kaynağına bağlı olduğudur. Hazır FinBERT iç testte 0,6794 Macro-F1'den hedefe fine-tuning ile 0,8512'ye yükselmiş; ancak RoBERTa üç seed ortalamasında $0,8728 \pm 0,0068$ ile en güçlü model olarak kalmıştır. RoBERTa S&P 500'de 0,8145 ile birinciyken Reuters'ta hazır FinBERT 0,6866 ile yeniden ilk sıraya çıkmış ve fine-tuned FinBERT'e 0,0765 Macro-F1 üstünlüğü eşleştirilmiş testlerle desteklenmiştir. Ayrıca Twitter-only RoBERTa'nın Twitter + Financial PhraseBank koşulunu iç testte 0,0132 ve Reuters'ta 0,0160 Macro-F1 aşması, heterojen yardımcı verinin otomatik kazanç sağlamadığını ve kaynak/etiket semantiği uyumunun belirleyici olduğunu göstermektedir.