

FİNANSAL DUYGU ANALİZİ

Tez Savunması Konuşma Metni

Slaytlarla paralel, akıcı anlatım ve geçiş cümleleri

Serkan Kaymak

Ana sunum: Slayt 1–34 • Yaklaşık 18–22 dakika

Soru-cevap eki: Slayt 35–39

Nasıl kullanılır?

Ana hedef: Metni ezberlemek yerine her slaytın ana fikrini ve geçiş cümlesini sahiplen.

- Her slaytta önce ana sonucu söyle, sonra sayıyı veya kanıtı göster.
- Tablolarda bütün hücreleri okuma; yalnızca karşılaştırmayı ve çıkarımı vurgula.
- İç test ile dış test arasındaki farkı sunum boyunca ana hikâye olarak koru.
- Sınırlılıkları savunmacı bir tonda değil, bilimsel şeffaflık ve devam planının gerekçesi olarak anlat.
- Slayt 35–39'u ana akışta açma; yalnızca ilgili soru geldiğinde kullan.

Kısa prova planı

Aşama	Uygulama
1. prova	Metni kullanarak akışı öğren; süreye bakma.
2. prova	Slayta bakarak kendi cümleleriyle anlat; metni yalnızca takıldığında kontrol et.
3. prova	18–22 dakika hedefiyle zaman tut; tablo açıklamalarını kısalt.
Son prova	Açılış, araştırma soruları, Reuters bulgusu ve kapanışı kesintisiz söyle.

Kritik savunma notları

Aşağıdaki ifadeler, soru işaretli notların tez, deney defteri ve dış kaynaklarla doğrulanmış kısa karşılığıdır.

Kavram	Savunmada kullanılacak net ifade
FinBERT geçmişi	ProsusAI/finbert önce Reuters TRC2 alt kümesiyle finansal dil uyarlaması, sonra Financial PhraseBank ile sentiment fine-tuning görmüştür.
Bizim fine-tuning	Fine-tuned FinBERT, 8.110 Twitter + 4.840 PhraseBank örneğiyle yeniden eğitildi. Validation 1.432 Twitter, test 2.386 Twitter örneğidir.
Eksik ablation	FinBERT için Twitter-only kolu çalıştırılmadı. Bu yüzden kazanımı yalnız Twitter verisine bağlamak doğru değildir.
Twitter etiketi	Veri kartı Bearish/Bullish/Neutral etiketli finans tweetlerini verir; etiketleyici profili, uzmanlık, oy sayısı, uzlaşa ve adjudication belgelenmez.
PhraseBank etiketi	Toplam 16 finans altyapılı etiketleyici vardır; her cümle 5-8 oy almıştır. PhraseBank, FinBERT eğitimiyle örtüştüğü için bağımsız test yapılmadı.
S&P/Reuters etiketi	Nihai etiket tek araştırmacıya aittir; ChatGPT açıklama/karar desteği sağlamıştır. Inter-annotator agreement ölçülmemiştir.
Üçlü yeniden etiketleme	Devam planında yeniden etiketleme için kullanılacak modeller ChatGPT, Claude ve Gemini'dir; nihai karar araştırma tasarımına aittir.
Financial-RoBERTa	Finans alanına uyarlanmış RoBERTa tabanlı alternatif olarak sonraki model karşılaştırmasına eklenebilir.
FinGPT planı	FinGPT sonraki aşamada ayrı model ailesi olarak eklenecek; kullandığı sentiment veri kaynakları benchmark overlap açısından ayrıca denetlenecektir.
Yeni eğitim verisi	Consensus S&P/Reuters-train ve açık finansal sentiment setleri kontrollü eklenecek; kilitli external test eğitimden tamamen ayrı tutulacaktır.
McNemar / Holm	McNemar aynı örneklerde iki modelin hata uyumsuzluğunu sınar; Holm çoklu karşılaştırmada p-değerlerini düzeltir.

Ana ayırım: Yüksek iç test skoru, farklı finansal kaynaklarda güvenilir genelleme garantisi değildir.

Ana sunum konuşma akışı

Hedef süre: Slayt 1–34 için yaklaşık 18–22 dakika; slayt 35–39 yalnız soru gelirse açılacak.

Slayt 1 — Finansal Duygu Analizinde

Süre: 20–25 sn

Söylenecekler

Merhaba, ben Serkan Kaymak. Bu çalışmada finansal duygu analizinde FinBERT, BERT, DistilBERT ve RoBERTa modellerini yalnızca iç test başarısına göre değil, farklı finansal veri kaynaklarına ne kadar genelleyebildiklerine göre karşılaştırdım. Sunum boyunca şu soruya cevap arayacağım: Finans alanına özel bir model gerçekten her koşulda en iyi model midir?

Geçiş: Önce problemi ve yöntemi kısaca kurup ardından deney sonuçlarına geçeceğim.

Kaynak notu: tez/finansal_duygu_analizi_tez.pdf

Slayt 2 — Sunum Planı

Süre: 35-45 sn

Söylenecekler

Sunum altı adımda ilerliyor. Önce finansal duygu analizinin neden zor olduğunu ve araştırma sorularını kuracağım. Ardından veri setlerinin rollerini, iç ve dış test ayrımını, modelleri ve deney akışını açıklayacağım. Bulgularda baseline, fine-tuning, üç seed ve iki dış test sonucunu göstereceğim. Son bölümde hata mekanizmaları, sınırlılıklar ve doğrudan bulgulardan çıkan gelecek deneyleri bağlayacağım.

Geçiş: Önce problemin neden sıradan bir sınıflandırma problemi olmadığını görelim.

Slayt 3 — « GİRİŞ ve MOTİVASYON »

Süre: 5 sn

Söylenecekler

İlk bölümde çalışmanın motivasyonunu ve temel araştırma problemini kuruyorum.

Geçiş: Finansal metinlerde tek bir kelimeye bakarak duygu çıkarmak çoğu zaman yeterli değildir.

Kaynak notu: tez/finansal_duygu_analizi_tez.pdf, Bölüm 1

Slayt 4 — Finansal metinlerde duygu analizi neden önemli?

Süre: 40 sn

Söylenecekler

Finansal kararlar yalnızca fiyat ve bilanço gibi sayısal verilerden etkilenmiyor; haberler, şirket açıklamaları, analist raporları ve sosyal medya da piyasa algısını şekillendiriyor. Buradaki zorluk bağlamdır. Örneğin ‘gelir yüzde 10 arttı’ olumlu görünebilir. Ancak devamında ‘analist beklentilerinin altında kaldı’ deniyorsa aynı haber olumsuz algılanabilir. Bu nedenle görevimiz kelime polaritesi bulmak değil, metnin şirket veya piyasa üzerindeki etkisini yorumlamaktır.

Geçiş: Bu zorluk bizi başlangıçtaki FinBERT beklentisine götürüyor.

Kaynak notu: [tez/finansal_duygu_analizi_tez.pdf](#), Bölüm 1.1

Slayt 5 — FinBERT'in eğitim geçmişi veri seçimini belirledi

Süre: 60-70 sn

Söylenecekler

FinBERT'i tek aşamalı bir model gibi düşünmemek gerekir. ProsusAI sürümünde önce Reuters TRC2'nin bir alt kümesiyle etiketsiz finansal metinler üzerinde dil modeli uyarlaması yapılmıştır. Ardından Financial PhraseBank ile Positive, Negative ve Neutral duygu sınıflandırması için fine-tuning uygulanmıştır.

Veri seçerken ilk adil-test ilkemiz, modelin yayımlanmış eğitim geçmişinde açıkça bulunan bir veri setini bağımsız başarı kanıtı olarak kullanmamaktır. Bu nedenle PhraseBank ana testten çıkarıldı; yalnız yardımcı eğitim ve ablasyon rolünde kaldı. Twitter Financial News ve S&P, FinBERT'in açıklanan eğitim kaynaklarında yer almıyor.

Geçiş: Bu ilke veri setlerinin çalışmadaki rollerini belirledi.

Kaynak notu: <https://github.com/ProsusAI/finBERT> <https://huggingface.co/ProsusAI/finbert> <https://arxiv.org/abs/1908.10063> [finansal_duygu_analizi_tez.pdf](#), Bölüm 3.2 ve 3.3

Slayt 6 — Araştırma soruları ve katkılar

Süre: 50 sn

Söylenecekler

İlk sorum hazır FinBERT'in ne kadar güçlü bir başlangıç modeli sunduğuydu. İkinci sorum, aynı görevde ince ayarlanan dört modelden hangisinin öne çıktığıydı. Üçüncü ve asıl sorum, iç testteki sıralamanın S&P 500 ve Reuters dış testlerinde korunup korunmadığıydı. Dördüncü sorum ise veri kaynağı ve etiket semantiğinin hataları nasıl değiştirdiğiydi. Katkı olarak aynı deney düzeninde genel ve finans-özümleri modelleri, çoklu tohumları ve dış genellemeyi birlikte inceliyorum.

Geçiş: Şimdi bu soruları hangi veri ve deney düzeniyle sınıadığımı göstereyim.

Kaynak notu: [tez/finansal_duygu_analizi_tez.pdf](#), Tablo 1-1 ve Bölüm 1.4

Slayt 7 — « MATERYAL ve YÖNTEM »

Süre: 5 sn

Söylenecekler

Yöntem bölümünde veri setlerinin rollerini, ana metriği ve deney akışını özetleyeceğim.

Geçiş: Buradaki en kritik tasarım kararı, eğitim verisi ile dış test verisini kesin biçimde ayırmaktır.

Kaynak notu: [tez/finansal_uygu_analizi_tez.pdf](#), Bölüm 3

Slayt 8 — İç test ve dış test aynı şeyi ölçmez

Süre: 55-65 sn

Söylenecekler

Burada iki kavramı ayırıyorum. İç test, ana veri setinden eğitim öncesinde ayrılan ve modelin eğitim sırasında hiç görmediği bölümdür. Kaynak ve etiketleme mantığı eğitim verisiyle aynıdır; bu nedenle temel soru modelin hedef görevi öğrenip öğrenmediğidir.

Dış test ise eğitimden bağımsız başka bir kaynaktan gelir. Dil, dönem, metin uzunluğu ve etiket karar sınırları değişebilir. Buradaki soru modelin yeni finansal kaynağa genelleyip genellemediğidir.

Bu tezde iç test Twitter held-out setidir. S&P daha yakın, Reuters daha uzak dış test olarak kullanıldı. Bu ayrımı sonraki sonuç slaytlarında kısaca tekrar hatırlatacağım.

Kaynak notu: [finansal_uygu_analizi_tez.pdf](#), Bölüm 3.2 ve 3.7

Slayt 9 — Veri seçimi: bağımsızlık ve etiket güveni

Süre: 85-95 sn

Söylenecekler

Veri setlerini dört ölçütü seçtik: finansal duygu görevine doğrudan uyum, Negative/Neutral/Positive ile eşlenebilir üç sınıf, açık erişim ve tekrar üretilebilirlik, ayrıca modelin bilinen eğitim geçmişinden bağımsız test kurabilme.

Twitter Financial News veri kartı, finansla ilgili İngilizce tweetleri Bearish, Bullish ve Neutral olarak etiketlenmiş bir korpus şeklinde tanımlıyor. Fakat etiketleyicilerin kim olduğu, insan ya da uzman olup olmadığı, kaç oy verildiği, uzlaşma oranı ve uyuşmazlıkların nasıl çözüldüğü belgelenmiyor. Dolayısıyla bu veri setini güvenilirliği doğrulanmış uzman-gold standardı olduğu için değil; göreve doğrudan uyduğu, hazır üç sınıf sunduğu ve açık biçimde yeniden kullanılabilirliği için ana hedef veri olarak seçtik. Etiket kökenindeki bu belirsizliği sınırlılık olarak açıkça yazıyoruz.

PhraseBank'ın etiketleme süreci daha ayrıntılıdır: toplam 16 finans altyapılı etiketleyici vardır ve her cümle 5 ile 8 oy almıştır. Buna karşın FinBERT bu veriyle sentiment fine-tuning gördüğü için PhraseBank bağımsız test olamaz; deneydeki 4.840 kullanılabilir örnek yalnız eğitim/ablasyon rolündedir. S&P ve Reuters'ta son karar araştırmacıya aittir; ChatGPT açıklama ve karar desteği vermiştir, bağımsız ikinci insan etiketi yoktur.

Kaynak notu: <https://huggingface.co/datasets/zeroshot/twitter-financial-news-sentiment>

<https://huggingface.co/datasets/zeroshot/twitter-financial-news-sentiment/raw/main/README.md>

https://huggingface.co/datasets/takala/financial_phrasebank <https://github.com/ProsusAI/finBERT> [finansal_uygu_analizi_tez.pdf](#), Bölüm 3.2.1-3.2.4 ve 5.2

Slayt 10 — Macro-F1: baskın Neutral sınıfına karşı adil ölçüm

Süre: 55-65 sn

Söylenecekler

İç testte Neutral sınıfı 1.549 örnekle toplamın yaklaşık yüzde 64,9'unu oluşturuyor. Böyle bir dağılımda accuracy, büyük sınıf iyi tahmin edildiğinde diğer iki sınıftaki zayıflığı gizleyebilir.

Önce her sınıf için precision ve recall hesaplanır. F1 bu ikisinin harmonik ortalamasıdır. Macro-F1 ise Negative, Neutral ve Positive sınıflarının F1 değerlerini basit ortalama ile birleştirir. Böylece her sınıf sonuca eşit ağırlıkla katılır.

Bu yüzden ana karşılaştırma metriğim Macro-F1'dir; accuracy ve sınıf bazlı skorları destekleyici olarak raporluyorum.

Kaynak notu: *finansal_duygu_analizi_tez.pdf*, Bölüm 3.2.6 ve 3.4

Slayt 11 — Deneysel akış: her aşama farklı bir soruyu sınıdı

Süre: 60-70 sn

Söylenecekler

Deney akışındaki her aşama farklı bir soruya cevap veriyor. Baseline aşamasında alan-özü FinBERT'i hiç hedefe uyarlamadan test ederek hazır modelin başlangıç gücünü ölçtüm. Fine-tuning aşamasında dört modeli aynı görev ve ayarlarla eğiterek adil karşılaştırma yaptım.

İç test, hedef görevin öğrenilip öğrenilmediğini ölçüyor. Üç farklı seed, rastgele ağırlık başlangıcı ve veri sırasının sonucu tesadüfen belirlemesini azaltıyor. S&P ve Reuters dış testleri, görülmemiş kaynaklara aktarımı ölçüyor. Son olarak hata, confidence ve verimlilik analizleri yalnız hangi modelin kazandığını değil, neden kazandığını ve maliyetini açıklıyor.

Geçiş: Bu akışta karşılaştırılan modelleri netleştirelim.

Slayt 12 — Kullanılan modeller

Süre: 55-65 sn

Söylenecekler

Burada model adları kadar eğitim koşulunu da netleştiriyorum. Original FinBERT, ProsusAI/finbert modelini ek eğitim yapmadan doğrudan test ettiğimiz baseline'dır. Fine-tuned FinBERT ise yalnız Twitter ile değil, 8.110 Twitter Financial News ve 4.840 Financial PhraseBank örneğinin birleşimiyle yeniden fine-tune edilmiştir. Validation'daki 1.432 ve testteki 2.386 örnek yalnız Twitter'dandır.

BERT, DistilBERT ve RoBERTa da aynı birleşik eğitim göreviyle karşılaştırıldı. Dolayısıyla bu deney model mimarisini ve birleşik veriye uyarlamayı karşılaştırır; FinBERT için Twitter-only bir kol bulunmadığından yalnız hedef verinin etkisini ayrı ölçmez.

Kaynak notu: *review/08_finetune_finbert_target_dataset.ipynb* *finansal_duygu_analizi_tez.pdf*, Bölüm 3.2.1 ve 3.3
<https://huggingface.co/ProsusAI/finbert>

Slayt 13 — « DENEYLER ve BULGULAR »

Süre: 5 sn

Söylenecekler

Bulguları önce iç testten, sonra dış testlerden ve son olarak tanısıl analizlerden okuyacağım.

Geçiş: İlk soru, hazır FinBERT'in hedef göreve uyarlanmadan ne kadar yeterli olduğuydu.

Kaynak notu: [tez/finansal_duygu_analizi_tez.pdf](#), Bölüm 4

Slayt 14 — Hazır FinBERT güçlüydü; hedef göreve tam uymadı

Süre: 55-65 sn

Söylenecekler

Hazır FinBERT finansal dili bilen güçlü bir başlangıç modelidir. ProsusAI sürümü Reuters TRC2 ile alan uyarlaması görmüş, sentiment başlığı Financial PhraseBank ile eğitilmiştir. Buna rağmen hedef Twitter iç testinde Macro-F1 0.6794'tür.

Bu bir çelişki değil. FinBERT genel finansal sentiment sinyallerini öğrenmiştir; hedef Twitter veri seti ise bazı cümlelerde şirket ya da piyasa yönünü farklı bir karar sınırıyla etiketler. En belirgin hata Neutral örneklerin Negative sınıfına kaymasıdır.

Ana çıkarım: Alan bilgisi başlangıç sağlar; hedef etiket semantiği ayrıca öğrenilmelidir.

Kaynak notu: [finansal_duygu_analizi_tez.pdf](#), Bölüm 4.1 <https://huggingface.co/ProsusAI/finbert> <https://github.com/ProsusAI/finBERT>

Slayt 15 — FinBERT hatası: olumsuz kelime, yanlış piyasa yorumu

Süre: 65-75 sn

Söylenecekler

İlk örnekte “jobless claims drop” ifadesindeki drop kelimesi yüzeysel olarak olumsuz görünüyor. Fakat işsizlik başvurularının beklentinin altına düşmesi piyasa açısından olumlu bir sinyaldir. Hazır FinBERT bunu yüzde 97'nin üzerinde güvenle Negative tahmin etmiştir.

İkinci örnek karışık sinyal taşır: beef satışları düşerken chicken satışları artıyor. Hedef etiket Neutral'dır; model ise fell bölümüne baskın ağırlık vererek Negative tahmin etmiştir.

Bu iki örnek aynı mekanizmayı gösteriyor: Model genel kelime tonuna odaklanıyor; hedef veri ise ekonomik veya piyasa yönünü ve karışık sinyali dikkate alıyor. Göreve özgü fine-tuning'in neden gerekli olduğu somut olarak burada görülüyor.

Kaynak notu: [review/02_baseline_original_finbert.ipynb](#) [finansal_duygu_analizi_tez.pdf](#), Bölüm 4.1

Slayt 16 — İç test: birleşik veriyle fine-tuning büyük fark yarattı

Süre: 55-65 sn

Söylenecekler

42 numaralı seed'de bütün ince ayarlı modeller hazır FinBERT'i geçti. FinBERT 0,6794'ten 0,8512'ye yükseldi; RoBERTa ise 0,8651 ile birinci oldu.

Fakat burada nedensel yorumu doğru kurmak gerekiyor. Fine-tuned FinBERT'in eğitim havuzu 8.110 Twitter ve 4.840 PhraseBank örneğidir; validation ve test yalnız Twitter'dır. Başlangıçtaki ProsusAI FinBERT zaten PhraseBank ile sentiment fine-tuning görmüştür. Bu nedenle PhraseBank model için tamamen yeni değildir. Ayrıca Twitter-only FinBERT ablasyonu çalıştırılmadı. Sonuç, birleşik veriyle yeniden fine-tuning'in kazanımını gösterir; artışın ne kadarının yalnız Twitter'dan geldiğini göstermez.

Geçiş: Sıralamanın tek bir seed'e bağlı olup olmadığını üç seed ile kontrol ettim.

Kaynak notu: [review/08_finetune_finbert_target_dataset.ipynb](https://huggingface.co/ProsusAI/finbert) finansal_uygu_analizi_tez.pdf, Tablo 4-1
<https://huggingface.co/ProsusAI/finbert>

Slayt 17 — Üç seed sonucu: RoBERTa üstünlüğü korundu

Süre: 45-55 sn

Söylenecekler

Tek bir eğitim koşusu model sıralamasını rastgele başlangıç, mini-batch sırası veya dropout etkisiyle değiştirebilir. Bu yüzden aynı eğitimleri 42, 123 ve 2024 seed'leriyle tekrarladım.

RoBERTa ortalama 0.8728 Macro-F1 ile ilk sırada kaldı. Standart sapmalar tüm modellerde düşüktür. Bu, sıralamanın tek bir şanslı koşuya dayanmadığını gösterir; yine de üç seed sonsuz kesinlik sağlamaz, yalnız rastlantısal oynaklığı daha görünür kılar.

Kaynak notu: [finansal_uygu_analizi_tez.pdf](#), Bölüm 3.5.2 ve 4.2

Slayt 18 — McNemar ve Holm: hangi fark gerçekten anlamlı?

Süre: 75-85 sn

Söylenecekler

Sonuçlara geçmeden üç aracı tanımlayayım. McNemar testi aynı örnekler üzerinde iki modelin doğru-yanlış kararlarının uyumadığı çiftleri kullanır; yani modellerin hata oranı farkının rastlantısal olup olmadığını sınar. Birden fazla ikili karşılaştırma yaptığımızda çok sayıda p-değeri yanlış-pozitif riskini artırır. Holm düzeltmesi p-değerlerini küçükten büyüğe sıralayan adım-aşağı bir yöntemle aile düzeyindeki hata riskini kontrol eder. Bootstrap ise aynı örnek çiftlerini 5.000 kez yeniden örnekleyerek Macro-F1 farkı için yüzde 95 güven aralığı üretir.

Bu çerçevede RoBERTa'nın ince ayarlı FinBERT'e üstünlüğü seed 123 ve 2024'te Holm sonrasında da anlamlıdır. S&P'de hazır ve ince ayarlı FinBERT farkı anlamlı değildir. Reuters'ta ise hazır FinBERT lehine güçlü ve güven aralığı sıfırı dışlayan fark vardır.

Kaynak notu: [finansal_uygu_analizi_tez.pdf](#), Bölüm 3.5 ve 4.10
[outputs/external_statistical_significance/external_statistical_significance_results.csv](#)

Slayt 19 — S&P 500 sonucu: RoBERTa dış veride de güçlü

Süre: 40 sn

Söylenecekler

S&P 500 dış testinde RoBERTa 0,8145 ile yine birinci oldu. İnce ayarlı FinBERT 0,7723, hazır FinBERT ise 0,7521 aldı. İç testteki sıralama büyük ölçüde korundu; ancak RoBERTa'nın skoru yaklaşık 0,87'den 0,81'e düştü. Bu, yakın bir finansal dış kaynağa geçildiğinde bile performans kaybı başladığını gösteriyor. Yine de bu sette RoBERTa'nın genellemesi güçlü kaldı.

Geçiş: Reuters'ta ise daha keskin ve tez açısından daha önemli bir değişim ortaya çıktı.

Kaynak notu: [tez/finansal_uygu_analizi_tez.pdf](#), Tablo 4-2

Slayt 20 — Reuters sonucu: ana kırılma noktası

Süre: 55-65 sn

Söylenecekler

Reuters testinde sıralama tersine döndü. Hazır FinBERT 0,6866 ile birinci olurken RoBERTa 0,6388, birleşik Twitter+PhraseBank ile yeniden ince ayarlı FinBERT ise 0,6101 aldı. Bu sonuç, fine-tuning'in iç testte kazandırırken daha uzak bir dağılımda genellemeyi azaltabileceğini düşündürüyor.

Ancak iki sınırı birlikte hatırlatıyorum. Birincisi, ince ayarlı FinBERT için Twitter-only kolu olmadığından düşüşü yalnız Twitter'a bağlayamayız; birleşik eğitim düzeninin sonucudur. İkincisi, hazır FinBERT Reuters TRC2 ile alan uyarlaması gördüğünden Reuters kaynak ailesine tamamen yabancı değildir. Bu bir örnek sızıntısı kanıtı değildir, fakat kaynak yakınlığı yorumda dikkate alınmalıdır.

Kaynak notu: [finansal_uygu_analizi_tez.pdf](#), Tablo 4-4 ve Bölüm 5.2 [review/08_finetune_finbert_target_dataset.ipynb](#)
<https://github.com/ProsusAI/finBERT>

Slayt 21 — « HATA ve TANISAL ANALİZLER »

Süre: 5 sn

Söylenecekler

Bu bölümde skorların arkasındaki hata mekanizmasını, özellikle tarafsız sınıfını ve etiket semantiğini inceliyorum.

Geçiş: En belirgin kırılma tarafsız sınıfında görülüyor.

Kaynak notu: [tez/finansal_uygu_analizi_tez.pdf](#), Bölüm 4.8 ve 4.12

Slayt 22 — Neutral sınıfı: performans düşüşünün merkezi

Süre: 45 sn

Söylenecekler

İnce ayarlı FinBERT'in tarafsız sınıf F1'i iç testte 0,9157. S&P'de 0,7538'e, Reuters'ta 0,5277'ye düşüyor. Sentetik sette ise 0,9876 gibi çok yüksek bir değer var. Bu büyük oynama, sorunun yalnızca model kapasitesi olmadığını düşündürüyor. Veri kaynağı değişikçe 'tarafsız' etiketinin pratik anlamı ve karar sınırı da değişebiliyor.

Geçiş: Burada iki kavramı ayırmak gerekiyor: domain shift ve label semantics.

Kaynak notu: tez/finansal_uygu_analizi_tez.pdf, Ek B.3 ve Bölüm 5.3

Slayt 23 — Domain shift ve label semantics ne demek?

Süre: 45 sn

Söylenecekler

Domain shift, eğitim ve test verilerinin farklı dağılımlardan gelmesidir. Kısa Twitter başlıklarıyla profesyonel Reuters haberlerinin dili aynı değildir. Label semantics ise aynı etiket adlarının farklı karar kurallarına dayanabilmesidir. Örneğin gelir artışı tek başına pozitif sayılabilir; fakat beklenti altı kaldığında negatif veya tarafsız etiketlenebilir. Bu iki etki Reuters düşüşünü birlikte açıklayan temel adaylardır.

Geçiş: Örnek bazlı hata analizi modelin bu sınırlarda nasıl davrandığını daha açık gösteriyor.

Kaynak notu: tez/finansal_uygu_analizi_tez.pdf, Bölüm 5.2–5.3

Slayt 24 — Hata analizi: model nerede yanılıyor?

Süre: 45 sn

Söylenecekler

İnce ayarlı FinBERT iç testte toplam 282 hata yaptı. Bunların 78'i tarafsızdan pozitive, 75'i tarafsızdan negatife geçti. Daha önemlisi, yanlış tahminlerin yaklaşık yüzde 77'sinde model güveni 0,90'ın üzerindeydi. Yani model yalnızca kararsız olduğu için hata yapmıyor; bazı örneklerde öğrendiği karar sınırından yüksek güvenle emin olup yanlış etiket üretiyor. Bu nedenle kalibrasyon analizi devam çalışması için anlamlı.

Geçiş: Veri kaynağının etkisini doğrudan sınamak için PhraseBank ablasyonu yaptım.

Kaynak notu: tez/finansal_uygu_analizi_tez.pdf, Tablo 4-10

Slayt 25 — PhraseBank ablasyonu: daha fazla veri her zaman daha iyi değil

Süre: 70-80 sn

Söylenecekler

Financial PhraseBank insan etiketlidir. Veri setinde toplam 16 finans altyapılı etiketleyici bulunur: üç araştırmacı ve Aalto Üniversitesi işletme yüksek lisans öğrencileri. Her cümle 5 ile 8 kişi tarafından değerlendirilmiş; veri kartında yüzde 50, 66, 75 ve 100 uzlaşma eşikleri ile farklı alt kümeler sunulmuştur. Bu yüzden doğru ifade “her cümle 5-8 uzman tarafından etiketlendi” değil, “16 finans altyapılı etiketleyiciden her cümle için 5-8 oy alındı”dır.

RoBERTa ablasyonunda yalnız Twitter ile eğitim, Twitter artı PhraseBank koşulundan hem iç testte hem Reuters'ta daha yüksek çıktı. Bu tek-seed bir bulgudur ve neden-sonuç kanıtlamaz. Makul yorum, daha iyi belgelenmiş insan etiketi olsa bile kaynak dili ve etiket semantiği uyuşmadığında ek verinin fayda sağlamayabileceğidir.

Bu ablasyon RoBERTa içindir. FinBERT için Twitter-only bir kol çalıştırılmamıştır.

Kaynak notu: https://huggingface.co/datasets/takala/financial_phrasebank_finance_sentiment_analysis_tez.pdf, Bölüm 3.6.2, 4.8 ve 5.2 review/08_finetune_finbert_target_dataset.ipynb

Slayt 26 — Sentetik veri ve zero-shot bulguları

Süre: 45 sn

Söylenecekler

Sentetik sette RoBERTa 0,9957 gibi neredeyse kusursuz bir Macro-F1 üretti. Ancak gerçek Reuters verisinde aynı model 0,6388 düzeyine geriliyor. Bu, sentetik örneklerde sınıf ipuçlarının daha açık olabileceğini ve sentetik testin gerçek dünya genellemesini iyimser gösterebildiğini düşündürüyor. S&P üzerinde en iyi zero-shot NLI sonucu da 0,558 ile denetimli modellerin belirgin biçimde gerisinde kaldı.

Geçiş: Model seçimi yalnız doğruluk değil, hesaplama maliyeti açısından da değerlendirildi.

Kaynak notu: tez/finansal_uygu_analizi_tez.pdf, Tablolar 4-3 ve 4-6

Slayt 27 — Verimlilik: doğruluk-maliyet dengesi

Süre: 40 sn

Söylenecekler

CPU ölçümlerinde DistilBERT saniyede 70,3 örnek işleyerek BERT'in yaklaşık 2,24 katı hızına ulaştı. RoBERTa ise saniyede 35,91 örnekle daha yavaş olmasına rağmen en yüksek iç test performansını verdi. Dolayısıyla üretim ortamında tek bir doğru seçim yok. Kaynak kısıtlı ve gecikmeye duyarlı bir sistemde DistilBERT; en yüksek sınıflandırma başarısının öncelikli olduğu durumda RoBERTa daha uygun olabilir.

Geçiş: Bu bulguları şimdi tek bir sonuç cümlesinde birleştireyim.

Kaynak notu: tez/finansal_uygu_analizi_tez.pdf, Tablo 4-9

Slayt 28 — « SONUÇ ve GELECEK ÇALIŞMA »

Süre: 15-20 sn

Söylenecekler

Son bölümde önce çalışmanın dört ana sonucunu tek çerçevede özetleyeceğim. Ardından geçerlik sınırlarını açıkça belirtecek ve bu sınırlılıklardan doğrudan çıkan etiket güvenilirliği, kontrollü veri büyütme ve yeni deney adımlarını sunacağım.

Geçiş: Önce tezin tek parça halinde ana mesajını özetleyelim.

Slayt 29 — Ana sonuçlar

Süre: 55 sn

Söylenecekler

Birincisi, finans alanına özel ön eğitim tek başına yeterli değil. İkincisi, göreve özgü ince ayar iç dağılımda çok güçlü kazanç sağlıyor. Üçüncüsü, bu kazanç farklı kaynaklarda garanti değil; Reuters'ta hazır FinBERT yeniden öne geçti. Dördüncüsü, veri miktarından çok veri kaynağı ve etiket semantiği belirleyici olabiliyor. Bu nedenle savunma mesajım şu: iyi bir iç test skoru, gerçek dünya genellemesini tek başına kanıtlamaz.

Geçiş: Bu yorumu yaparken çalışmanın sınırlılıklarını da açık biçimde belirtmek gerekiyor.

Kaynak notu: [tez/finansal_uygu_analizi_tez.pdf](#), Bölüm 6.1

Slayt 30 — Sınırlılıklar: sonuçların geçerlik sınırı

Süre: 75-85 sn

Söylenecekler

Sonuçların geçerlik sınırını beş noktada açıkça belirtiyorum. Birincisi, Twitter veri kartı üç sınıfı açıklasa da etiketleyici profilini, oy sayısını, uzlaşma oranını ve karar çözümünü belgelemiyor. İkincisi, S&P ve Reuters'ın nihai etiketleri tek araştırmacı tarafından verilmiştir; ChatGPT açıklama ve karar desteği sağlamış, bağımsız ikinci insan olmadığı için inter-annotator agreement hesaplanmamıştır.

Üçüncüsü, fine-tuned FinBERT Twitter ve PhraseBank birleşimiyle eğitildi; Twitter-only FinBERT kolu olmadığı için kazanımı tek bir veri kaynağına ayıramıyoruz. Dördüncüsü, S&P örnekleri ilk FinBERT tahminlerine göre dengeli seçildiği için doğal haber dağılımını temsil etmiyor. Beşincisi, PhraseBank ablasyonu tek seed'dir; ayrıca S&P ablasyon kolu 1.030, ana dış test 1.060 örnektir.

Bu sınırlılıklar sonuçları geçersiz kılmaz; hangi iddiaların kurulabileceğini doğru sınırlar.

Kaynak notu: <https://huggingface.co/datasets/zeroshot/twitter-financial-news-sentiment>

<https://huggingface.co/datasets/zeroshot/twitter-financial-news-sentiment/raw/main/README.md> [finansal_uygu_analizi_tez.pdf](#), Bölüm 3.2.1-3.2.4, 3.6.2 ve 5.2 [review/08_finetune_finbert_target_dataset.ipynb](#)

Slayt 31 — Devam planı 1: Üç modelle yeniden etiketleme

Süre: 55-65 sn

Söylenecekler

Devam planındaki ilk adım yeniden etiketlemedir. Burada kullanacağım üç model belirsiz değil: ChatGPT, Claude ve Gemini. Amaç tek bir modelin kararına bağımlı kalmadan hem eğitim adaylarını hem de dış test adaylarını daha güvenilir biçimde sınıflandırmak.

Kurgu şöyle olacak: Üç model aynı metin için aynı etiketi verirse bu örnek 3/3 consensus olarak güvenilir çekirdek sete alınacak. İki model aynı, biri farklı karar verirse 2/3 majority olarak ayrı tutulacak ve duyarlılık analizinde değerlendirilecek. Üç model birbirinden ayrılırsa örnek belirsiz kabul edilip ya dışarıda bırakılacak ya da ayrıca hata analizi konusu yapılacaktır.

Buradaki amaç araştırmayı başkasına devretmek değil; benim nihai veri seçimi kararımı daha sistematik ve denetlenebilir hale getirmektir. Son karar yine araştırma tasarımıma aittir, modeller karar destek aracı olarak kullanılacaktır.

Kaynak notu: *finansal_uygu_analizi_tez.pdf*, Bölüm 6

Slayt 32 — Devam planı 2: Eğitim veri setini kontrollü büyütme

Süre: 60-70 sn

Söylenecekler

Devam planındaki ikinci adım, eğitim verisini yalnız daha büyük yapmak değil, kontrollü biçimde çeşitlendirmektir. Bu çalışmada ana eğitim Twitter ve PhraseBank üzerinden kuruldu. Sonraki aşamada consensus ile güvenilir bulunan S&P ve Reuters örneklerinin yalnız train adayı bölümü eğitim havuzuna eklenebilir. Kilitli external test bölümü ise en baştan ayrılacak ve eğitim, veri seçimi ya da hiperparametre kararlarında hiç kullanılmayacak.

Bu genişletmeye model seti de eşlik edecek. FinGPT ve Financial-RoBERTa ayrı finans-özü model alternatifleri olarak deneye alınacak. FinGPT sentiment kaynaklarında Financial PhraseBank, FiQA, Twitter Financial News ve GPT-news tabanlı instruction sentiment verileri bulunduğu için iki şeyi birlikte yapmam gerekir: Birincisi, FinGPT'i yalnız skor açısından değil, daha önce görmüş olabileceği veri kaynakları açısından da raporlamak. İkincisi, ek eğitim veri setlerini ve Financial-RoBERTa gibi yeni modelleri benchmark overlap açısından açık denetlemek.

Bu nedenle yeni kurgu üç parçalıdır: mevcut Twitter+PhraseBank temel eğitim havuzu, kontrollü consensus dış-kaynak train adayı ve FinGPT ile Financial-RoBERTa dahil yeni model karşılaştırması. Ana soru şudur: kaynak çeşitliliği ve finans-özü model ailesi genişlediğinde dış genelleme gerçekten güçleniyor mu?

Kaynak notu: <https://github.com/AI4Finance-Foundation/FinGPT> <https://huggingface.co/datasets/FinGPT/finppt-sentiment-train> <https://huggingface.co/soleimanian/financial-roberta-large-sentiment> <https://huggingface.co/datasets/zeroshot/twitter-financial-news-sentiment> https://huggingface.co/datasets/takala/financial_phrasebank *finansal_uygu_analizi_tez.pdf*, Bölüm 6

Slayt 33 — Devam planı 3: Yeni deneyler

Süre: 55-65 sn

Söylenecekler

Yeni deneyleri dört ailede topluyorum. İlk deney, fine-tuning miktarını değiştirerek aşırı adaptasyonun dış genellemeyi bozup bozmadığını ölçecek. İkinci deney, veri ve model kompozisyonunu birlikte ele alacak:

Twitter, PhraseBank, S&P, Reuters ve ek finansal sentiment veri setlerinin oranları değiştirilecek; aynı zamanda FinGPT ve Financial-RoBERTa ayrı finans-özü model alternatifleri olarak karşılaştırmaya alınacak.

Üçüncü deney label semantics üzerinedir. Positive, Neutral ve Negative karar sınırları Twitter, PhraseBank, S&P ve Reuters arasında aynı mı, yoksa aynı etiket adı farklı karar mantıklarına mı dayanıyor? Dördüncü deney ise calibration analizidir; model yanlış olduğunda ne kadar emin davranıyor?

Bu deneylerle yalnız “hangi model yüksek skor aldı?” sorusunu değil, hangi veri karışımı ve model ailesinin farklı finansal kaynaklarda daha sağlam kaldığını ölçmeyi hedefliyorum.

Kaynak notu: *finansal_uygu_analizi_tez.pdf*, Bölüm 6 <https://github.com/Al4Finance-Foundation/FinGPT>
<https://huggingface.co/datasets/FinGPT/finpt-sentiment-train> <https://huggingface.co/soleimanian/financial-roberta-large-sentiment>

Slayt 34 — Teşekkürler

Süre: 20 sn

Söylenecekler

Özetle, finansal duygu analizinde model başarısı yalnız mimariye veya alan-özü ön eğitime bağlı değil. Hedefe özü ince ayar, veri kaynağı ve etiket semantiği birlikte belirleyici. Bu nedenle iç test başarısını mutlaka bağımsız dış testlerle doğrulamak gerekiyor. Dinlediğiniz için teşekkür ederim; sorularınızı memnuniyetle yanıtlarım.

Geçiş: Sorular gelirse sonraki ek slaytları kullanabilirim.

Kaynak notu: *tez/finansal_uygu_analizi_tez.pdf*, Bölüm 6

Soru-cevap eki

Kullanım: Bu bölüm ana akışta sunulmayacak; yalnızca ilgili soru geldiğinde kullanılacak.

Slayt 35 — « EKLER »

Süre: Sunulmayacak

Söylenecekler

Bu slayttan sonrası soru-cevap için hazırlanmış yedek içeriktir. Ana sunum sırasında zaman kaybetmemek için doğrudan gösterilmeyecek.

Geçiş: Sorunun konusuna göre ilgili ek slayta geçilir.

Kaynak notu: *tez/finansal_uygu_analizi_tez.pdf*

Slayt 36 — Literatür bağlamı

Süre: Soru gelirse 30–40 sn

Söylenecekler

Literatürde transformer modellerinin bağlamsal temsil gücü, FinBERT gibi alan-özü modellerin avantajı ve domain shift riski ayrı ayrı tartışılıyor. Bu tez bu başlıkları aynı deney akışında birleştiriyor. Özellikle iç test ile bağımsız S&P ve Reuters testlerinin ayrıştırılması, etiket semantiğinin neutral sınıfı üzerinden tartışılması ve kaynak ablasyonu çalışmanın farklılaşan yönleridir.

Geçiş: Model kaynakları sorulursa bir sonraki ek slayta geçilebilir.

Kaynak notu: tez/finansal_uygu_analizi_tez.pdf, Bölüm 2 ve 5.7

Slayt 37 — Finans-özü modellerin eğitim kaynakları

Süre: Soru gelirse 50-60 sn

Söylenecekler

FinBERT'in avantajını yorumlarken eğitim geçmişini iki aşamada ayırmak gerekir. ProsusAI modeli Reuters TRC2 alt kümesiyle finansal dil uyarlaması görmüş, sentiment başlığı Financial PhraseBank ile eğitilmiştir. Buna ek olarak sonraki çalışmada Financial-RoBERTa gibi finans alanına uyarlanmış RoBERTa tabanlı modeller de denenebilir. Bu model ailesi RoBERTa-Large üzerine 10-K, 10-Q, 8-K, earnings call transcriptleri, CSR/ESG haberleri ve finans haberleriyle further training/fine-tuning gördüğü için mevcut genel RoBERTa sonucuna daha adil bir finans-özü RoBERTa karşılığı sunar.

PhraseBank ile doğrudan veri seti örtüşmesi bilindiği için onu bağımsız ana test olarak kullanmadık; yalnız yardımcı eğitim ve ablasyon rolünde tuttuk. Reuters dış testimizde birebir örnek örtüşmesi gösterilmiş değildir. Buna rağmen TRC2 ile Reuters aynı kaynak ailesine yakın olduğundan, Reuters sonucunu tamamen kaynak-bağımsız başarı diye sunmuyoruz. Bu durum veri sızıntısı kanıtı değil, yorum gücünü sınırlayan bir kaynak yakınlığıdır.

Kaynak notu: <https://github.com/ProsusAI/finBERT> <https://huggingface.co/ProsusAI/finbert>

<https://huggingface.co/soleimanian/financial-roberta-large-sentiment> https://huggingface.co/datasets/takala/financial_phrasebank

Slayt 38 — Eğitim ve değerlendirme ayarları

Süre: Soru gelirse 30 sn

Söylenecekler

Bütün ana modeller aynı üç sınıflı görevde Negative, Neutral ve Positive etiketleriyle değerlendirildi. Ana metrik Macro-F1'dir. Robustluk için 42, 123 ve 2024 tohumları kullanıldı. İç test 2.386 örnekten, dış testler ise S&P, Reuters ve sentetik veri kaynaklarından oluşuyor. Ayrıntılı hiperparametreler ve deney dosyaları tezde ve notebook akışında kayıtlıdır.

Geçiş: Benchmark örtüşmesi veya contamination sorusu gelirse son ek slayta geçilebilir.

Kaynak notu: tez/finansal_uygu_analizi_tez.pdf, Bölüm 3 ve Ek B.1

Slayt 39 — Devam planı 4: Finansal model audit'i

Süre: Soru gelirse 40 sn

Söylenecekler

Finans-özü modeller karşılaştırılırken hangi korpuslarda ön eğitim veya talimat ince ayarı gördükleri incelenecek. Kendi eğitim setimizle örtüşen benchmarklar varsa bu durum avantaj olarak değil, olası contamination veya benchmark overlap riski olarak raporlanacak. Bu denetim özellikle FinBERT ve FinGPT sürümleri arasında adil karşılaştırma yapabilmek için gerekli.

Geçiş: Yanıtı ana sonuçla bağlayarak tamamlayın: veri geçmişi, model performansının yorumunu değiştirir.

Kaynak notu: tez/sunuma hazırlık/hocaya_2_aylik_gelistirme_plani_sunumu_serkan_kaymak_guncel_v2.pptx
<https://github.com/AI4Finance-Foundation/FinGPT>