

# Finansal Duygu Analizinde Transformer Modellerinin Karşılaştırılması

FinBERT, BERT, DistilBERT ve RoBERTa: iç test başarısı, dış genelleme ve verimlilik

**Ana soru: Finans için özel model gerçekten her zaman en iyi mi?**

---

Serkan Kaymak

Yüksek Lisans Tezi • Tez Savunması

Finansal NLP

Domain generalization

# Sunum Planı

Önce problem ve yöntem, sonra bulgular, en sonda güvenilirlik ve yeni deneyler.

- |   |                                 |                                                      |
|---|---------------------------------|------------------------------------------------------|
| 1 | <b>Giriş ve motivasyon</b>      | Finansal metinlerde sentiment neden zor?             |
| 2 | <b>Araştırma soruları</b>       | FinBERT beklentisi, fine-tuning ve genelleme         |
| 3 | <b>Materyal ve yöntem</b>       | Veri setleri, modeller, metrik ve deney akışı        |
| 4 | <b>Deneyler ve bulgular</b>     | İç test, S&P, Reuters, sentetik ve zero-shot         |
| 5 | <b>Hata / tanısal analiz</b>    | Neutral sınıfı, confidence, PhraseBank etkisi        |
| 6 | <b>Sonuç ve gelecek çalışma</b> | Etiket güvenilirliği, veri bileşimi ve yeni deneyler |

# « GİRİŞ ve MOTİVASYON »

Finansal sentiment neden sıradan metin sınıflandırmadan daha zor?

# Finansal metinlerde duygu analizi neden önemli?

Haber, tweet ve raporların piyasa algısına hızlı etkisi vardır.

Finansal kararlar yalnızca sayısal verilerden değil; haber, sosyal medya, rapor ve beklenti metinlerinden de etkilenir. Aynı olay farklı bağlamlarda farklı sentiment doğurabilir: gelir artışı olumlu olabilir; beklenti altı kalırsa olumsuz algılanabilir. Bu nedenle finansal duygu analizi yalnızca kelime polaritesi değil, bağlam ve finansal etki yorumudur.

**Finansal sentiment = metnin piyasaya veya şirkete yönelik olumlu / olumsuz / nötr etkisini yorumlama problemi**

## Örnek

“Revenue increased by 10%.”  
→ çoğu durumda Positive

“Revenue increased by 10%,  
below analyst expectations.”  
→ bağlama göre Negative olabilir

**Bu yüzden modellerin farklı veri kaynaklarında aynı kararı verip vermediği kritik hale gelir.**

# FinBERT'in eğitim geçmişini belirledi

Modelin daha önce gördüğü veriyi bağımsız test olarak kullanmadık.

## Alan uyarlaması

Reuters TRC2 alt kümesi  
Etiketsiz finansal metinlerle  
dil modeli uyarlaması

## Duygu sınıflandırması

Financial PhraseBank  
Positive / Negative / Neutral  
sentiment fine-tuning

**Adil test: PhraseBank ana testten çıkarıldı; Twitter ve S&P yeni kaynaklardı**

# Araştırma soruları ve katkılar

Çalışma yalnızca model yarışı değil; genelleme ve veri etkisi analizi.

RQ1

Original FinBERT, göreve özel fine-tuning olmadan ne kadar güçlü bir baseline sağlar?

RQ2

Fine-tuning sonrası FinBERT, BERT, DistilBERT ve RoBERTa arasında hangi model öne çıkar?

RQ3

İç testte başarılı model S&P ve Reuters gibi dış finansal kaynaklarda da başarılı kalır mı?

RQ4

Veri kaynağı, etiket semantiği ve ek veri kullanımı model başarısını nasıl etkiler?

## Katkı

Aynı görevde genel ve finans-özümler transformer modellerinin karşılaştırılması  
İç test ile dış test performansı arasındaki farkın S&P ve Reuters üzerinden incelenmesi  
Neutral sınıfı, PhraseBank etkisi, sentetik veri ve verimlilik gibi tanısal analizlerle sonuçların yorumlanması

# « MATERYAL ve YÖNTEM »

Veri setleri, model ailesi, metrik ve deney akışı

# İç test ve dış test aynı şeyi ölçmez

İç test öğrenmeyi; dış test yeni kaynağa aktarımı sınar.

## İç test

Eğitimde görülmeyen, ana veri setinden ayrılmış bölümdür.

Kaynak ve etiket mantığı aynıdır.

Soru: Model hedef görevi öğrendi mi?

## Dış test

Eğitimden bağımsız başka bir kaynaktan gelir.

Dil, dönem veya etiket ölçütü değişebilir.

Soru: Model yeni kaynağa genelliyor mu?

## Bu tezdeki karşılık

**İç: Twitter held-out, N=2.386**

**Yakın dış: S&P 500, N=1.060 | Uzak dış: Reuters, N=5.000**

# Veri seçimi: bağımsızlık ve etiket güveni

Ölçütler: görev uyumu, üç sınıf, açık erişim ve model geçmişinden bağımsız test.

| Veri seti              | N      | Rol              | Etiket / güven        |
|------------------------|--------|------------------|-----------------------|
| Twitter Financial News | 11.931 | Ana hedef        | Hazır 3 sınıf*        |
| Financial PhraseBank   | 4.840  | Yardımcı train   | İnsan; 5–8 oy         |
| İç test                | 2.386  | Aynı kaynak test | Hazır Twitter etiketi |
| S&P 500                | 1.060  | Yakın dış test   | Araştırmacı + destek  |
| Reuters                | 5.000  | Uzak dış test    | Araştırmacı + destek  |
| Sentetik               | 3.000  | Tanısal test     | Koşullu üretim        |

## Twitter etiketi\*

Veri kartı üç sınıfı tanımlar; etiketleyici profili, uzmanlığı, uzlaşısı ve adjudication süreci açıklanmaz.

# Macro-F1: baskın Neutral sınıfına karşı adil ölçüm

İç testin %64,9'u Neutral; accuracy tek başına yeterli değil.

## Sınıflar

Negative

Neutral

Positive

## İç test dağılımı

358 Negative • 1.549 Neutral • 479 Positive

## F1 ve Macro-F1

Precision =  $TP / (TP + FP)$

Recall =  $TP / (TP + FN)$

F1 =  $2PR / (P + R)$

Macro-F1 =  $(F1_{neg} + F1_{neu} + F1_{pos}) / 3$

Her sınıf eşit ağırlıkta: büyük Neutral sınıfı sonucu domine etmez.

# Deneyisel akış: her aşama farklı bir soruyu sınadı

Baseline'dan genellemeye uzanan kontrollü karşılaştırma.



| Aşama         | Amaç                                                           |
|---------------|----------------------------------------------------------------|
| Baseline      | Alan-öзgü FinBERT hedefe uyarlanmadan ne kadar güçlü?          |
| Fine-tuning   | Aynı görev ve ayarlarla adil model karşılaştırması.            |
| Robustluk     | 3 seed ile rastgele başlangıç ve veri sırası etkisini azaltma. |
| External test | Görülmemiş kaynaklarda genelleme başarısını ölçme.             |

# Kullanılan modeller

Genel amaçlı modeller ile finans-özü FinBERT aynı görevde karşılaştırıldı.

| Model              | Rol                          | Tezdeki anlamı                                                           |
|--------------------|------------------------------|--------------------------------------------------------------------------|
| Original FinBERT   | Baseline                     | Finansal alana özel model fine-tune edilmeden ne yapıyor?                |
| Fine-tuned FinBERT | Finans-özü + task adaptation | FinBERT birleşik eğitimle yeniden ayarlanınca ne kadar iyileşiyor?       |
| BERT               | Genel transformer baseline   | Genel dil temsili finans görevinde ne kadar yeterli?                     |
| DistilBERT         | Verimlilik modeli            | Daha hızlı ama daha küçük model performans-maliyet dengesi kurabilir mi? |
| RoBERTa            | Güçlü genel encoder          | Finans-özü olmayan ama mimari olarak güçlü model FinBERT'i geçebilir mi? |

# « DENEYLER ve BULGULAR »

İç test başarıları, dış genelleme ve ana kırılma noktaları

# Hazır FinBERT güçlüydü; hedef göreve tam uymadı

Finans dilini biliyor; Twitter'ın piyasa-yönlü karar sınırlarını görmemişti.

## Original FinBERT

# 0.6794

Internal Macro-F1

Finans diline uyarlanmış; PhraseBank ile sentiment fine-tuning görmüş bir modeldir.

Twitter iç testinde Macro-F1 = 0.6794; başlıca hata Neutral → Negative'ti.

Sonuç: alan bilgisi, hedef etiket semantiğini tek başına çözmez.

**İlk ders: alan bilgisi güçlü bir başlangıçtır; hedef karar sınırları ayrıca öğrenilmelidir.**

# FinBERT hatası: olumsuz kelime, yanlış piyasa yorumu

İki örnek, yüzeysel kelime eşleşmesinin neden yetmediğini gösteriyor.

## Örnek 1 — Gold: Positive

“Jobless claims drop below consensus”

FinBERT: Negative (%97,03)

Düşük başvuru olumlu; “drop” modeli yanıltıyor.

## Örnek 2 — Gold: Neutral

“Beef sales fell 8%; chicken rose 4.5%”

FinBERT: Negative

Karışık sinyal; “fell” kısmı baskın geliyor.

## Hata mekanizması

**FinBERT genel finansal tonu; hedef veri ise piyasa yönünü etiketliyor.**

**Semantik fark, göreve özgü fine-tuning ihtiyacını açıklıyor.**

# İç test: birleşik veriyle fine-tuning büyük fark yarattı

Train: 8.110 Twitter + 4.840 PhraseBank; validation ve test yalnız Twitter.




## Ana yorum

FinBERT: 0.6794 → 0.8512  
Train: Twitter + PhraseBank.  
PhraseBank, hazır model için tekrar veridir.  
RoBERTa 0.8651 ile yine birinci.

**Twitter-only FinBERT kolu yok: kazanımı yalnız hedef veriye bağlayamayız.**

# Üç seed sonucu: RoBERTa üstünlüğü korundu

Rastgele başlangıç ve veri sırası değişse de sıralama korundu.



| Model      | Ortalama Macro-F1 |
|------------|-------------------|
| RoBERTa    | 0.8728 ± 0.0068   |
| FinBERT    | 0.8480 ± 0.0028   |
| BERT       | 0.8396 ± 0.0023   |
| DistilBERT | 0.8231 ± 0.0028   |

**Düşük standart sapmalar: RoBERTa üstünlüğü tek koşuluk şans etkisi değil.**

# McNemar ve Holm: hangi fark gerçekten anlamlı?

RoBERTa iç testte; hazır FinBERT Reuters'ta anlamlı üstünlük gösterdi.

McNemar: Aynı örneklerde iki modelin hata uyumsuzluğunu sınar.

Holm: Çoklu karşılaştırmada p-değerlerini düzeltir.

Bootstrap:  $\Delta F1$  için %95 GA.

RoBERTa – ince ayarlı FinBERT

- Seed 123:  $\Delta F1 = +0.0294$ ;  $p = 0.000617$
- Seed 2024:  $\Delta F1 = +0.0312$ ;  $p = 0.001410$

## Dış test sonucu

S&P 500

Hazır – ince ayarlı FinBERT:  $\Delta F1 = -0.0201$ ;  
 $p = 0.1678$ ; GA sıfırı içeriyor → anlamlı fark yok.

Reuters

$\Delta F1 = +0.0765$ ;  $p \approx 1.37 \times 10^{-32}$ ; GA [0.0610, 0.0923] → hazır FinBERT lehine güçlü fark.

**İç testte RoBERTa üstünlüğü iki seed'de de anlamlı.**

# S&P 500 sonucu: RoBERTa dış veride de güçlü

İç test sıralaması büyük ölçüde korundu; ancak performans düştü.




RoBERTa S&P setinde de birinci oldu. Ancak iç testteki  $\sim 0.87$  düzeyinden  $\sim 0.81$ 'e düşüş var. Bu düşüş veri kaynağı değiştiğinde performansın etkilenebildiğini gösteriyor.

**S&P sonucu: RoBERTa güçlü kaldı; fakat dış kaynağa çıkınca skor kaybı başladı.**

# Reuters sonucu: ana kırılma noktası

Fine-tuning iç testte kazandırdı; Reuters'ta avantaj tersine döndü.



## En önemli bulgu

**Original FinBERT, Reuters'ta fine-tuned FinBERT'i geçti.**

Bu sonuç fine-tuning'in yalnızca iç dağılım başarısını artırmadığını; bazen dış dağılım genellemesini azaltabileceğini düşündürdü.

**Reuters sonucu tezin ana mesajını oluşturdu: iç test başarısı  $\neq$  dış genelleme.**

# « HATA ve TANISAL ANALİZLER »

Model neden düşüyor? Neutral, label semantics ve veri etkisi

# Neutral sınıfı: performans düşüşünün merkezi

Fine-tuned FinBERT farklı kaynaklarda Neutral sınıfını koruyamadı.



İç testte Neutral oldukça güçlü ayrılıyor.  
Reuters'ta Neutral F1 yaklaşık 0.53'e düşüyor.  
Bu düşüş, yalnızca model değil veri kaynağı ve etiket tanımı farklılığını da düşündürüyor.

**Neutral sınıfındaki düşüş bizi domain shift ve label semantics tartışmasına götürdü.**

# Domain shift ve label semantics ne demek?

Reuters düşüşü iki olası açıklama doğurdu.

## Domain shift

Eğitimde görülen veri ile testte karşılaşılan veri aynı dağılımdan gelmez. Twitter tarzı kısa metin ile Reuters tarzı profesyonel haber dili farklı olabilir.

## Label semantics

Positive / Neutral / Negative etiket adları aynı olsa da hangi durumda hangi etiketin verileceği veri setinden veri setine değişebilir.

## Örnek label semantics farkı

**“Revenue increased 10%, below expectations.”**

**Aynı cümle bir yerde Positive, başka bir yerde Negative veya Neutral sayılabilir.**

# Hata analizi: model nerede yanılıyor?

Hatalar özellikle Neutral sınırlarında ve yüksek confidence ile yoğunlaştı.

## İç test hataları

**282**

toplam hata

Neutral → Positive: 78

Neutral → Negative: 75

Neutral kaynaklı hatalar toplam hatanın önemli kısmını oluşturdu.

## Confidence bulgusu

**~%77**

yanlış tahminlerde  
confidence  $\geq 0.90$

**Model bazen emin olmadığı için değil,  
yanlış öğrendiği karar sınırından emin  
olduğu için hata yapıyor olabilir.**

**Bu bulgu ileride calibration analizi yapılmasını anlamlı kılıyor.**

# PhraseBank ablasyonu: daha fazla veri her zaman daha iyi değil

Sorun insan etiketi değil; kaynak, uzlaş ve etiket semantiği farkı.

| Eğitim konfigürasyonu | Internal | Reuters | Yorum       |
|-----------------------|----------|---------|-------------|
| Twitter-only          | 0.8810   | 0.6465  | Daha yüksek |
| Twitter + PhraseBank  | 0.8679   | 0.6305  | Düşüş       |

PhraseBank: 16 finans altyapılı etiketleyici; her cümle için 5–8 oy.

Uzlaş düzeyi, kaynak ve etiket sınırları Twitter'dan farklı olabilir.

Tek-seed RoBERTa ablasyonunda Twitter-only iki testte de daha yüksekti.

**Yorum: veri miktarından önce veri uyumu, etiket semantiği ve uzlaş kontrol edilmelidir.**

# Sentetik veri ve zero-shot bulguları

Kolay benchmark ve genel NLI yaklaşımı dikkatle yorumlanmalı.

## Sentetik test

**RoBERTa  $\approx 0.9957$**

3.000 sentetik örnekte skor çok yüksek çıktı; fakat Reuters sonucu çok daha düşük kaldı.

## Zero-shot NLI

**BART-MNLI  $\approx 0.558$**

S&P'de zero-shot NLI modelleri fine-tuned modellerin belirgin biçimde gerisinde kaldı.

**Sentetik veri yüksek skor verdi; gerçek dünya genellemesi için Reuters/S&P gibi dış testler daha belirleyici oldu.**

# Verimlilik: doğruluk-maliyet dengesi

En yüksek F1 ile en hızlı model aynı olmak zorunda değil.

**BERT**

**31.4**

örnek/s

**DistilBERT**

**70.3**

örnek/s

**DistilBERT yaklaşık 2.24× daha hızlı; RoBERTa ise doğruluk tarafında öne çıktı.**

Araştırma sonucunda tek seçim kriteri F1 olmamalı.  
Canlı sistemlerde latency, throughput ve kaynak maliyeti de önemlidir.  
Bu nedenle doğruluk-verimlilik dengesi ayrıca raporlandı.

# « SONUÇ ve GELECEK ÇALIŞMA »

Ana mesaj, sınırlılıklar ve gelecek çalışma adımları

# Ana sonuçlar

Çalışmanın tek parça halinde yorumu.

1

**Finans alanına özel pretrained model olmak tek başına yeterli değildir.**

Original FinBERT baseline sonucu bunu gösterdi.

2

**Task-specific fine-tuning iç dağılımda performansı ciddi biçimde artırır.**

FinBERT 0.6794'ten 0.8512'ye çıktı.

3

**Ancak iç test başarısı dış genellemeyi garanti etmez.**

Reuters'ta Original FinBERT, fine-tuned FinBERT'i geçti.

4

**Veri kaynağı ve label semantics performansı doğrudan etkiler.**

Neutral sınıfı ve PhraseBank ablasyonu bu tartışmayı destekledi.

**Savunma mesajı: iyi iç test skoru, gerçek dünya genellemesini garanti etmez.**

# Sınırlılıklar: sonuçların geçerlik sınırı

Bulgular güçlüdür; ancak kapsamı bu deney düzeniyle sınırlıdır.

Twitter veri kartı etiketleyici profilini ve uzlaşma sürecini belgelemiyor.  
S&P/Reuters nihai etiketi tek araştırmacıya ait; etiketleyiciler arası uyum yok.  
FinBERT, Twitter + PhraseBank ile yeniden eğitildi; Twitter-only kolu yok.  
S&P seçimle dengeli; PhraseBank ablasyonu tek seed.

**Sonuçlar bu kaynak, etiketleme ve deney koşulları içinde yorumlanmalıdır.**

# Devam planı 1: Üç modelle yeniden etiketleme

Amaç: tek model etiketine bağımlılığı azaltmak ve daha güvenilir veri havuzu oluşturmak.

| Metin   | ChatGPT  | Claude   | Gemini   | Karar               |
|---------|----------|----------|----------|---------------------|
| Haber 1 | Positive | Positive | Positive | Consensus ✓         |
| Haber 2 | Neutral  | Neutral  | Positive | 2/3 majority        |
| Haber 3 | Negative | Positive | Neutral  | Tutarsız / dışarıda |

Hem eğitim adayları hem dış test adayları ChatGPT, Claude ve Gemini ile yeniden etiketlenecek.

3/3 consensus geçen örnekler güvenilir çekirdek set olarak kullanılacak.

2/3 majority örnekler duyarlılık analizine ayrılacak; tutarsız örnekler analiz edilecek veya dışarıda bırakılacak.

# Devam planı 2: Eğitim veri setini kontrollü büyütme

Yeni eğitim havuzu ve yeni model seti birlikte kurulacak.

## Yeni öneri

Consensus S&P/Reuters-train + açık finansal sentiment setleri eğitim havuzuna kontrollü eklenebilir.

## Leakage kontrolü

**Train'e eklenen hiçbir örnek kilitli external testte kullanılmayacak. FinGPT ve Financial-RoBERTa için benchmark overlap denetlenecek.**

| Eski kurgu                   | Yeni kurgu                                                                                 |
|------------------------------|--------------------------------------------------------------------------------------------|
| Twitter + PhraseBank → Train | Twitter + PhraseBank + consensus S&P/Reuters-train + ek finansal sentiment setleri → Train |
| S&P/Reuters → External test  | Kilitli S&P/Reuters-test → External test                                                   |

**Araştırma sorusu: veri çeşitliliği + FinGPT + Financial-RoBERTa dışı genellemeyi güçlendirir mi?**

# Devam planı 3: Yeni deneyler

Mevcut bulgulardan doğrudan çıkan üç deney ailesi.

| Deney                     | Soru                                                                                             | Beklenen katkı                                            |
|---------------------------|--------------------------------------------------------------------------------------------------|-----------------------------------------------------------|
| Fine-tuning miktarı       | %0, %10, %25, %50, %75, %100 eğitim verisiyle ne değişiyor?                                      | Aşırı adaptation dış genellemeyi bozuyor mu?              |
| Veri + model kompozisyonu | Twitter / PhraseBank / S&P / Reuters / ek veri + FinGPT + Financial-RoBERTa eklenince ne oluyor? | Yeni veri + finans-özü model ailesi birlikte test edilir. |
| Label semantics           | Positive/Neutral/Negative karar kriterleri setler arasında aynı mı?                              | Reuters ve Neutral düşüşünün nedeni açıklanabilir.        |
| Calibration               | Model yanlışken ne kadar emin?                                                                   | Confidence güvenilirliği ölçülür.                         |

# Teşekkürler

Sorular ve görüşler

**Ana mesaj: İç test başarısı önemli; ancak finansal NLP’de gerçek değer, farklı veri kaynaklarında güvenilir genelleme sağlayabilmektir.**

# « EKLER »

Soru-cevap için literatür, model kaynakları ve deney ayrıntıları

# Literatür bağlamı

Finansal NLP’de başarı yalnızca mimari değil, veri ve etiket tasarımına bağlıdır.

| Alan                   | Literatürde genel bulgu                                       | Bu tezdeki karşılığı                                               |
|------------------------|---------------------------------------------------------------|--------------------------------------------------------------------|
| Transformer tabanlı SA | BERT/RoBERTa türü modeller bağlamsal temsil öğrenir.          | BERT, DistilBERT, RoBERTa ve FinBERT aynı görevde karşılaştırıldı. |
| Finans-özü modeller    | FinBERT gibi modeller finansal dil üzerinde adapte edilir.    | FinBERT’in hazır ve fine-tuned halleri ayrı ayrı incelendi.        |
| Domain shift           | Kaynak değişince model başarısı düşebilir.                    | S&P ve Reuters dış testleri ile ölçüldü.                           |
| Etiket semantiği       | Aynı etiket adları farklı anotasyon mantıklarına dayanabilir. | Neutral sınıfındaki düşüş ve PhraseBank etkisi ile tartışıldı.     |

**Literatürdeki boşluk: İç testte yüksek skor alan finansal sentiment modelinin farklı finansal kaynaklarda ne kadar sağlam kaldığı çoğu zaman yeterince ayrıştırılmıyor.**

# Finans-özgü modellerin eğitim kaynakları

Devam çalışması için modelin daha önce hangi veriyi gördüğü kritik.

| Model ailesi      | Bilinen eğitim / adaptasyon kaynakları                                                                   | Bizim çalışma açısından not                                                              |
|-------------------|----------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|
| ProsusAI FinBERT  | Reuters TRC2 ile domain-adaptive training; Financial PhraseBank ile sentiment fine-tuning                | PhraseBank ile doğrudan örtüşme var; bağımsız test olarak kullanılmadı.                  |
| Financial-RoBERTa | RoBERTa-Large; 10-K/10-Q/8-K, earnings call, CSR/ESG ve finans haberleriyle further training/fine-tuning | Genel RoBERTa'ya karşı finans alanına uyarlanmış RoBERTa alternatifi olarak denenebilir. |
| FinGPT sentiment  | Financial PhraseBank, FiQA, Twitter Financial News ve GPT-news tabanlı instruction sentiment verileri    | Bizim Twitter + PhraseBank verileriyle potansiyel örtüşme var.                           |

Kaynak notu: ProsusAI/finBERT; Financial-RoBERTa; FinGPT/fingpt-sentiment-train Hugging Face.

# Eğitim ve değerlendirme ayarları

Karşılaştırmalar aynı görev ve aynı metrik üzerinden yapıldı.

| Başlık     | Uygulama                                             |
|------------|------------------------------------------------------|
| Görev      | 3 sınıflı finansal sentiment classification          |
| Etiketler  | Negative / Neutral / Positive                        |
| Ana metrik | Macro-F1                                             |
| Robustluk  | 3 random seed: 42, 123, 2024                         |
| İç test    | 2.386 örnek; ana veri dağılımındaki performans       |
| Dış test   | S&P, Reuters, Synthetic; eğitimde kullanılmayan veri |

# Devam planı 4: Finansal model audit'i

FinBERT / Financial-RoBERTa / FinGPT gibi modellerin eğitim kaynakları sonuç yorumunu etkiler.

ProsusAI FinBERT: Reuters TRC2 + Financial PhraseBank bilgisi nedeniyle PhraseBank örtüşmesi dikkate alınmalı.  
Financial-RoBERTa: 10-K/10-Q/8-K, earnings call, CSR/ESG ve finans haberleriyle finans alanına uyarlanmış RoBERTa alternatifi sunar.  
FinGPT sentiment: PhraseBank ve Twitter Financial News gibi bizim verilerle örtüşebilecek kaynaklar içerir.  
Yeni model eklenirse, yalnızca skor değil; modelin hangi verileri daha önce görmüş olabileceği de raporlanacak.

**Bu adım, model karşılaştırmalarında data contamination / benchmark overlap riskini daha açık yönetmemizi sağlar.**