



Finansal Duygu Analizinde Model Genellemesi: FinBERT ve İnce Ayarlı Transformer Modellerinin Karşılaştırmalı İncelenmesi

Serkan Kaymak^{1*}, Mansur Alp Toçoğlu¹

¹ İzmir Kâtip Çelebi Üniversitesi, Fen Bilimleri Enstitüsü, Yazılım Mühendisliği Anabilim Dalı

Y220237016@ogr.ikc.edu.tr
mansuralp.tocoglu@ikcu.edu.tr

Özet – Finansal metinlerin otomatik duygu sınıflandırmasında alan-özü ön eğitim ile hedef veri setine özgü ince ayarın etkisi, üç sınıflı (olumlu, tarafsız, olumsuz) finansal duygu analizi problemi üzerinden deneysel olarak incelenmiştir. Hazır FinBERT; aynı modelin hedef veri setine ince ayarlanmış sürümü ve hedef veri setine ince ayarlanan BERT-base-uncased, DistilBERT-base-uncased ve RoBERTa-base modelleri, toplam 16.768 örnekten oluşan ana veri havuzunda (12.950 eğitim, 1.432 doğrulama ve 2.386 iç test örneği) aynı temel eğitim düzeniyle karşılaştırılmıştır. Modeller ayrıca S&P 500 (1.060 örnek), sentetik finansal haber (3.000 örnek) ve Reuters (5.000 örnek) dış test setlerinde değerlendirilmiş; yeniden üretilebilirlik 42, 123 ve 2024 rastgelelik tohumlarıyla ölçülmüştür. Ana ölçüt Macro-F1 olup sonuçlar McNemar testi, Holm düzeltmesi, 5.000 tekrarlı eşleştirilmiş bootstrap güven aralıkları, kaynak-bileşimi ablasyonu ve CPU çıkarım verimliliği analizleriyle desteklenmiştir. Hazır FinBERT 0,6794 Macro-F1 üretirken aynı modelin hedef veri setine ince ayarlanması bu değeri 0,8512'ye yükseltmiştir; üç tohum ortalamasında RoBERTa $0,8728 \pm 0,0068$ ile ilk sırada yer almıştır. İnce ayarlı FinBERT dış testlerde S&P 500'de 0,7723, sentetik sette 0,9746 ve Reuters'ta 0,6101 sonucunu vermiş; Reuters'ta hazır FinBERT (0,6866) en yüksek sonucu vermiştir. Ablasyonda yalnız Twitter verisiyle eğitilen RoBERTa (0,8810), Twitter + Financial PhraseBank koşulunu (0,8679) geçmiştir. Bulgular, tek bir modelin tüm finansal metin türlerinde evrensel olarak en iyi olmadığını ve veri kaynağı, etiket semantiği ve kaynak bileşiminin model sıralamasını değiştirebildiğini göstermektedir. Dış test etiketleri tek araştırmacı tarafından, bir büyük dil modelinin açıklama desteğiyle belirlenmiş; etiketleyiciler arası uyum istatistiksel olarak ölçülmemiştir. Bu nedenle dış test sonuçları mutlak performans iddiası değil, modeller arası göreceli karşılaştırma olarak yorumlanmalıdır.

Anahtar Sözcükler – finansal duygu analizi, FinBERT, BERT, RoBERTa, DistilBERT, ince ayar, model genellemesi, alan kayması, Transformer, etiketleme rubriği

1. GİRİŞ

Finansal piyasalar; şirket açıklamaları, haber akışları, analist raporları, merkez bankası duyuruları ve sosyal medya mesajları gibi yoğun bir metinsel bilgi üretmektedir. Bu içeriklerin elle incelenmesi veri hacmi ve hız nedeniyle sürdürülebilir değildir; doğal dil işleme yöntemleri, finansal metinlerden sistematik bilgi çıkarılmasını ve metinde ifade edilen ekonomik etkinin otomatik biçimde sınıflandırılmasını mümkün kılmaktadır. Finansal duygu analizi, genel amaçlı duygu analizinden daha karmaşıktır: finans dilinde olumsuz görünen bir sözcük bağlama göre olumlu bir piyasa sinyali taşıyabilir; aynı cümlede zıt yönlü bilgiler birlikte bulunabilir. Loughran ve McDonald, genel amaçlı sözlüklerin finansal metinlerde olumsuz işaretlediği kelimelerin yaklaşık dörtte üçünün finans bağlamında olumsuz sayılmadığını göstermiştir. [1] Ayrıca farklı veri setleri aynı "olumlu, tarafsız, olumsuz" sınıf adları altında farklı karar kuralları kullanabilmektedir; dilsel ton, ekonomik etki ve yükseliş-düşüş beklentisi etiketleme ölçütleri arasında belirgin bir uyumsuzluk bulunur. [2]

Araştırma sorularına karşılık gelen hipotezler şu şekilde tanımlanmıştır: H1: Hedef veri setine ince ayarlanan FinBERT, hazır FinBERT modelinden daha yüksek Macro-F1 performansı gösterir. H2: İnce ayarlı modellerin performans sıralaması farklı rastgelelik tohumlarında büyük ölçüde korunur. H3: İç testte en başarılı modelin üstünlüğü bağımsız dış testlerin tamamında korunmayacaktır. H4: Veri kaynağı ve etiket semantiği, özellikle tarafsız sınıfta gözlenen hata örüntülerini ve model sıralamasını etkiler. H5: Sentetik finansal metinlerde elde edilen performans, gerçek finansal haber verilerindeki dış test performansına kıyasla daha iyimser sonuçlar üretir.

Finans alanına uyarlanmış modeller, örneğin Aracı tarafından geliştirilen FinBERT modeli, alan terminolojisini öğrenerek güçlü bir başlangıç noktası sunar. [3] Bununla birlikte alan-özü ön eğitim, hedef veri setinin kendine özgü etiketleme ölçütlerini otomatik olarak öğrenmez. Bu çalışmanın amacı, hazır FinBERT modeli ile aynı modelin hedef veri setine ince ayarlanmış sürümünü ve hedef veri setine ince ayarlanan genel amaçlı BERT,

DistilBERT ve RoBERTa modellerini performans, yeniden üretilebilirlik ve farklı finansal metin kaynaklarına genelleme açısından karşılaştırmaktır. Çalışma beş araştırma sorusu etrafında yapılandırılmıştır: hedefe özgü ince ayarın hazır FinBERT kullanımına göre getirisi; ince ayarlı modellerin üç tohum altındaki performans kararlılığı; iç test sıralamasının bağımsız dış testlerde korunup korunmadığı; veri kaynağı ve etiket semantiğinin, özellikle tarafsız sınıftaki hata örüntülerine etkisi; sentetik veri performansının gerçek haber genellemesini ne ölçüde temsil ettiği. Bu sorulara karşılık gelen beş hipotez (H1–H5) ilgili bölümlerde test edilmiş ve sonuç bölümünde özetlenmiştir.

Çalışmanın katkıları şunlardır: (i) alan odaklı ön eğitim ile hedefe özgü ince ayarın, FinBERT'in kendisi de ince ayarlanarak daha dengeli bir deneysel tasarımda karşılaştırılması; (ii) iç test, yakın alan dış testi ve uzak alan dış testinin birlikte değerlendirilmesi; (iii) üç farklı tohumla yeniden üretilebilirlik ölçümü; (iv) örnek-bazlı istatistiksel testler; (v) etiket semantiği uyumsuzluğunun kaynak-bileşimi ablasyonu ile deneysel olarak sınanması; (vi) performansın yanında parametre sayısı, CPU işlem hızı ve gecikme ile verimlilik analizi; (vii) dış test etiketleme ölçütlerinin post-hoc olarak belgelenmesi ve veri hazırlama akışının tekrarlanabilir biçimde sunulması.

II. İLGİLİ ÇALIŞMALAR

A. Finansal duygu analizi ve sözlük yaklaşımları

Erken dönem araştırmalar finansal sözlükler, n-gramlar, destek vektör makineleri ve lojistik regresyon üzerinde yoğunlaşmıştır. Loughran ve McDonald'ın finans sözlüğü çalışması, genel sözlüklerin finansal metinlerde olumsuz işaretlediği kelimelerin yaklaşık dörtte üçünün finans bağlamında olumsuz sayılmadığını göstermiştir. [1] Sözlük yaklaşımları sözcük sırası, olumsuzlama, hedef varlık ve karışık bilgi gibi bağlamsal unsurları sınırlı temsil ettiğinden, bağlamsal dil modelleri öne çıkmıştır. Alanın temel karşılaştırma ölçütlerinden Financial PhraseBank, uzmanlar tarafından etiketlenen finans haber cümlelerinden oluşmaktadır. [4]

B. Transformer tabanlı modeller ve model aileleri

BERT, maskeli dil modelleme amacıyla çift yönlü bağlamsal temsiller öğrenmiş ve çoğu doğal dil işleme görevinde minimal görev-özel mimari değişiklikle en yüksek performansa ulaşmıştır. [5] Aracı, genel BERT modelini finansal metinlerde ince ayar yoluyla FinBERT'e dönüştürmüş ve finansal duygu veri setlerinde güçlü sonuçlar elde etmiştir. [3] Yang ve arkadaşları ise büyük ölçekli finansal iletişim metinleriyle ön eğitilen bir FinBERT sürümü sunmuş ve genel amaçlı BERT'e göre üstünlüğünü finansal sınıflandırma görevlerinde göstermiştir. [6] RoBERTa, BERT ön eğitim prosedürünü daha fazla veri, dinamik maskeleyme, NSP kaybının kaldırılması ve daha büyük yığın boyutlarıyla optimize etmiştir. [7] DistilBERT ise bilgi damıtma yoluyla BERT'in boyutunu %40 azaltırken dil anlama kapasitesinin %97'sini koruyan ve %60 daha hızlı bir sürümünü sunmuştur. [8]

C. Sıfır örnekli sınıflandırma

NLI tabanlı sıfır örnekli sınıflandırma, hedef göreve ait etiketli eğitim örneği olmadan tahmin yapmayı amaçlar ve düşük maliyetli bir başlangıç ölçütü sağlar. [9] Ancak genel alan NLI modellerinin finansal metinlere taşındığında belirgin performans kaybı yaşadığı gösterilmiştir; FinNLI karşılaştırma setinde alan kaymasının genel alan NLI performansını önemli ölçüde düşürdüğü raporlanmıştır. [10] Bu nedenle bu çalışmada sıfır örnekli sonuçlar tamamlayıcı/keşifsel olarak ele alınmıştır.

D. Alan kayması ve dış test

Rastgele iç test ayırımı, aynı veri setine özgü kalıpların öğrenilmesi nedeniyle gerçek genellemeyi olduğundan yüksek gösterebilir. Guo ve arkadaşları, üç yıllık gerçek finansal sosyal medya verisi üzerinde ince ayarlı modellerin zamansal dağılım kayması karşısında genel performans kaybı yaşadığını göstermiştir. [11] Bu bulgular doğrultusunda literatürdeki araştırma boşluğu, en iyi iç test modelinin hangi koşullarda dış test üstünlüğünü koruduğu ve alan odaklı FinBERT'in hangi metin türlerinde yeniden avantaj sağladığı sorularında konumlanmaktadır.

E. Etiketleme metodolojisi, çoklu etiketleyici ve etiketleyiciler arası uyum


Duygu analizi veri setlerinin kalitesi, büyük ölçüde etiketleme protokolünün tasarımına bağlıdır. Literatürde üç temel yaklaşım öne çıkar: (i) uzman etiketleme, (ii) çoklu etiketleyici ve uzlaş (majority vote veya adjudication), (iii) crowdsourcing tabanlı etiketleme. Uzman etiketleme, alan bilgisi gerektiren finansal metinlerde yüksek nitelik sağlar; ancak maliyet ve ölçeklenebilirlik sınırlıdır. Crowdsourcing, daha geniş örnekleme imkânı sunarken etiket gürlüğü riskini artırır. [12] Çoklu etiketleyici protokollerinde etiketleyiciler arası uyum, yüzde uyum (observed agreement) ve Cohen's Kappa [13] veya ikiden fazla etiketleyici için Fleiss' Kappa [14] ve Krippendorff alpha [15] ile ölçülür. Kappa değerleri, şans eseri uyumayı düzelttiği için yüzde uyuma göre daha muhafazakâr bir tutarlılık göstergesidir; 0,61–0,80 aralığı “belirgin uyum”, 0,81 ve üzeri “neredeyse tam uyum” olarak yorumlanır. [16] Duygu analizinde sınıf sınırlarının öznelliği, etiketleyiciler arası uyumu zorlaştırabilmektedir. [17] Son yıllarda büyük dil modelleri (LLM) etiketleme sürecine yardımcı araç olarak girmiştir; ancak LLM etiketlerinin insan etiketleriyle uyumu görev ve alan bağımlıdır ve LLM'lerin tek başına etiket kaynağı olarak kullanılması

literatürde tartışmalıdır. [18] Bu çalışmada dış test etiketleri tek araştırmacı tarafından, bir LLM'nin açıklama desteğiyle belirlenmiştir. Çoklu etiketleyici ve Kappa tabanlı uyum ölçümü uygulanmamıştır; bu durum çalışmanın sınırlılıkları bölümünde açıkça ele alınmıştır.

III. YÖNTEM

A. Araştırma tasarımı

Çalışma nicel, deneysel ve karşılaştırmalı bir tasarıma sahiptir. İlk aşamada hazır FinBERT temel model olarak değerlendirilmiş; BERT, DistilBERT ve RoBERTa hedef veri setinde ince ayarlanmıştır. İkinci aşamada FinBERT'in kendisi de aynı hedef veri setine ince ayarlanmıştır. Üçüncü aşamada dört ince ayarlı model 42, 123 ve 2024 rastgelelik tohumları altında karşılaştırılmıştır. Dördüncü aşamada modeller S&P 500, sentetik ve Reuters dış testlerinde değerlendirilmiştir. Beşinci aşamada RoBERTa için kaynak-bileşimi ablasyonu yürütülmüş; son olarak hata örüntüleri ve CPU çıkarım verimliliği incelenmiştir. Şekil 1, veri hazırlamadan dış test ve performans-verimlilik analizine kadar deney akışını özetlemektedir.



Şekil 1. Deneysel araştırma ve değerlendirme akışı.

B. Veri setleri ve veri hazırlama akışı

Veri hazırlama akışı. Çalışmanın veri hazırlama süreci beş adımda yürütülmüştür.

Kaynak seçimi. Ana hedef veri olarak Twitter Financial News Sentiment (TFNS) ve yardımcı eğitim verisi olarak Financial PhraseBank (FPB) seçilmiştir. Seçim ölçütleri: üç sınıflı etiket şeması (olumsuz/tarafsız/olumlu), açık erişim, finans alanına uygunluk ve model ön eğitiminde kullanılmamış olma (TFNS için). FPB'nin ProsusAI/finbert ön eğitiminde kullanılmış olması nedeniyle FPB dış test kümelerine alınmamış, yalnızca eğitim havuzunda yardımcı veri olarak tutulmuştur.

Toplama ve birleştirme. TFNS ve FPB örnekleri HuggingFace Datasets üzerinden indirilmiş; ortak şema (metin, etiket) altında birleştirilmiştir.

Temizleme. URL, mention (@kullanıcı), HTML etiketi ve kontrol karakterleri kaldırılmış; boş ve yinelenen örnekler ayıklanmıştır. Temizleme sonrası TFNS'te 11.928, FPB'de 4.840 örnek kalmıştır ve toplam 16.768 örnek elde edilmiştir.

Bölümleme. İç test yalnızca TFNS üzerinden katmanlı örnekleme ile ayrılmıştır. Eğitim/doğrulama/iç test oranları sırasıyla %77,2 / %8,5 / %14,2'dir. Bölümleme işlemi 42 numaralı rastgelelik tohumuyla yapılmıştır.

Dış test setleri. S&P 500 (1.060 başlık), sentetik (3.000 örnek) ve Reuters (5.000 haber) dış test setleri eğitim havuzuna dâhil edilmemiştir.

Ana veri havuzu. TFNS (11.928) ve FPB (4.840) örneklerinden oluşur. Eğitim kümesi 12.950 (TFNS 8.110 + FPB 4.840), doğrulama 1.432, iç test 2.386 örnek içerir. İç test yalnızca TFNS'ten ayrılmıştır; FPB test kümesine alınmamıştır.

Dış test setleri. S&P 500 seti 1.060 şirket haber başlığından; sentetik set her sınıfta 1.000 örnek olacak şekilde dengeli 3.000 finansal haber örneğinden; Reuters seti 5.000 editoryal kurumsal haberden oluşmaktadır.

Dış test alanlarının tanımı. S&P 500, ana eğitim verilerindeki kısa ve piyasa yönelimli finansal metinlere görece daha yakın bir dağılımı temsil ettiği için yakın alan dış test olarak değerlendirilmiştir. Reuters ise profesyonel ve editoryal kurumsal haber yapısı bakımından ana eğitim dağılımından daha farklı olduğundan uzak alan dış test olarak ele alınmıştır. Sentetik set ise kontrollü bir tanışal test olarak kullanılmıştır.

Tablo 1. Veri setleri, kaynakları, rolleri ve sınıf dağılımları.

Veri seti	Kaynak	Rol	N	Negatif	Tarafsız	Pozitif	Etiketleme
Twitter Financial News (TFNS)	HuggingFace (zeroshot/twitter-financial-news-sentiment)	Ana hedef	11.928	1.781	8.343	1.804	Hazır 3 sınıf
Financial PhraseBank (FPB)	Malo et al. (2014)	Yardımcı eğitim	4.840	612	2.272	1.956	Uzman, 5–8 oy

Veri seti	Kaynak	Rol	N	Negatif	Tarafsız	Pozitif	Etiketleme
Ana havuz (toplam)	—	Eğitim/doğrulama/iç test	16.768	2.393	10.615	3.760	—
Eğitim	—	Eğitim	12.950	1.820	8.137	2.993	—
Doğrulama	—	Model seçimi	1.432	215	929	288	—
İç test	—	Aynı kaynak test	2.386	358	1.549	479	TFNS etiketi
S&P 500	Şirket haber başlıkları	Yakın alan dış test	1.060	323	339	398	LLM açıklama desteği + araştırmacı onayı
Sentetik	Koşullu LLM üretimi	Tanısal test	3.000	1.000	1.000	1.000	Üretim koşulu
Reuters	Editöryal kurumsal haber	Uzak alan dış test	5.000	1.579	1.146	2.275	LLM açıklama desteği + araştırmacı onayı

Not. Twitter etiketi veri kartında üç sınıf tanımlanır; etiketleyici profili, uzmanlık düzeyi ve uzlaşi süreci veri kartında açıklanmamaktadır. Bu, ana veri setinin bilinen bir sınırlılığıdır.

C. Etiketleme ölçütleri ve post-hoc dokümanite edilmiş rubrik

S&P 500 ve Reuters dış test setlerinin etiketleri, etiketleme sürecinde prospektif bir rubrik kullanılmadan, tek araştırmacı tarafından LLM’nin açıklama desteğiyle belirlenmiştir. Etiketleme süreci sonrasında, fiilen uygulanan karar ölçütleri aşağıdaki post-hoc rubrikte belgelenmiştir. Rubrik, prospektif bir etiketleme aracı olarak değil, uygulanan kararların şeffaf biçimde raporlanması amacıyla sunulmaktadır.

Ortak ilke. Etiket, metnin dilsel tonu değil, metnin ilgili şirketin piyasa değeri veya yatırımcı beklentisi üzerindeki yönlü etkisi üzerinden verilmiştir. Belirsizlik durumunda tarafsız sınıfına başvurulmuştur.

Pozitif (olumlu). Metin, ilgili şirket veya piyasa için net ve yönlü bir olumlu etki taşır.

Örnek: “Company X reported quarterly earnings above analyst expectations.”

Sınır durum: “Revenue increased 10%, in line with expectations.” → Tarafsız (beklentiye uygun; yönlü sürpriz yok).

Negatif (olumsuz). Metin, ilgili şirket veya piyasa için net ve yönlü bir olumsuz etki taşır.

Örnek: “Company X cut its full-year guidance.”

Sınır durum: “Jobless claims drop below consensus.” → Pozitif (düşük işsizlik başvurusu olumlu makro sinyal; “drop” sözcüğü yüzeysel olarak olumsuz olsa da etki olumludur).

Tarafsız. Metin yönlü bir piyasa etkisi taşımaz; açıklayıcı, betimleyici, nötr kurumsal duyuru niteliğindedir veya karışık sinyaller dengededir.

Örnek: “Company X announced the appointment of a new CFO.”

Sınır durum: “Beef sales fell 8%; chicken rose 4.5%.” → Karışık sinyal, net yön yok → Tarafsız.

Karar sırası. (1) Metinde yönlü ekonomik etki var mı? (2) Etki hangi yönde? (3) Etki net mi, yoksa karışık/dengeli mi? Karışık veya belirsizse tarafsız. Bu sıra, sınıflar arasındaki karar sınırının tarafsız etrafında yoğunlaşmasına yol açmaktadır; bulgular bölümündeki hata örüntüleri bu tasarımla tutarlıdır.

D. Model aileleri ve sınıflandırma

Çalışmada kullanılan modeller, yalnızca isim üzerinden değil, ait oldukları model aileleri ve alt kırımlar dikkate alınarak sınıflandırılmıştır. Ana karşılaştırma modelleri Transformer tabanlı encoder-only dil modelleridir (BERT, DistilBERT, RoBERTa ve FinBERT). Sıfır örnekli karşılaştırmada kullanılan BART-large-MNLI ise encoder-decoder (seq2seq) mimarisine sahiptir. Bu nedenle ana ince ayar karşılaştırmasından ayrı, tamamlayıcı bir sıfır örnekli referans olarak değerlendirilmiştir.

Tablo 2. Model aileleri ve sınıflandırma.

Model	Aile	Mimari	Parametre	Ön eğitim / model uyarlaması	Alan	Görev
BERT-base-uncased	BERT	Encoder-only, 12 katman	~110M	Wikipedia BooksCorpus	Genel	MLM + NSP
DistilBERT-base-uncased	BERT (damıtılmış)	Encoder-only, 6 katman	~67M	BERT’ten bilgi damıtma	Genel	MLM
RoBERTa-base	BERT türevi	Encoder-only, 12 katman	~125M	BookCorpus Wikipedia CC-News OpenWebText Stories (~160 GB)	Genel	MLM (NSP yok)
ProsusAI/finbert	BERT + alan uyarlaması	Encoder-only, 12 katman	~110M	Reuters TRC2 + Financial PhraseBank	Finans	MLM + duygu ince ayarı

Model	Aile	Mimari	Parametre	Ön eğitim / model uyarlaması	Alan	Görev
BART-large-MNLI	BART (encoder-decoder)	Seq2seq	~400M	MNLI	Genel	NLI (sıfır örnekleli)
BERT-base-MNLI, RoBERTa-base-NLI, DistilBERT-base-MNLI	BERT ailesi + NLI	Encoder-only	67–125M	MNLI	Genel	NLI (sıfır örnekleli)

Hazır FinBERT alan-özgü ön eğitimin temel modeli; hedef veri setine ince ayarlı FinBERT ise alan ön eğitimi ile görev-özel ince ayarın birleşik etkisini ölçen model olarak ele alınmıştır.

E. Sentetik veri üretimi

Bu çalışmada “sentetik veri” ile “LLM tarafından etiketlenen gerçek veri” birbirinden ayrılmıştır:

Sentetik set (3.000 örnek). Bir büyük dil modeli tarafından, her sınıftan 1.000 örnek olacak şekilde koşullu üretimle oluşturulmuştur. Üretimde sınıf koşulu prompt’a açıkça verilmiş; örnekler kısa finansal haber cümlesi biçiminde istenmiştir. Üretim çıktıları, yinelenen örnekler ve üç sınıfa net biçimde oturmeyen cümleler ayıklanarak filtrelenmiştir. Set, gerçek dağılımı temsil etmeyen, kontrollü bir tanısıl stres testi olarak kullanılmıştır. İnsan doğrulaması sistematik olarak yapılmamıştır; bu durum sınırlılık olarak belirtilmiştir.

LLM-etiketli gerçek veri (S&P 500 ve Reuters). Metinler gerçek kaynaklardan alınmış; etiketler tek araştırmacı tarafından LLM açıklama desteğiyle atanmıştır. Bu setler “sentetik” değildir.

Sentetik setin amacı, modellerin açık duygu ipuçları içeren kontrol örneklerindeki davranışını ölçmek ve gerçek dışı testlerle karşıtlık kurmaktır. Sentetik performans, gerçek dünya genellemesi göstergesi olarak yorumlanmamıştır.

F. Eğitim ayarları

Aşağıdaki ortak ayarlar ince ayar deneylerinde kullanılmıştır. Model seçimi doğrulama Macro-F1 değerine göre yapılmış; ana deneyde 42, yeniden üretilebilirlik analizinde 123 ve 2024 numaralı rastgelelik tohumları kullanılmıştır. Eğitim ve çoklu tohum çalıştırmaları CPU ortamında yürütülmüştür.

Tablo 3. Eğitim ve deney ayarları.

Ayar	Değer
Eğitim dönemi (Epoch)	4
Öğrenme oranı	2×10^{-5}
Eğitim yığın boyutu	16
Değerlendirme yığın boyutu	32
Maksimum dizi uzunluğu	128
Ağırlık azaltma (Weight decay)	0,01
Sınıf ağırlıkları	Kullanıldı
Ana rastgelelik tohumu	42
Ek tohumlar	123 ve 2024
Model seçimi	Doğrulama Macro-F1
Çalıştırma ortamı	CPU
Python	3.14.2
PyTorch	2.11.0+cpu
Transformers	5.8.1
Datasets	4.5.0
scikit-learn	1.8.0

G. Değerlendirme ölçütleri ve istatistiksel analiz

Ana ölçüt, her sınıfın F1 değerini eşit ağırlıkla değerlendiren ve baskın tarafsız sınıfın doğruluk üzerindeki etkisini sınırlayan Macro-F1'dir. Doğruluk, kesinlik, duyarlılık ve ağırlıklı F1 değerleri de raporlanmıştır. Aynı test örneklerinde iki modelin doğru/yanlış kararları McNemar testiyle karşılaştırılmış, çoklu karşılaştırmalar için Holm düzeltmesi uygulanmıştır. Macro-F1 farkları, aynı örneklerin birlikte yeniden örneklenmesine dayanan 5.000 tekrarlı eşleştirilmiş bootstrap yöntemiyle %95 güven aralığı üzerinden incelenmiştir. Ayrıca model parametre sayısı, CPU örnek/saniye ve örnek başına gecikme performans-verimlilik analizinde kullanılmıştır.

H. Etik, geçerlik ve tekrarlanabilirlik


Etik. S&P 500 ve Reuters dış test setlerinin nihai etiketleri araştırmacı tarafından belirlenmiş; etiketleme sırasında LLM açıklama ve karar desteği sağlayan yardımcı bir araç olarak kullanılmıştır. LLM, etiket kararını tek başına vermemiş; araştırmacı nihai etiketi onaylamıştır. Etiketleme tek araştırmacı tarafından gerçekleştirildiğinden etiketleyiciler arası uyum katsayısı (yüzde uyum, Cohen’s Kappa, Krippendorff alpha) hesaplanmamıştır. Bu durum, çalışmanın temel geçerlik sınırlılığıdır.

Geçerlik. İç geçerlik, aynı eğitim düzeni, sabit hiperparametreler ve üç rastgelelik tohumu ile desteklenmiştir. Dış geçerlik, iç testten bağımsız üç dış test seti (S&P 500, sentetik, Reuters) ile sınanmıştır. Yapı geçerliği, Macro-F1 ve sınıf bazlı ölçütlerle değerlendirilmiştir. Etiket geçerliği, tek etiketleyici ve LLM desteği nedeniyle sınırlıdır; bu nedenle dış test sonuçları keşifsel olarak yorumlanmalıdır.

IV. BULGULAR

A. Hazır FinBERT temel model


Hazır FinBERT, iç test kümesinde 0,7323 doğruluk ve 0,6794 Macro-F1 (ağırlıklı F1: 0,7400) elde etmiştir. Hata analizinde en belirgin örüntü, gerçek etiketi tarafsız olan çok sayıda örneğin yüksek güvenle negatif olarak tahmin edilmesidir; bu durum, modelin Financial PhraseBank benzeri genel finansal ton mantığı ile hedef veri setinin piyasa yönü odaklı etiket mantığı arasındaki farkla açıklanmıştır. Şekil 2, iç testte RoBERTa ve ince ayarlı FinBERT'in öne çıktığını göstermektedir.



Şekil 2. Modellerin iç test Macro-F1 sonuçları (tohum 42).

B. İç test sonuçları

İnce ayarlı bütün modeller hazır FinBERT'in 0,6794 sonucunu belirgin biçimde aşmıştır. FinBERT'in kendisinin hedef veri setine ince ayarlanması Macro-F1'i 0,8512'ye yükseltmiştir; buna rağmen 42 numaralı tohumda en yüksek iç test sonucu RoBERTa-base modelinde 0,8651 ile elde edilmiştir. İnce ayarlı FinBERT 0,8512 ile ikinci, BERT 0,8378 ile üçüncü ve DistilBERT 0,8218 ile dördüncü sırada yer almıştır. Şekil 3, üç tohum altında model sıralamasının büyük ölçüde korunduğunu göstermektedir.



Şekil 3. Üç rastgelelik tohumu altında Macro-F1 ortalamaları ve standart sapmalar.

Tablo 4. İnce ayarlı modellerin 42 numaralı tohumdaki iç test sonuçları.

Model	Test doğruluğu	Test Macro-F1	Test Weighted-F1
RoBERTa-base	0,8906	0,8651	0,8918
İnce ayarlı FinBERT	0,8818	0,8512	0,8829
BERT-base-uncased	0,8722	0,8378	0,8733
DistilBERT-base-uncased	0,8583	0,8218	0,8593
Hazır FinBERT	0,7323	0,6794	0,7400

C. Çoklu tohum sonuçları ve yeniden üretilebilirlik

Üç tohumun ortalamasında model sıralaması büyük ölçüde korunmuştur: RoBERTa $0,8728 \pm 0,0068$; ince ayarlı FinBERT $0,8480 \pm 0,0028$; BERT $0,8396 \pm 0,0023$; DistilBERT $0,8231 \pm 0,0028$. Düşük standart sapmalar, tek tohumlu sonuçların genel sıralamayı büyük ölçüde yansıttığını desteklemektedir.

Tablo 5. Üç rastgelelik tohumu için iç test performansı (ortalama $\pm$ standart sapma).


Model	Doğruluk	Macro-F1	Weighted-F1
RoBERTa-base	0,8975 $\pm$ 0,0059	0,8728 $\pm$ 0,0068	0,8984 $\pm$ 0,0057
İnce ayarlı FinBERT	0,8790 $\pm$ 0,0025	0,8480 $\pm$ 0,0028	0,8799 $\pm$ 0,0026
BERT-base-uncased	0,8736 $\pm$ 0,0021	0,8396 $\pm$ 0,0023	0,8743 $\pm$ 0,0017
DistilBERT-base-uncased	0,8601 $\pm$ 0,0028	0,8231 $\pm$ 0,0028	0,8610 $\pm$ 0,0029

123 ve 2024 numaralı tohumlarda aynı 2.386 örnek üzerinde eşleştirilmiş istatistiksel testler yapılmıştır. RoBERTa'nın ince ayarlı FinBERT'e üstünlüğü her iki tohumda da hem Holm-düzeltilmiş McNemar testinde anlamlı kalmış hem eşleştirilmiş bootstrap güven aralıklarında sıfırı dışlamıştır; iki model arasındaki fark yaklaşık 0,03 Macro-F1 düzeyindedir. Buna karşılık ince ayarlı FinBERT ile BERT arasındaki fark iki tohumda da anlamlı değildir; BERT ile DistilBERT arasındaki fark ise tohum duyarlıdır (bir tohumda Holm $p=0,009323$ ile güven aralığı sıfırı dışlarken diğerinde Holm $p=0,214522$ ile sıfırı içermektedir).

D. Dış test sonuçları

Model sıralaması dış test alanlarına göre belirgin biçimde değişmiştir.

Test alanlarına göre Macro-F1 karşılaştırması



Şekil 4. Modellerin test alanlarına göre Macro-F1 karşılaştırması.

Şekil 4, dış test alanlarına geçildikçe model sıralamasının değişebildiğini görsel olarak ortaya koymaktadır. Tablo 6 ise bu karşılaştırmanın kesin Macro-F1 değerlerini sunmaktadır.

Tablo 6. Model ve test alanı bazında Macro-F1 sonuçları.

Model	İç test	S&P 500	Sentetik	Reuters
Hazır FinBERT	0,6794	0,7521	0,9551	0,6866
DistilBERT	0,8218	0,7510	0,9581	0,5869
BERT	0,8378	0,7549	0,9742	0,6131
RoBERTa	0,8651	0,8145	0,9957	0,6388
İnce ayarlı FinBERT	0,8512	0,7723	0,9746	0,6101

S&P 500 dış testinde ($N=1.060$) RoBERTa 0,8145 Macro-F1 ile ilk sırayı korumuş; ince ayarlı FinBERT 0,7723 ile hazır FinBERT'in 0,7521 sonucunu 0,0201 puan aşmıştır. Ancak eşleştirilmiş karşılaştırmada bu fark istatistiksel olarak anlamlı değildir (Holm $p=0,1678$; hazır – ince ayarlı $\Delta F1=-0,0201$; %95 GA $[-0,0492; 0,0080]$). Sentetik sette bütün modeller çok yüksek başarı göstermiş; tüm modeller 0,9551 ile 0,9957 arasında Macro-F1 üretmiş, RoBERTa 0,9957 ile ilk sırada yer almıştır. Bu sıkışmış yüksek performans aralığı, sentetik örneklerde duygu ipuçlarının gerçek dış testlere göre daha açık olduğunu göstermektedir. Reuters dış testinde ($N=5.000$) model sıralaması köklü biçimde değişmiş; hazır FinBERT 0,6866 Macro-F1 ile en başarılı model, RoBERTa 0,6388 ile ikinci olmuştur. Hazır FinBERT'in ince ayarlı FinBERT'e üstünlüğü eşleştirilmiş analizde güçlü biçimde desteklenmiştir ($\Delta \text{Macro-F1}=+0,0765$; Holm $p \approx 1,37 \times 10^{-32}$; %95 GA $[0,0610; 0,0923]$).

Reuters sonucunun yorumunda veri kontaminasyonu olasılığı. ProsusAI/finbert, Reuters TRC2 alt kümesi ile alan uyarlaması görmüştür. Bu çalışmanın Reuters dış testi editoryal kurumsal haberlerden oluşmaktadır ve ön eğitim verisiyle kısmi örtüşme olasılığı deneysel olarak dışlanamamıştır. Bu nedenle Reuters'ta hazır FinBERT'in üstünlüğü, alan bilgisinin yanı sıra olası örtüşmeden de kaynaklanıyor olabilir; sonuç bu sınırlılıkla birlikte yorumlanmalıdır.

E. Sıfır örnekli modeller

S&P 500 üzerinde en iyi sıfır örnekli sonuç BART-large-MNLI tarafından 0,6594 doğruluk ve 0,5580 Macro-F1 ile elde edilmiştir; ancak tarafsız sınıf F1 değeri 0,1199 düzeyinde kalmıştır. RoBERTa-base NLI 0,6085/0,4913, BERT-base MNLI 0,5057/0,4033 ve DistilBERT-base MNLI 0,4679/0,3880 doğruluk/Macro-F1 üretmiştir; hepsinde tarafsız sınıf F1 değeri çok düşüktür (sırasıyla 0,0233, 0,0058 ve 0,0776). Sıfır örnekli yaklaşım, denetimli modellerin eşdeğeri değil, düşük başlangıç maliyetli tamamlayıcı bir referanstır. Şekil 5, DistilBERT'in hız avantajını ve RoBERTa'nın yüksek Macro-F1 değerini birlikte göstermektedir.

F. Sınıf bazlı hata örüntüleri

İnce ayarlı FinBERT iç testte 2.386 örneğin 282'sini yanlış sınıflandırmıştır; en sık hata yönleri tarafsız → pozitif (78; %27,66) ve tarafsız → negatif (75; %26,60) olmuştur. Negatif → tarafsız ve pozitif → tarafsız geçişleri 52'ser örnekle hataların ayrı ayrı %18,44'ünü; pozitif → negatif 17 (%6,03) ve negatif → pozitif 8 (%2,84) örnekle küçük payları oluşturmuştur. Hataların 217'si (%77,0) en az 0,90, 196'sı (%69,5) en az 0,95 ve 137'si (%48,6) en az 0,99 tahmin güvenine sahiptir; bu yüksek güvenli yanlışlar, bazı başlıkların sistematik biçimde farklı etiket semantiğiyle yorumlandığını göstermektedir. S&P 500 dış testinde tarafsızdan negatife hata oranı hazır FinBERT için %10,62 (36/339) iken RoBERTa için %5,60 (19/339), BERT için %4,42 (15/339) ve DistilBERT için %4,72 (16/339) düzeyindedir.

G. Kaynak-bileşimi ablasyonu


RoBERTa, 42 numaralı tohumda iki eğitim koşuluyla karşılaştırılmıştır: yalnız Twitter eğitim verisi (n=8.110) ve Twitter + Financial PhraseBank birleşimi (n=12.950). Yalnız Twitter koşulu iç testte 0,8810, birleşik koşul 0,8679 Macro-F1 üretmiştir (fark -0,0132). Reuters'ta fark -0,0160 (0,6465'e karşı 0,6305); S&P 500 ablasyonunda ise -0,0021 (0,7989'a karşı 0,7968) olmuştur. S&P 500 ablasyonu, iki eğitim koşulunun aynı 1.030 ortak örnek üzerindeki değerlendirmesine dayanmaktadır; bu değerler, ana S&P 500 değerlendirmesinin 1.060 örneğiyle mutlak performans açısından karşılaştırılmamış, yalnızca iki koşul arasındaki kaynak-bileşimi etkisini ölçmek amacıyla kullanılmıştır. Daha fazla fakat farklı kaynak ve etiket semantiği taşıyan eğitim verisi otomatik olarak daha iyi genelleme sağlamamıştır.

Tablo 7. RoBERTa kaynak-bileşimi ablasyon sonuçları (tohum 42).

Veri seti	Yalnız Twitter	Twitter + PhraseBank	Fark
İç test (N=2.386)	0,8810	0,8679	-0,0132
Reuters (N=5.000)	0,6465	0,6305	-0,0160
S&P 500 ablasyon (N=1.030)	0,7989	0,7968	-0,0021

H. Model verimliliği

CPU üzerinde 1.000 iç test örneği, yığın boyutu 32 ve üç tekrar kullanılarak yapılan çıkarım ölçümünde DistilBERT 66,96 milyon parametreyle (BERT'in yaklaşık %61'i) 70,30 örnek/s hızına ulaşmış; BERT'in 31,37 örnek/s hızının yaklaşık 2,24 katı işlem gücü sağlamıştır. RoBERTa 124,65 milyon parametreyle en büyük model olmasına karşın 35,91 örnek/s ile iç testte en yüksek Macro-F1'i vermiştir. Ölçümler donanım ve yazılım ortamına özgü olduğundan mutlak hızdan çok modeller arası göreceli farklar yorumlanmıştır. Şekil 5, iç test Macro-F1 ile CPU çıkarım hızı arasındaki dengeyi görselleştirerek performans ve işlem maliyeti arasındaki farkı ortaya koymaktadır.



Şekil 5. İç test Macro-F1 ile CPU çıkarım hızı arasındaki denge.

Tablo 8. CPU çıkartım verimliliği ve iç test performansı.

Model	Parametre (M)	CPU örnek/s	Gecikme (ms/örnek)	İç test Macro-F1
Hazır FinBERT	109,48	30,81	32,46	0,6794
İnce ayarlı FinBERT	109,48	28,84	34,68	0,8512
BERT	109,48	31,37	31,88	0,8378
DistilBERT	66,96	70,30	14,23	0,8218
RoBERTa	124,65	35,91	27,85	0,8651

V. TARTIŞMA

A. Hedefe özgü ince ayarın etkisi

Hazır FinBERT'in 0,6794 Macro-F1 değerinin aynı veri setinde ince ayar sonrası 0,8512'ye yükselmesi, görev-özel öğrenmenin güçlü etkisini doğrulamaktadır. Kaynak-ablasyonu ise kritik unsurun yalnız veri miktarı değil, hedef dağılım ve etiketleme ölçütlerine uygun öğrenme olduğunu göstermiştir: yalnız Twitter ile eğitilen RoBERTa, Twitter + Financial PhraseBank koşulunu aşmıştır. RoBERTa'nın üç tohum ortalamasındaki üstünlüğü istatistiksel olarak sağlamdır; buna karşılık ince ayarlı FinBERT ile BERT arasındaki fark anlamlı değildir. Bu sonuç, alan uyarlaması ve görev uyumu ayrımının deneysel kanıtıdır: alan ön eğitimi avantajlı bir başlangıç noktası sunmakla birlikte tek başına model seçiminde yeterli bir ölçüt değildir; güçlü genel amaçlı ön eğitim, hedefe ince ayar ile birleştğinde alan-özel bir modeli geçebilmektedir.

B. Genelleme ve alan kayması

S&P 500'de RoBERTa'nın 0,8145 ile önde kalması, ana dağılıma benzer metinlerde temsil gücünün aktarılabildiğini gösterirken; Reuters'ta hazır FinBERT'in 0,6866 ile yeniden birinci olması ve ince ayarlı FinBERT'in 0,6101'e gerilemesi, görev-özel uyarlamanın bir tür dağılım uzmanlaşması yaratabildiğini ortaya koymaktadır. Profesyonel ve editöryal Reuters dili, FinBERT'in finans alanı ön eğitimine daha yakın bir dil taşıırken hedef ince ayar verisi kısa ve piyasa yönelimli sosyal medya örneklerine daha yakındır. Bu bulgu, zamansal ve dağılımsal kayma altında ince ayarlı modellerin örneklem dışı performans kaybı yaşayabildiğini gösteren çalışmalarla uyumludur. Ablasyonda PhraseBank eklenmesinin Reuters performansını 0,6465'ten 0,6305'e düşürmesi de kaynak karışımının genelleme etkisinin doğrusal olmadığını desteklemektedir. Reuters sonucunun yorumunda hazır FinBERT'in Reuters TRC2 ile ön eğitilmiş olması nedeniyle olası veri örtüşmesi göz önünde tutulmalıdır.

C. Tarafsız sınıf ve etiket semantiği

Tarafsız sınıf, ince ayar sonrasında da temel karar sınırı olmayı sürdürmüştür; ince ayarlı FinBERT hatalarının %54,3'ü tarafsız sınıftan diğer sınıflara geçişlerden oluşmuştur. Hataların yaklaşık %77'sinin en az 0,90 güvenle üretilmesi, sorunun yalnızca belirsiz örneklerden değil, farklı etiket semantiği altında sistematik yorum farklarından kaynaklandığını göstermektedir; bu nedenle hata analizi yalnızca model yanlışı olarak sunulmamalıdır. Finansal sözcüklerin genel duygu sözlüklerinden farklı yorumlanması gerektiğini ortaya koyan geleneksel bulgular [1], bu çalışmada sınıf etiketlerinin veri setleri arasındaki anlam farklılığına genişletilmiştir: Financial PhraseBank kurumsal haber cümlelerinin ekonomik etkisini merkeze alırken [4], bu çalışmanın ana veri seti kısa ve piyasa yönelimli metinler içermektedir. belgelenen post-hoc rubrik, bu karar sınırlarının tarafsız sınıf etrafında yoğunlaştığını göstermektedir.

D. Sentetik verinin yorumu

Sentetik setteki 0,9551–0,9957 aralığındaki Macro-F1 değerleri ile Reuters'taki 0,5869–0,6866 aralığı arasındaki keskin fark, sentetik performansın gerçek dünya genellemesini belirgin biçimde fazla iyimser gösterdiğini kanıtlamaktadır. Sentetik veri kontrollü bir stres testi amacıyla yararlıdır; ancak gerçek Reuters ve S&P 500 dış testlerinin yerine geçmemelidir. Sentetik setin sınıf koşullu üretimle ve insan doğrulaması olmadan hazırlanmış olması, bu setin yalnızca tanısal amaçla kullanılmasını gerektirmektedir.

E. Araştırma sorularının yanıtlanması

AS1: Evet; hazır FinBERT 0,6794'ten 0,8512'ye yükselmiştir. AS2: Üç tohum ortalamasında sıralama RoBERTa ($0,8728 \pm 0,0068$), ince ayarlı FinBERT ($0,8480 \pm 0,0028$), BERT ($0,8396 \pm 0,0023$), DistilBERT ($0,8231 \pm 0,0028$) biçimindedir. AS3: Hayır; RoBERTa S&P 500'de üstünlüğünü korurken Reuters'ta hazır FinBERT birinci olmuştur. AS4: Evet; tarafsız sınıf hata yönleri ile kaynak-ablasyonu, kaynak ve etiket semantiğinin karar sınırlarını etkilediğini göstermiştir. AS5: Sentetik Macro-F1 değerleri gerçek S&P 500 ve Reuters dış testlerinden daha yüksek gerçekleşmiştir. Buna göre H1, H2, H4 ve H5 desteklenmiş; H3 desteklenmemiştir.

VI. SONUÇLAR

Bu çalışma, finansal duygu analizinde hedef veri setine özgü ince ayarın güçlü bir performans kazanımı sağladığını göstermiştir. İç testte RoBERTa 0,8651 Macro-F1 ile ilk sırada yer alırken, ince ayarlı FinBERT 0,8512 ile ikinci olmuştur. Üç tohum ortalamasında da aynı sıralama korunmuş; RoBERTa $0,8728 \pm 0,0068$

Macro-F1 ile öne çıkmıştır. Buna karşılık dış testlerde model sıralaması değişmiş ve Reuters veri setinde hazır FinBERT 0,6866 Macro-F1 ile en yüksek sonucu vermiştir.

Bulgular, tek bir modelin tüm finansal metin kaynaklarında evrensel olarak en iyi olmadığını göstermektedir. Veri kaynağı, etiket semantiği ve hedefe özgü ince ayar model başarısını birlikte belirlemektedir. Sentetik verideki yüksek skorların gerçek haber genellemesini tek başına temsil etmediği görüldüğünden, uygulamalarda model seçimi bağımsız dış testler ve verimlilik ölçütleriyle birlikte değerlendirilmelidir.

KOD VE VERİ ERİŞİLEBİLİRLİĞİ

Deneylerde kullanılan kodlar, eğitim ayarları ve dosyalar GitHub deposunda paylaşılmıştır: https://github.com/serkankaymak/financial_sentiment_thesis

KAYNAKLAR

- [1] T. Loughran and B. McDonald, “When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks,” *Journal of Finance*, vol. 66, no. 1, pp. 35–65, 2011.
- [2] B. Lefort, E. Benhamou, B. Guez, J.-J. Ohana, E. Setrouk, and A. Etienne, “FinMarBa: A Market-Informed Dataset for Financial Sentiment Classification,” *arXiv:2507.22932*, 2025.
- [3] D. Araci, “FinBERT: Financial sentiment analysis with pre-trained language models,” *arXiv preprint arXiv:1908.10063*, 2019.
- [4] P. Malo, A. Sinha, P. Korhonen, J. Wallenius, and P. Takala, “Good debt or bad debt: Detecting semantic orientations in economic texts,” *JASIST*, vol. 65, no. 4, pp. 782–796, 2014. doi:10.1002/asi.23062.
- [5] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *NAACL-HLT*, 2019.
- [6] Y. Yang, M. C. S. UY, and A. Huang, “FinBERT: A pretrained language model for financial communications,” *arXiv preprint arXiv:2006.08097*, 2020.
- [7] Y. Liu et al., “RoBERTa: A robustly optimized BERT pretraining approach,” *arXiv preprint arXiv:1907.11692*, 2019.
- [8] V. Sanh et al., “DistilBERT, a distilled version of BERT,” *arXiv preprint arXiv:1910.01108*, 2019.
- [9] S. Storks, Q. Gao, and J. Y. Chai, “Recent advances in natural language inference: A survey of benchmarks, resources, and approaches,” *arXiv preprint arXiv:1904.01172*, 2019.
- [10] J. Magomere, E. Kochkina, S. Mensah, S. Kaur, and C. H. Smiley, “FinNLI: Novel dataset for multi-genre financial natural language inference benchmarking,” in *Findings of the Association for Computational Linguistics: NAACL 2025*, pp. 4545–4568, 2025.
- [11] Y. Guo, C. Hu, and Y. Yang, “Predict the Future from the Past? On the Temporal Data Distribution Shift in Financial Sentiment Classifications,” in *Proc. 2023 Conf. Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1029–1038, Singapore, 2023. doi:10.18653/v1/2023.emnlp-main.65.
- [12] R. Snow, B. O’Connor, D. Jurafsky, and A. Y. Ng, “Cheap and fast—but is it good? Evaluating non-expert annotations for natural language tasks,” *EMNLP*, 2008.
- [13] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.
- [14] J. L. Fleiss, “Measuring nominal scale agreement among many raters,” *Psychological Bulletin*, vol. 76, no. 5, pp. 378–382, 1971.
- [15] K. Krippendorff, *Content Analysis: An Introduction to Its Methodology*. Sage, 2004.
- [16] J. R. Landis and G. G. Koch, “The measurement of observer agreement for categorical data,” *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977.
- [17] J. Wiebe, T. Wilson, and C. Cardie, “Annotating expressions of opinions and emotions in language,” *Language Resources and Evaluation*, vol. 39, no. 2–3, pp. 165–210, 2005.
- [18] F. Gilardi, M. Alizadeh, and M. Kubli, “ChatGPT outperforms crowd workers for text-annotation tasks,” *PNAS*, vol. 120, no. 30, 2023.